

Métricas

Clase práctica 4

Regresión


Regresión

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$RMSLE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(y_i + 1) - \log(\hat{y}_i + 1))^2} \quad R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Regresión



Regresión

Vayamos con ejemplos de predicción:

1. Precio de Casas 🏠

2. Tiempo de Llegada de una Ambulancia 🚑

3. Notas Alumnos

Regresión - Casas

Casa	Precio Real	Predicción (A/B)
Casa A	\$100,000	\$110,000 / \$102,000
Casa B	\$150,000	\$140,000 / \$148,000
Casa C	\$100,000	\$85,000 / \$97,000
Mansión	\$500,000	\$515,000 / \$450,000

Regresión - Casas

Casa	Precio Real	Predicción (A/B)	Error Cuadrado (A/B)
Casa A	\$100,000	\$110,000 / \$102,000	100M / 4M
Casa B	\$150,000	\$140,000 / \$148,000	100M / 4M
Casa C	\$100,000	\$85,000 / \$97,000	225M / 9M
Mansión	\$500,000	\$515,000 / \$450,000	225M / 2,500M

Regresión - Casas

Casa	Precio Real	Predicción (A/B)	Error Cuadrado (A/B)	Error Absoluto (A/B)
Casa A	\$100,000	\$110,000 / \$102,000	100M / 4M	\$10,000 / \$2,000
Casa B	\$150,000	\$140,000 / \$148,000	100M / 4M	\$10,000 / \$2,000
Casa C	\$100,000	\$85,000 / \$97,000	225M / 9M	\$15,000 / \$3,000
Mansión	\$500,000	\$515,000 / \$450,000	225M / 2,500M	\$15,000 / \$50,000

Regresión - Casas




Casa	Precio Real	Predicción (A/B)	Error Cuadrado (A/B)	Error Absoluto (A/B)	Error % (A/B)
Casa A	\$100,000	\$110,000 / \$102,000	100M / 4M	\$10,000 / \$2,000	10% / 2%
Casa B	\$150,000	\$140,000 / \$148,000	100M / 4M	\$10,000 / \$2,000	6.67% / 1.3%
Casa C	\$100,000	\$85,000 / \$97,000	225M / 9M	\$15,000 / \$3,000	15% / 3%
Mansión	\$500,000	\$515,000 / \$450,000	225M / 2,500M	\$15,000 / \$50,000	3% / 10%

Regresión - Casas

*mencionar relación MAPE / RMSLE

Casa	Precio Real	Predicción (A/B)	Error Cuadrado (A/B)	Error Absoluto (A/B)	Error % (A/B)
Casa A	\$100,000	\$110,000 / \$102,000	100M / 4M	\$10,000 / \$2,000	10% / 2%
Casa B	\$150,000	\$140,000 / \$148,000	100M / 4M	\$10,000 / \$2,000	6.67% / 1.3%
Casa C	\$100,000	\$85,000 / \$97,000	225M / 9M	\$15,000 / \$3,000	15% / 3%
Mansión	\$500,000	\$515,000 / \$450,000	225M / 2,500M	\$15,000 / \$50,000	3% / 10%
Promedio (métrica)			MSE: 162M / 629M	MAE: \$12,500 / \$14,250	MAPE: 8.67% / 4.08%

Regresión - Errores



Regresión - Salvar a Charlie

?

(Dot)



(Utdt)

Regresión - Salvar a Charlie

Opinión A: 18 minutos

Opinión B: 21 minutos


Opinión C: 16 minutos

Regresión - Salvar a Charlie

Opinión A: 18 minutos **3 mins**

Opinión B: 21 minutos **6 mins**

Opinión C: 16 minutos **1 min**




Regresión - Salvar a Charlie


Opinión A: 18 minutos **3 mins**

Opinión B: 21 minutos **6 mins**


Opinión C: 16 minutos **1 min**




Regresión - Salvar a Charlie




Regresión - Salvar a Charlie



Regresión - Salvar a Charlie



Regresión - Salvar a Charlie



Regresión - Notas

Alumno A: 6

Alumno C: 10

Alumno E: ?

Alumno B: 8

Alumno D: ?

Alumno F: ?

Regresión - Notas

Alumno A: 6

Alumno C: 10

Alumno E: ?

Alumno B: 8

Alumno D: ?

Alumno F: ?

¿Y si tomamos el promedio?

Regresión - Notas

Alumno A: 6

Alumno C: 10

Alumno E: ?

Alumno B: 8

Alumno D: ?

Alumno F: ?

¿Y si tomamos el promedio?

$$(6 + 8 + 10) / 3 = 8 \longrightarrow$$

Predecir siempre 8 no tiene mucho sentido, pero sí establece un baseline

Regresión

Alumno	Real	Predicho Baseline	Error
D	6	8	2
E	8	8	0
F	10	8	2

$$R = 0$$

Regresión

Alumno	Real	Predicho Baseline	Error
D	6	8	2
E	8	8	0
F	10	8	2

R = 0

Alumno	Real	Predicho Baseline	Error
D	6	7	1
E	8	8	0
F	10	9	1

R = 0.75

Regresión

Alumno	Real	Predicho Baseline	Error
D	6	8	2
E	8	8	0
F	10	8	2

$$R = 0$$


Alumno	Real	Predicho Baseline	Error
D	6	7	1
E	8	8	0
F	10	9	1

$$R = 0.75$$

El modelo explica el 75% de la variación de las notas respecto al baseline de predecir siempre el promedio.

Clasificación

Clasificación



Clasificación

Accuracy

Casos **bien** clasificados por sobre el total de casos

¿Qué pasa con el modelo que siempre dice **SÍ**?

Clasificación

Accuracy

Casos **bien** clasificados por sobre el total de casos

¿Qué pasa con el modelo que siempre dice **SÍ**?

¿La persona está enferma?

1000 personas

990 enfermas

10 sanas

Clasificación

Accuracy

Casos **bien** clasificados por sobre el total de casos

¿Qué pasa con el modelo que siempre dice **SÍ**?

¿La persona está enferma?

1000 personas

990 enfermas

10 sanas



Accuracy = $990 / 1000 = 99\%$

Clasificación

Accuracy

Casos **bien** clasificados por sobre el total de casos

¿Qué pasa con el modelo que siempre dice **SÍ**?

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas



$$\text{Accuracy} = 10 / 1000 = 1\%$$

muy engañosa!

Clasificación

¿Es igual de grave predecir “**sí**” cuando en realidad era “**no**” que predecir “**no**” cuando en realidad era “**sí**”?



Clasificación

¿Es igual de grave predecir “**sí**” cuando en realidad era “**no**” que predecir “**no**” cuando en realidad era “**sí**”?



Clasificación

¿Es igual de grave predecir “**sí**” cuando en realidad era “**no**” que predecir “**no**” cuando en realidad era “**sí**”?



Clasificación

Matriz de Confusión

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

Clasificación

Matriz de Confusión

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Clasificación

Matriz de Confusión

		Predicted	
		Positive	Negative
Actual	Positive	TP 10	FN 0
	Negative	FP 980	TN 10

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2%

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas

Clasificación

Matriz de Confusión

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas

		Predicted	
		Positive	Negative
Actual	Positive	TP 10	FN 0
	Negative	FP 990	TN 10

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2%

$$Precision = \frac{TP}{TP + FP}$$

Clasificación

Matriz de Confusión

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas

		Predicted	
		Positive	Negative
Actual	Positive	TP 10	FN 0
	Negative	FP 990	TN 10

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2%

$$Precision = \frac{TP}{TP + FP}$$

Quando el modelo dice **sí**,
¿Cuántas veces tiene razón?

Clasificación

Matriz de Confusión

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas

		Predicted	
		Positive	Negative
Actual	Positive	TP 10	FN 0
	Negative	FP 990	TN 10

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2%

$$Precision = \frac{TP}{TP + FP}$$

1%

Clasificación

Matriz de Confusión

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas

		Predicted	
		Positive	Negative
Actual	Positive	TP 10	FN 0
	Negative	FP 990	TN 10

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2%

$$Precision = \frac{TP}{TP + FP}$$

1%

$$Recall = \frac{TP}{TP + FN}$$

Clasificación

Matriz de Confusión

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas

		Predicted	
		Positive	Negative
Actual	Positive	TP 10	FN 0
	Negative	FP 990	TN 10

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2%

$$Precision = \frac{TP}{TP + FP}$$

1%

$$Recall = \frac{TP}{TP + FN}$$

De los que **sí** eran ¿Cuántos dijo que **sí**?

Clasificación

Matriz de Confusión

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas

		Predicted	
		Positive	Negative
Actual	Positive	TP 10	FN 0
	Negative	FP 990	TN 10

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2%

$$Precision = \frac{TP}{TP + FP}$$

1%

$$Recall = \frac{TP}{TP + FN}$$

100%

Clasificación

Matriz de Confusión

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas

		Predicted	
		Positive	Negative
Actual	Positive	TP 10	FN 0
	Negative	FP 990	TN 10

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2%

$$Precision = \frac{TP}{TP + FP}$$

1%

$$Recall = \frac{TP}{TP + FN}$$

100%

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$



Equilibrio entre **Precision** y **Recall**

Clasificación

Matriz de Confusión

¿La persona está enferma?

1000 personas

10 enfermas

990 sanas

		Predicted	
		Positive	Negative
Actual	Positive	TP 10	FN 0
	Negative	FP 990	TN 10

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2%

$$Precision = \frac{TP}{TP + FP}$$

1%

$$Recall = \frac{TP}{TP + FN}$$

100%

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

2%

Clasificación

ROC, AUC-ROC

En general, los modelos arrojan la **probabilidad** de pertenecer a la clase **positiva**

Un **threshold** se usa para decidir si la muestra es **positiva** o no

Las **métricas** que vimos son muy sensibles al **threshold**

Queremos ver cómo se comporta el **modelo** si variamos el **threshold**

NO usar con clases muy desbalanceadas

Clasificación

ROC, AUC-ROC

$$\text{True Positive Rate} = TPR = \frac{TP}{P} = \frac{TP}{TP + FN} = \text{Recall}$$

$$\text{False Positive Rate} = FPR = \frac{FP}{N} = \frac{FP}{FP + TN}$$

Clasificación

ROC, AUC-ROC


True Positive Rate: 0/10

False Positive Rate: 0/10

Matriz de Confusión


		Prediction label	
		POS (+)	NEG (-)
Actual label	POS (+)	0	10
	NEG (-)	0	10

ROC



Clasificación

ROC, AUC-ROC



Clasificación

PR, AUC-PR

Relación entre **Precision** y **Recall** cuando variamos el **threshold**

Prioriza las **métricas** sobre la clase **positiva**

Clasificación

PR, AUC-PR

