

Objetivo

El objetivo de este Trabajo Práctico es que experimenten el ciclo de vida completo de un proyecto de Machine Learning en un entorno competitivo real. Deberán resolver un problema de clasificación multiclase utilizando datos de la industria musical, participando en una competencia interna en **Kaggle**, y luego contrastando las métricas de laboratorio con el verdadero impacto en el negocio.

El entregable consiste en un Jupyter Notebook (`.ipynb`) que incluya todo su código, junto a un pequeño informe con el análisis y las decisiones tomadas durante el desarrollo.

Competencia en Kaggle

Trabajarán con un dataset basado en métricas acústicas de Spotify. El objetivo es predecir a qué género musical pertenece una canción basándose en otras características (como *danceability*, *energy*, *tempo*, etc.).

Entorno de competencia

- Deben unirse a la competencia de Kaggle a través del link provisto en el Campus Virtual.
- Tienen un conjunto de entrenamiento (`train.csv`) y uno de prueba (`test.csv`) cuyas etiquetas deben predecir.
- En la sección de datos de la competencia podrán encontrar la información sobre cada columna del dataset.
- El dataset utilizado es un derivado del dataset presente en <https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset>. No está permitido utilizar APIs externas (como la API de Spotify) o intentar cruzar los datos del dataset del TP con el dataset original con el fin de encontrar las etiquetas correspondientes.

Enunciado

Más allá de buscar conseguir el mejor resultado posible en la competencia de Kaggle se debe cumplir, como mínimo, con los siguientes puntos:

- Realizar un Análisis Exploratorio de Datos (EDA). ¿Qué características diferencian mejor a los distintos géneros? Incluyan al menos tres visualizaciones clave.
- Preprocesamiento de los datos. Más allá de que la aplicación de modelos *out-of-the-box* puede resultar útil, el dataset admite diferentes preprocesamientos posibles. Explicar cuáles utilizaron y por qué.
- Implementar al menos dos modelos distintos de Machine Learning para la predicción.

- Realizar una búsqueda de hiperparámetros (ej. *GridSearchCV* o *RandomizedSearchCV*) optimizando la métrica oficial de la competencia.
- Realizar un Model Selection robusto aplicando las técnicas vistas en la materia.
- En la competencia de Kaggle, la métrica a optimizar es el **F1-Score (Macro)**. Esta métrica exige que el modelo acierte exactamente el género de la canción en su primera predicción, castigando todos los errores por igual.

Sin embargo, Spotify es un *Sistema de Recomendación*. A los usuarios se les ofrecen listas con múltiples opciones. En el mundo real del negocio, es mucho más valioso que el género correcto esté dentro de las **top 3 predicciones** del modelo, a que se equivoque rotundamente por forzar una sola etiqueta.

- Investiguen e implementen una función que calcule la métrica **MAP@3** (*Mean Average Precision at K=3*) sobre su conjunto de validación local.
- Comparen el rendimiento de los modelos utilizados para la competencia de kaggle utilizando ahora ambas métricas (F1-Macro y MAP@3).
- Ideen formas de buscar una optimización del MAP@3 para sus modelos, aún a costa de perder performance en la métrica original.
- Realicen una explicación de qué métrica utilizarían en diferentes posibles casos de negocio. Mencionen, si es necesario, otras métricas diferentes que podrían adecuarse mucho mejor al problema de negocio real.

Modalidad de Entrega

- El trabajo se debe realizar en grupos de 3 personas. Únicamente **1 integrante** del grupo debe subir el TP a la carpeta correspondiente en el Campus Virtual.
- La entrega debe contener una forma clara de replicar el CSV final enviado a Kaggle..
- Las consultas virtuales deben realizarse **exclusivamente** a través del foro **TP Integrador** — **Consultas** en el Campus Virtual.
- El trabajo se debe entregar hasta las **23:59hs del domingo 10 de mayo**.