

XGBoost y Ejercicios Guía 2


Clase práctica 8

XGBoost | Idea General


Explicación didáctica **super recomendada** (por StatQuest): [LINK](#)

Conceptos principales:

- **No creamos un solo árbol grande, creamos muchos.**
- **Cada árbol corrige el error de los anteriores**
- La **predicción final** es la **suma de todas las predicciones** (correcciones sobre sus “antepasados”).



XGBoost | Noción del Gradiente



XGBoost | Sus 7 hiperparámetros más importantes

- **n_estimators** | Número de **árboles** a crear. OF: porque se corrigen demasiados errores
- **max_depth** | **Profundidad** máxima para cada árbol.
- **eta** o **learning_rate** | Tasa de **aprendizaje**.
- **gamma** | Mínima reducción del **error** para generar un corte.
- **min_child_weight** | Mínima cantidad de obs. en los **hijos** para generar un corte.
- **subsample** | Proporción de **observaciones** a muestrear y considerar en cada árbol.
- **colsample_bytree** | Proporc. de **variables** a muestrear y considerar en cada árbol.
(atributos)

¿Qué son? Definición.

¿Cuándo aumentan las chances de *overfitting*? Cuanto más **altos** vs. más **bajos** son.

XGBoost | Otros de sus hiperparámetros útiles

- **early_stopping_rounds** | Dejará de crear árboles si el *score* no mejora, al menos, una vez durante el número indicado de iteraciones. Por defecto, vale None.
Antes de hacer overfitting, se puede frenar cuando se alcance un mínimo de validation error.
- **reg_lambda** | Término de regularización de tipo L2 (i. e., ridge; término de penalización implica elevar al cuadrado) sobre pesos de las hojas. Permite crear árboles cuyas hojas tienen pesos más pequeños. Por defecto, vale 1.

XGBoost | Ventajas

En la teórica, ya vimos qué es XGBoost y cuáles son sus **ventajas**.

Entre otras cosas:

- Permite trabajar con valores **missings**.
- Permite trabajar con **matrices ralas***.
- Permite ser **acelerado** por GPU.
- Es un **algoritmo distribuido** (i. e., distintos componentes que interactúan entre sí para lograr un objetivo en común).

* : formalmente, una **matriz rala** es una **matriz que tiene una cantidad relativamente alta de elementos que son 0** (e.g., el 50%) (más info. [acá](#)). Una matriz rala puede ser **almacenada** de diferentes formas (más info. [acá](#)).

XGBoost | Modo

Para conocer cómo usar XGBoost en Python, veamos `td6-p09-c-xgboost.ipynb`.

XGBoost | Recursos

- Primera opción: documentación oficial [general](#), [sobre los hiperparámetros](#) y [sobre el uso en Python](#).
- Otros: [Geek for Geeks](#) y [StatQuest](#).

Ejercicios Guía 2

Clase práctica 8

22. Una fintech emergente llamada CréditoRápido nos contrató para auditar su sistema de scoring crediticio. El objetivo del sistema es decidir automáticamente si se le otorga o no un microcrédito a un usuario basándose en su probabilidad de *default* (impago).

El equipo de Data Science anterior dejó implementada una solución antes de renunciar. Contamos con la siguiente información sobre el desarrollo actual:

Se cuenta con un histórico de 100,000 préstamos otorgados. De estos, solo 3,500 resultaron en impago (default), mientras que el resto fueron pagados a término. Las variables incluyen historial de navegación en la app y modelo del celular.

Debido a la complejidad del problema y la necesidad de mostrar buenos resultados al CEO, el equipo decidió entrenar una Red Neuronal Profunda con 5 capas ocultas utilizando PyTorch. El reporte final del modelo muestra las siguientes métricas en el conjunto de test:

- Accuracy : 96.5
- Loss Function: Binary Cross Entropy

A pesar de la métrica reportada, el CFO no está nada contento. La empresa está perdiendo plata porque se otorgan muchos créditos que no se pagan. Además, el área legal ha recibido denuncias de usuarios rechazados exigiendo saber el motivo exacto del rechazo, y el equipo de tecnología responde que la red neuronal es una caja negra y no permite saber qué variable causó la decisión.

Mencionar y justificar todos los aspectos a mejorar que tiene la solución actual. ¿Cómo se podría mejorar cada uno de estos aspectos? ¿Qué otros aspectos importantes fueron omitidos y sería importante tenerlos en cuenta? ¿Cómo se pueden tener en cuenta?

23. En los últimos años se han popularizado soluciones de machine learning para predecir la necesidad de mantenimiento en diferentes maquinarias. El objetivo de este problema es lograr detectar que una maquinaria particular necesita diversos ajustes antes de que suceda una rotura mayor. Como parte de nuestro trabajo para la planta productora que tenemos a cargo, contamos con diversos datos sobre las máquinas: sensores para detectar vibraciones, sonidos emitidos, energía eléctrica consumida, temperaturas, etc. Adicionalmente contamos con otros datos de fabricación de las máquinas y también contamos con reportes históricos de problemas y diversas roturas. El objetivo es desarrollar un modelo que nos indique cuándo una máquina está necesitando un tratamiento preventivo. Describa todos los pasos que haría para conseguir una solución al problema.

Describa toda parte del camino de Machine Learning que considere necesario. Como guía, se pueden utilizar las siguientes preguntas, sin tener que limitarse a ellas:

- ¿En qué categoría de Machine Learning cae este problema?
- ¿Es un problema de regresión o de clasificación?
- ¿Qué debemos hacer con los features para poder utilizar el modelo elegido? Más allá de lo que debemos hacer, ¿Qué otros preprocesamientos podemos hacer? ¿Qué otros datasets podemos sumar para tener mayor poder predictivo?
- ¿Hay algún problema con el balance de los datos? ¿Es necesario hacer algo al respecto?
- ¿Qué modelos de Machine Learning vamos a utilizar?
- ¿Qué métricas van a resultar de mayor interés en este problema?
- ¿Nos interesa la interpretabilidad o *solamente* queremos predecir?
- ¿Qué cuestiones se deben tener en consideración para utilizar nuestro desarrollo en un ambiente real?

14. Para un problema de clasificación binaria tenemos 3 modelos entrenados. Cada uno de estos modelos presenta una accuracy de 0.8. Si armamos un ensamble de Majority Voting a partir de estos 3 modelos, ¿cuál será la accuracy del ensamble resultante?

6. Suponga que tiene un problema de clasificación en dos dimensiones (X_1 y X_2) donde la clase positiva se encuentra concentrada en el centro del plano formando un círculo, y la clase negativa forma un anillo alrededor de ella. ¿Puede una Regresión Logística estándar separar estas clases de manera efectiva?. Si la respuesta es afirmativa, ¿cómo?. Si la respuesta es negativa, ¿existe alguna adaptación posible para que sea capaz?