



UNIVERSIDAD
TORCUATO DI TELLA

Licenciatura en Tecnología Digital

Tecnología Digital VI: Inteligencia Artificial

Práctica Pre-Parcial Integradores

Clase práctica 10

Aclaración Importante

Notar que los siguientes ejercicios no son de una sola respuesta correcta. Sino para desarrollar y justificar la toma de decisiones a lo largo del camino. Se pueden tomar supuestos razonables y avanzar en diferentes direcciones. La idea es que resuelvan de una manera que se sientan cómodos como resolverían un problema del estilo en un caso real. Siempre explicando el porqué de las decisiones y los posibles problemas de las mismas.

Las resoluciones/ideas listadas son posibles justificaciones coherentes entre sí y al approach tomado en estas slides.

Tomenlas para comparar si tomaron algun approach similar y para sumar ideas para completar sus respuestas en la medida que sigan la misma linea que lo que plantearon ustedes.

Si les sirve otro orden/enfoque o separar en problema en secciones también puede estar bien.

21. Se tiene un dataset tabular que contiene información demográfica y transaccional de los clientes de un servicio de películas y series basado en suscripción. El objetivo es construir un modelo de predicción de churn (abandono) para identificar a los clientes que tienen más probabilidades de cancelar su suscripción. El conjunto de datos presenta valores faltantes, clases desbalanceadas con un mayor número de clientes que no cancelan su suscripción, y una combinación de características numéricas y categóricas. Describa los pasos que haría, considerando estos desafíos específicos, para construir un modelo efectivo de predicción de churn.

Describa toda parte del camino de Machine Learning que considere necesario. Como guía, se pueden utilizar las siguientes preguntas, sin tener que limitarse a ellas:

- ¿Es un problema de regresión o de clasificación? ¿Qué se considera como churn?
- ¿Qué debemos hacer con los features para poder utilizar el modelo elegido? Más allá de lo que debemos hacer, ¿Qué otros preprocesamientos podemos hacer? ¿Qué otros datasets podemos sumar para tener mayor poder predictivo?
- ¿Qué modelos de Machine Learning vamos a utilizar?
- ¿Qué cuestiones se deben tener en consideración para utilizar nuestro desarrollo en un ambiente real?

Algunas ideas o respuesta ejemplo:

- Churn puedo plantearlo como un **problema de clasificación**. Donde la variable objetivo (churn) es **si un cliente abandona el servicio en un horizonte determinado**. Supongamos 30 días. 1 si deja el servicio en un plazo de 30 días, 0 si sigue estando suscripto.
- Si tenemos valores faltantes, podemos eliminar observaciones, algún método de imputación (media, mediana, etc) o usar un modelo que los termine handleando. Al no saber el tamaño del dataset ni si hay información en esos faltantes, **siempre optaría por una de las últimas dos y nunca por eliminar observaciones**. Eliminarlas tiene 2 cons principalmente. Primero, podemos estar potenciando un sesgo subyacente, es decir, que la razón de ser faltante no sea aleatoria. Por otro lado, en un caso real que estaríamos haciendo, no dar una respuesta?
- Por modelo plantearía inicialmente 2, una **regresión logística y un random forest para tener un baseline de performance sin depende de demasiados parámetros**. Y más adelante iría con más complejos en búsqueda de performance. La regresión logística es interpretable desde sus coeficientes y extrapola en caso de tener rangos acotados de datos. El random forest por otro lado capta interacciones entre variables.
- **Cada modelo necesita distintos preprocesamientos**. La reg.log. necesita escalado e imputaciones, mientras que el random por el momento diría que ninguno por fuera de las categóricas por ejemplo one hot encoding con cuidado si hay clases que aparecen muy poco para evitar overfitting. Aunque para ambos casos seguro sea necesario algún manejo de pesos o cantidad de observaciones por el desbalance. Sample_weights es un parámetro que puede ayudara decir cuanto pesa cada observación en relación al desbalance que quiero compensar. Y sino algún tipo de up/downsampling.

Algunas ideas o respuesta ejemplo (continuación):

- Elegir una métrica robusta a optimizar (AUC ROC (relativa) y **AUC PR por desbalance, es decir precisión/recall** para ver si los que se están por ir los encuentro y con que seguridad). Quizás más de una para evaluar desde el punto de negocio, ejemplo la matriz de confusión y un costo/beneficio asociado a el uso de la predicción de churn. Si se iba a ir con 90% de chance, y le mando oferta, y se queda, cuanto evite perder?
- El primer **dataset que se me ocurre para sumar** dado que partimos solo de uno demográfico y uno transaccional, es uno de **actividad**. Se me ocurre que algo bastante informativo es con que regularidad viene utilizando el servicio. Naturalmente, aunque el modelo despues dirá, a menor actividad mayor chance de abandono pensaría.
- En un entorno real, **tiempo de estimación** se me ocurre como algo interesante, si predecimos churn a 1 día y el modelo tarda 2 días en predecir entonces no nos sirve de nada. También no solo evaluar por si o por no sino que **tan certera es la probabilidad respecto a su frecuencia real (calibración)** para ver si podemos confiar en esa probabilidad para hacer cuenta probabilísticas de que tan rentable es darle una oferta para que no se vaya a un cliente por ejemplo. Si quiero reentrenar el modelo seguido para ver si ciertas features toman más o menos importancia a medida que pasa el tiempo. Obviamente un **monitoreo continuo** para ver si las metricas que esperaba se mantienen estables.

5. Estamos trabajando en un reconocido hospital de la ciudad y tenemos a cargo la logística asociada a la asignación de camas para los pacientes. Dado que es un hospital con mucha demanda, sería muy útil contar con un modelo predictivo que nos pueda indicar en qué momento se irán liberando las diferentes camas para que puedan ser asignadas a nuevos pacientes.

Para esto contamos, al menos como punto de partida, con un dataset tabular que tiene información de las características de cada paciente (edad, peso, altura, entre otras mediciones) e información contextual (fecha de ingreso, cantidad de internaciones previas, especialización por la cuál fue admitido, etc).

El objetivo es construir un modelo de predicción que nos ayude a entender qué camas vamos a tener disponibles en los próximos días. El conjunto de datos presenta valores faltantes y una combinación de características numéricas y categóricas.

Describe los pasos que haría, considerando estos desafíos específicos, para construir un modelo efectivo.

Describe toda parte del camino de Machine Learning que considere necesario. Como guía, se pueden utilizar las siguientes preguntas, sin tener que limitarse a ellas:

- ¿Es un problema de regresión o de clasificación? ¿Cuál es específicamente el valor a predecir?
- ¿Qué debemos hacer con los features para poder utilizar el modelo elegido? Más allá de lo que debemos hacer, ¿Qué otros preprocesamientos podemos hacer? ¿Qué otros datasets podemos sumar para tener mayor poder predictivo?
- ¿Qué modelos de Machine Learning vamos a utilizar?
- ¿Qué cuestiones se deben tener en consideración para utilizar nuestro desarrollo en un ambiente real?

Algunas ideas o respuesta ejemplo:

- Lo plantería como un **modelo de regresión para cada paciente individual siendo la variable a predecir cuantos días le quedan para irse** a un determinado paciente en cama. Y después haría una agregación de las predicciones para saber mi disponibilidad estimada total a diferentes plazos.
- Hay una decisión importante respecto a si mi predicción se hace regularmente (frecuencia diaria o menor) o una vez para cada paciente cuando ingresa. **El problema de esto sería que me quedo con información vieja y probablemente pierda valor en mi predicción.** Ej: Un cliente se viene a ver por tal especialización, supongamos que para estos casos suele pasar que, ó no encuentran nada y se va rápido (1 día) o se va en mucho tiempo (7 días). Si tuviera una feature de hace cuanto esta y especialización, un árbol podría facilmente predecir que al pasar 2 días es probable que este 5 más. En cambio si predigo una vez cuando llega el paciente, tendría que predecir 4 días porque no tendría esa información nueva y lo que mejor minimiza (caso balanceado), es la mitad entre 1 y 7. Cada acercamiento al problema tiene sus pros/cons. Al también predecir sobre pacientes sobre los que tengo más información, aquellos en cama, podría ganar valor, al mismo tiempo genero “artificialmente” más observaciones de los que más días se quedaron... posible “desbalanceo”.

Notar que uno lo puede plantear como regresión de esta manera y quizás tenga incluso más sentido si necesitamos precisión en términos de horas. O también como clasificación y definir distintos horizontes al cual se libera o no la cama. Cada uno con su justificación.

Algunas ideas o respuesta ejemplo (continuación):

- En cuanto al **preprocesamiento podemos tomar de la solución anterior todo en relación a cada modelo**. Por la interacción explicada arriba, es probable que sea mejor utilizar árboles o analizar que interacciones suceden para manualmente agregarlas como features a la regresión. **Notar que no sería regresión logística o arbol regresor, sino regresión lineal y arbol clasificador.**
- Si hay pocos datos, los **árboles no interpolan** por ejemplo edad, etc. Entonces si por algún motivo tenemos este tipo de problema y hay relaciones lineales del tipo, mayor edad => mayor tiempo, entonces sería interesante tener o un ensamble de ambos modelos o tan solo ver si con la regresión es suficiente.
- Pensando un poco en la métrica. **MSE a optimizar suena coherente dado que si nos interesa penalizar pocos casos en donde le erramos por mucho**. Si quisieramos una métrica **interpretable** para los del hospital quizás el **RMSE** sea más adecuado. Alguna simulación de escenarios o estimación del error a la hora de agregar todos los errores y estimaciones de las camas quizás ayude a obtener un “número de camas esperadas disponibles” vs “efectivamente disponibles” para tal horizonte”.
- Como es un problema temporal, podríamos simular estimaciones y esta métrica como evolucionaría en el tiempo, para ver en general si estamos estimando bien las camas disponibles o no para cada horizonte.
- Notar que **desbalanceo no hay por que no es un problema de clases, pero podríamos tener outliers** que nos compliquen no solo el escalado sino también la optimización del MSE, tomar alguna decisión respecto a esto, drop, clip, cambiar MSE por Huber, etc. Cada una tiene ventajas y desventajas. Si desbalanceo, desde el lado observaciones por paciente único quizás como comentamos en la slide anterior.

Algunas ideas o respuesta ejemplo (continuación):

- A la hora de construir el dataset y observaciones, los casos donde siguen en cama a día de hoy, si no son muchos podría droppearlos dado que son muy actuales en la medida que tenga suficientes observaciones, sino podría tomar algun supuesto. Además, tenemos que tener **cuidado con utilizar información futura o que no vaya a estar disponible a la hora de hacer las predicciones.**
- Volviendo al primer punto un poco, es importante tener en cuenta **con que frecuencia se necesita el modelo para evaluar si el tiempo de inferencia es un problema.** No solo eso, sino que la ingesta de datos, su disponibilidad y uso también son importantes. Es decir, quizás no tengo los datos disponibles porque se cargan a la semana. Entonces si uso features del estilo, *hace cuanto esta en cama un paciente* quizás son datos viejos o que no voy a tener disponibles para inferir.
- **Monitoreo de performance** esperada vs. rendimiento del modelo real en los ultimos n días también suena coherente para un caso de producción.