



UNIVERSIDAD
TORCUATO DI TELLA

Licenciatura en Tecnología Digital

Tecnología Digital VI: Inteligencia Artificial

Convoluciones Traspuestas

Clase práctica 18

Convoluciones traspuestas | Contexto

Nosotros ya vimos cómo **mantener** la resolución, mediante el ***stride*** y el ***padding***.

También vimos cómo **disminuir** la resolución, mediante ***pooling***.


Pero, ¿cómo podemos **aumentar** la resolución?

Están las técnicas de **interpolación**, las de **extrapolación** y las **convoluciones traspuestas**.


Convoluciones traspuestas | Contexto (cont.)

Recordemos que las técnicas de **interpolación** implican computar nuevos valores a partir de una **fórmula** e incluyen:

- En base a los **vecinos más cercanos**.
- **La bilineal**.



Mientras tanto, una técnica de **extrapolación** es **unpooling**. En PyTorch: `nn.MaxUnpool1d`; `nn.MaxUnpool2d` y `nn.MaxUnpool3d`; documentación oficial disponible [acá](#).



La diferencia entre interpolación y extrapolación radica en lo siguiente:

- Si el valor “rellenado” se encuentra **entre** otros dos conocidos, **interpolación**.
- Si el valor “rellenado” se encuentra a **izquierda/derecha** de los conocidos, **extrapolación**.

Convoluciones traspuestas | Concepto

Las **convoluciones traspuestas** (a veces llamadas “deconvoluciones”) tienen como objetivo **expandir el tensor de entrada**.

A diferencia de las otras técnicas, la red **aprende** un proceso de *upsampleo*, en vez de basarse en una fórmula matemática fija.

Se usan, por ejemplo, en las **GANs** (redes adversarias generativas), para aumentar las dimensiones del ruido (tamaño del bottleneck) y transformarlo en una imagen.

En el caso de **PyTorch**, la respectiva documentación oficial es [esta](#). Veámosla. Si queremos especificar sus pesos, podemos usar la [versión funcional](#) de la misma clase.


Convoluciones traspuestas | Valores

En las convoluciones traspuestas, tenemos que pensar en 3 cuestiones:

- La cantidad de **canales de salida**.
- La cantidad de **padding**.
 - El padding, en este caso, es **negativo**: se resta del *output*.
 - *Default* = 0.
- La cantidad de **stride** en el **output**.
 - El stride se aplica **al generar el output**.
 - *Default* = 1.

Convoluciones traspuestas | Un primer ejemplo


Para entender mejor la cuestión del **stride**, veamos el siguiente ejemplo, donde el padding es 0 y el stride es **1**.



[Fuente](#)

Convoluciones traspuestas | Un primer ejemplo


Para entender mejor la cuestión del **stride**, veamos el siguiente ejemplo, donde el padding es 0 y el stride es **1**.



[Fuente](#)

Convoluciones traspuestas | Un primer ejemplo


Para entender mejor la cuestión del **stride**, veamos el siguiente ejemplo, donde el padding es 0 y el stride es **1**.



[Fuente](#)

Convoluciones traspuestas | Un primer ejemplo


Para entender mejor la cuestión del **stride**, veamos el siguiente ejemplo, donde el padding es 0 y el stride es **1**.



[Fuente](#)

Convoluciones traspuestas | Un primer ejemplo


Para entender mejor la cuestión del **stride**, veamos el siguiente ejemplo, donde el padding es 0 y el stride es **1**.



[Fuente](#)

Convoluciones traspuestas | Un primer ejemplo


Para entender mejor la cuestión del **stride**, veamos el siguiente ejemplo, donde el padding es 0 y el stride es **1**.



[Fuente](#)

Convoluciones traspuestas | Un segundo ejemplo

Veamos otro ejemplo;
ahora con padding = 0
pero **stride = 2**.



Convoluciones traspuestas | Fórmula para tamaño

Podemos calcular el **tamaño del output** con la siguiente **fórmula**:

$$O = (I-1)*S - 2P + K$$



UNIVERSIDAD
TORCUATO DI TELLA

Licenciatura en Tecnología Digital

Tecnología Digital VI: Inteligencia Artificial

Autoencoders

Clase práctica 18


Motivación

- ¿Cómo se implementa un **autoencoder**? ¿Cómo podemos acceder a su **espacio latente**?
- ¿De qué manera podemos **eliminar ruido** en imágenes?
- ¿Cuáles son sus posibles usos además de los vistos?

Autoencoders

¿Qué pasa si la salida final de un MLP es una entrada para otro MLP invertido?


Autoencoders (continuación)




Autoencoders (continuación)

Veamos un ejemplo en
`td6-p18-c-autoencoder.ipynb`.

Autoencoders (continuación)




Autoencoders (continuación)



Autoencoders (continuación)

Si en este espacio latente está la representación de las imágenes, podríamos probar manipular estos valores para construir nuevas figuras.



Volvamos a `td6-p18-c-autoencoder.ipynb`.

Denoising Autoencoders (DAEs)

Problema:


Los datos pueden tener perturbaciones no deseadas. Por ejemplo, fallas en sensores de una cámara, mala iluminación, interferencia, etc.

Denoising Autoencoders (DAEs) (continuación)


Llamamos **ruido** a las perturbaciones sobre los datos que contaminan el contenido de la información que se quiere recuperar.

Idea: Usar la estructura del Encoder/Decoder para aprender las características más importantes y luego reconstruir la imagen original.

Denoising Autoencoders (DAEs) (continuación)



Denoising Autoencoders (DAEs) (continuación)



En vez de entrenar con los elementos del *dataset* directamente, se modela el ruido. Es decir, se lo caracteriza numéricamente. La salida esperada de la red corresponde al X sin ruido.

Denoising Autoencoders (DAEs) (continuación)

Algunas **técnicas** para **agregar ruido**:

- **Gaussian noise**: se añade a todos los píxeles de la imagen. Tiene distribución de probabilidad normal.
- **Salt and pepper**: un porcentaje de píxeles seleccionados aleatoriamente se cambian a blanco o negro.



Denoising Autoencoders (DAEs) - Taller

Resolvamos el taller `td6-p18-d-dae-taller.ipynb`.