

Tecnología Digital VI

Clustering

Licenciatura en Tecnología Digital - UTDT

Clustering

Problema de aprendizaje no supervisado


El problema de *Clustering* se centra en encontrar subgrupos o *clusters* en un dataset.

Si bien hay muchas técnicas alrededor de este problema, todas persiguen dos principios muy simples:


- Que las muestras asignadas a un mismo subgrupo sean *similares* entre sí.
- Que las muestras asignadas a dos subgrupos distintos sean *disímiles* entre sí.

Con estos principios queda la tarea de definir qué significa que dos muestras sean similares o distintas, lo cual muchas veces es subjetivo y depende del dominio del problema.

Decisiones



(a) 1st clustering



(b) 2nd clustering

Cualquiera de los dos pueden estar bien, por eso es subjetivo. Además, podría decidirse antes cuántos clusters hacer.

Existen múltiples familias de algoritmos de clustering:

- Partitioning: Divide los datos en grupos no superpuestos (Ejemplos: K-Means, K-Medoids) Sin intersecciones.
- Hierarchical: Crea una estructura jerárquica de clusters (Ejemplos: AGNES, DIANA)
- Density-based: Agrupa puntos basándose en áreas de alta densidad (Ejemplos: DBSCAN, OPTICS)
- Grid-based: Divide el espacio en una cuadrícula para formar clusters (Ejemplos: STING, CLIQUE)
- Model-based: Asume un modelo estadístico para crear clusters (Ejemplo: GMM)

Vamos a centrarnos en K-Means y Clustering Jerarquico Aglomerativo (AGNES)

K-means

La técnica de K-means (o K-medias) separa los puntos del dataset en conjuntos sin intersección. El algoritmo toma como parámetro de entrada la cantidad de clusters (*el K*).

Los clusters resultantes cumplen:

1. $C_1 \cup C_2 \cup \dots \cup C_K = \{1, \dots, n\}$. In other words, each observation belongs to at least one of the K clusters.
2. $C_k \cap C_{k'} = \emptyset$ for all $k \neq k'$. In other words, the clusters are non-overlapping: no observation belongs to more than one cluster.

K-means

K-means utiliza la idea de que un buen clustering es aquel que se minimiza la within-cluster variation.

La distancia entre las muestras que quedan en un cluster no son tan grandes.
Un cluster bueno tiene muestras muy concentradas.

$$\underset{C_1, \dots, C_K}{\text{minimize}} \left\{ \sum_{k=1}^K W(C_k) \right\}.$$

Hay muchas maneras de definir esta variación dentro de un cluster. Una muy clásica es utilizar la distancia euclídea entre cada par de puntos.

La normalización es opcional y subjetiva, por más que tenga efecto en esta fórmula.

$$W(C_k) = \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2$$

K-means

Reemplazando la definición de variación en un cluster, el algoritmo busca la siguiente minimización:

$$\underset{C_1, \dots, C_K}{\text{minimize}} \left\{ \sum_{k=1}^K \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2 \right\}$$

Este problema de optimización no es simple de resolver de manera exacta (NP-Hard). La cantidad posible de soluciones (K^n) hace que sea prohibitivo pensar en soluciones de búsqueda exhaustiva.

Ideas K-Means

$$\frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2 = 2 \sum_{i \in C_k} \sum_{j=1}^p (x_{ij} - \bar{x}_{kj})^2$$

Para buscar una *buena solución* al problema de optimización planteado, primero reemplazamos la variación con su definición entre pares de puntos por una definición en función del centroide del cluster. Luego, el algoritmo se basa en dos ideas simples:

- Si ya tengo los puntos originales divididos en clusters, un buen representante del cluster es el centroide de todos los puntos.
- Si ya tengo los centroides definidos, una buena forma de asignar los puntos originales a los clusters es asociándolo al centroide más cercano.

K-means algoritmo

Algorithm 12.2 *K-Means Clustering*

1. Randomly assign a number, from 1 to K , to each of the observations. These serve as initial cluster assignments for the observations.
 2. Iterate until the cluster assignments stop changing:
 - (a) For each of the K clusters, compute the cluster *centroid*. The k th cluster centroid is the vector of the p feature means for the observations in the k th cluster.
 - (b) Assign each observation to the cluster whose centroid is closest (where *closest* is defined using Euclidean distance).
-

Centroides iniciales

El algoritmo presentado es muy sensible a los valores iniciales de los centroides, pudiendo converger a diferentes mínimos.

Para contrarrestar este efecto existen diferentes alternativas:


- Comenzar varias iteraciones del algoritmo con diferentes centroides iniciales.
- Posicionar los centroides iniciales con ciertas técnicas de separación predeterminadas (*k-means++*)



Valor del k

El método pretende de antemano un valor de k , que no está claro como elegirlo.

Si no tenemos información del dominio, una opción es correr el algoritmo para varios valores de k y aplicar el método del codo.



Clustering aglomerativo

Una opción para evitar tener que decidir de antemano el valor del K, es utilizar un método alternativo como *clustering jerárquico aglomerativo*.





Es un método *bottom-up* en el que comenzamos con todos los puntos separados en su propio cluster e iremos juntándolos según qué tan distantes sean entre ellos.

El resultado final será un *dendrograma* de cómo se fueron uniendo los diferentes clusters.

Algorithm 12.3 *Hierarchical Clustering*

1. Begin with n observations and a measure (such as Euclidean distance) of all the $\binom{n}{2} = n(n-1)/2$ pairwise dissimilarities. Treat each observation as its own cluster.
 2. For $i = n, n-1, \dots, 2$:
 - (a) Examine all pairwise inter-cluster dissimilarities among the i clusters and identify the pair of clusters that are least dissimilar (that is, most similar). Fuse these two clusters. The dissimilarity between these two clusters indicates the height in the dendrogram at which the fusion should be placed.
 - (b) Compute the new pairwise inter-cluster dissimilarities among the $i-1$ remaining clusters.
-

Dendrograma



Linkage

Para dos puntos es claro **cómo medir su distancia**, para dos grupos de puntos la noción de distancia **se puede definir de diferentes maneras**. Las 4 más utilizadas:

<i>Linkage</i>	<i>Description</i>
Complete	Maximal intercluster dissimilarity. Compute all pairwise dissimilarities between the observations in cluster A and the observations in cluster B, and record the <i>largest</i> of these dissimilarities.
Single	Minimal intercluster dissimilarity. Compute all pairwise dissimilarities between the observations in cluster A and the observations in cluster B, and record the <i>smallest</i> of these dissimilarities. Single linkage can result in extended, trailing clusters in which single observations are fused one-at-a-time.
Average	Mean intercluster dissimilarity. Compute all pairwise dissimilarities between the observations in cluster A and the observations in cluster B, and record the <i>average</i> of these dissimilarities.
Centroid	Dissimilarity between the centroid for cluster A (a mean vector of length p) and the centroid for cluster B. Centroid linkage can result in undesirable <i>inversions</i> .

El tipo de linkage influye mucho en el resultado y su estructura

Otros métodos

K-means y Clustering Jerárquico Aglomerativo son dos de los métodos más clásicos para el problema de clustering. Existen otras alternativas que persiguen ciertos objetivos particulares:

- DBSCAN: Busca que los clusters *no sean un círculo*. Se adapta a formas irregulares y busca manejar outliers.
- Gaussian Mixture Models: Busca definir probabilidades de que un punto pertenezca a un clusters en vez de dar una respuesta binaria.
- Spectral Clustering: En vez de utilizar directamente la distancia geométrica, utiliza un grafo de vecindad de los puntos.