

Resumen Teórico

Taller de Datos VI

1er Semestre 2026

Materias cubiertas: Introducción, Camino ML, Modelos Lineales, Árboles de Decisión, Ensamblados I–III, Reducción de la Dimensionalidad

Índice

1. Preprocesamiento y Validación

1.1. Calidad de Datos

1.1.1. Valores Faltantes

Existen tres mecanismos de ausencia:

- **MCAR** (Missing Completely at Random): la ausencia no depende de ningún valor.
- **MAR** (Missing at Random): la ausencia depende de otras variables observadas.
- **MNAR** (Missing Not at Random): la ausencia depende del propio valor faltante.

1.1.2. Outliers

- **Z-score**: $z_i = \frac{x_i - \mu}{\sigma}$; se considera outlier si $|z_i| > 3$.
- **Método IQR**: outlier si $x < Q_1 - 1,5 \text{ IQR}$ o $x > Q_3 + 1,5 \text{ IQR}$.

1.1.3. Desbalance de Clases

- **Oversampling**: duplicar muestras de la clase minoritaria.
- **Undersampling**: eliminar muestras de la clase mayoritaria.
- **SMOTE**: generar muestras sintéticas interpolando vecinos de la clase minoritaria.
- **Class weights**: penalizar más la clasificación errónea de la clase minoritaria.

1.1.4. Data Leakage

El **data leakage** ocurre cuando información del conjunto de test (o del futuro) se filtra al entrenamiento. Consecuencia: métricas optimistas que no se reproducen en producción. Prevención: ajustar transformadores *solo* con datos de entrenamiento.

1.2. Escalado de Features

$$\text{MinMax: } x' = \frac{x - x_{\text{mín}}}{x_{\text{máx}} - x_{\text{mín}}}, \quad \text{Estándar: } x' = \frac{x - \mu}{\sigma}, \quad \text{Robusto: } x' = \frac{x - \tilde{x}}{\text{IQR}}$$

1.3. Selección de Features

Tipo	Método	Característica
Filter	Correlación, χ^2 , información mutua	Independiente del modelo
Wrapper	Forward/Backward selection	Evalúa subconjuntos con modelo
Embedded	L1 (Lasso), importancia en árboles	Integrado al entrenamiento

1.4. K-Fold Cross-Validation




Figura 1: 5-Fold Cross-Validation: en cada iteración un fold actúa como validación.

$$\hat{R}_{CV} = \frac{1}{k} \sum_{j=1}^k \text{score}_j$$

2. Métricas de Evaluación

2.1. Regresión

Métricas de Regresión

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1)$$

$$\text{RMSE} = \sqrt{\text{MSE}} \quad (2)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3)$$

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i} \quad (4)$$

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(y_i + 1) - \log(\hat{y}_i + 1))^2} \quad (5)$$

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad (6)$$

2.2. Clasificación

2.2.1. Matriz de Confusión

	Pred. Positivo	Pred. Negativo
Real Positivo	TP	FN
Real Negativo	FP	TN

Métricas de Clasificación

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}$$

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}, \quad \text{TPR} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN}$$

2.2.2. Curva ROC y AUC

La curva ROC grafica TPR vs. FPR para distintos umbrales de clasificación.




Figura 2: AUC-ROC: área bajo la curva. $AUC = 0.5$ equivale a azar; $AUC = 1$ es perfecto.

2.2.3. Curva Precision-Recall

Más informativa que ROC cuando las clases están muy desbalanceadas; se focaliza en la clase positiva.

3. Modelos Lineales

3.1. Regresión Lineal

Modelo

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i \iff \mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

donde $\varepsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$.

3.1.1. Función de Pérdida y Solución Analítica

$$J(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Ecuaciones normales:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

3.2. Regresión Logística

3.2.1. De probabilidades a log-odds

$$\text{odds} = \frac{p}{1-p}, \quad \text{logit}(p) = \ln\left(\frac{p}{1-p}\right)$$

3.2.2. Función Sigmoide

$$\sigma(z) = \frac{1}{1 + e^{-z}} \in (0, 1)$$




Figura 3: La sigmoide mapea cualquier valor real a $(0, 1)$, interpretable como probabilidad.

3.2.3. Modelo y Pérdida

$$P(Y = 1 \mid \mathbf{x}) = \sigma(\boldsymbol{\beta}^\top \mathbf{x})$$

Log-loss (cross-entropía binaria):

$$J(\boldsymbol{\beta}) = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)]$$

3.3. Regularización


La regularización agrega un término de penalización a la función de pérdida para controlar la complejidad del modelo y evitar el sobreajuste.

Formas de Regularización

$$\text{Lasso (L1): } J_{\text{Lasso}}(\mathbf{w}) = J(\mathbf{w}) + \lambda \sum_j |w_j| \quad (7)$$


$$\text{Ridge (L2): } J_{\text{Ridge}}(\mathbf{w}) = J(\mathbf{w}) + \lambda \sum_j w_j^2 \quad (8)$$

$$\text{Elastic Net: } J_{\text{EN}}(\mathbf{w}) = J(\mathbf{w}) + \lambda_1 \sum_j |w_j| + \lambda_2 \sum_j w_j^2 \quad (9)$$



L1: solución esparsa

vs.



L2: coeficientes pequeños

Figura 4: L1 tiende a producir coeficientes exactamente cero (selección de features); L2 encoge todos los coeficientes pero raramente a cero.

Propiedad	L1 (Lasso)	L2 (Ridge)
Coeficientes	Exactamente 0 (esparsidad)	Pequeños, $\neq 0$
Selección de features	Sí	No
Multicolinealidad	Selecciona una	Distribuye el peso
Solución	No analítica	Analítica

4. Árboles de Decisión

4.1. Intuición Geométrica

Un árbol de decisión particiona el espacio de features en regiones rectangulares (hiperplanos perpendiculares a los ejes). Dentro de cada hoja, la predicción es constante.




Figura 5: Un árbol divide recursivamente el espacio de features; cada hoja corresponde a una región rectangular con predicción constante.

4.2. Funciones de Impureza

Para **regresión**, se minimiza el MSE ponderado del nodo:

$$\text{MSE}_m = \frac{1}{N_m} \sum_{i \in m} (y_i - \bar{y}_m)^2$$

Para **clasificación** se emplean:

Gini e Entropía

$$\text{Gini}_m = 1 - \sum_{k=1}^K p_{mk}^2, \quad H_m = - \sum_{k=1}^K p_{mk} \log_2(p_{mk})$$

donde p_{mk} es la proporción de clase k en el nodo m . Ambas valen 0 para nodos puros y alcanzan su máximo para distribuciones uniformes.

4.3. Criterio de División

Se elige el feature j y umbral t que minimizan la impureza ponderada de los hijos:

$$J(j, t) = \frac{N_{\text{izq}}}{N_m} I_{\text{izq}} + \frac{N_{\text{der}}}{N_m} I_{\text{der}}$$

Algoritmo CART (greedy)

- 1: **for** cada feature j y cada umbral t **do**
- 2: Calcular $J(j, t)$
- 3: **end for**
- 4: Dividir con $(j^*, t^*) = \arg \min_{j,t} J(j, t)$
- 5: Repetir recursivamente en cada hijo hasta criterio de parada

4.4. Regularización del Árbol

Hiperparámetro	Efecto	Rango típico
max_depth	Profundidad máxima	3–10
min_samples_split	Mín. muestras para dividir	2–20
min_samples_leaf	Mín. muestras por hoja	1–10
max_features	Features consideradas por split	$\sqrt{p}$, $\log_2 p$

4.5. Importancia de Features

$$\text{Imp}(j) \propto \sum_{\text{splits en } j} \frac{N_m}{N} \left(I_m - \frac{N_{\text{izq}}}{N_m} I_{\text{izq}} - \frac{N_{\text{der}}}{N_m} I_{\text{der}} \right)$$

Se pondera por la proporción de muestras que pasan por cada split y se normaliza para que sumen 1.

Sesgo de importancia: los árboles tienden a sobreestimar la importancia de features con muchas categorías o alta cardinalidad. Para corregir esto se puede usar importancia por permutación.

5. Ensamblados I: Voting y Bagging

5.1. ¿Qué es un Ensamble?

Ensamble

Combinar múltiples **modelos base** (learners) para producir una predicción más robusta que cualquier modelo individual.

5.2. Votación (Voting)

Clasificación: predicción = moda de los votos.

Regresión: predicción = promedio de las predicciones.

¿Por qué funciona? Si n clasificadores son independientes con exactitud $p > 0,5$ cada uno, la probabilidad de que la mayoría se equivoque decrece exponencialmente con

n :

$$P(\text{error del ensamble}) = \sum_{k=\lceil n/2 \rceil}^n \binom{n}{k} (1-p)^k p^{n-k}$$

5.3. Varianza, Sesgo y Diversidad

Para modelos *no correlacionados* con varianza σ^2 :

$$\text{Var}\left(\frac{1}{B} \sum_{b=1}^B \hat{f}_b\right) = \frac{\sigma^2}{B} \xrightarrow{B \rightarrow \infty} 0$$

En la práctica los modelos están correlacionados (ρ):

$$\text{Var}(\bar{f}) = \rho \sigma^2 + \frac{1-\rho}{B} \sigma^2$$

La clave es **reducir** ρ : modelos más diversos bajan más la varianza.

5.4. Bootstrap y Bagging

Bootstrap

Dado un conjunto de n muestras, seleccionar *con reemplazo* n muestras aleatoriamente. En promedio, el $\approx 63,2\%$ de las muestras originales aparece al menos una vez; el $\approx 36,8\%$ queda fuera (*Out-of-Bag*, OOB).

Bagging (Bootstrap Aggregating)

- 1: **for** $b = 1$ to B **do**
- 2: Generar muestra bootstrap $\mathcal{D}_b$ a partir de $\mathcal{D}$
- 3: Entrenar modelo $\hat{f}_b$ en $\mathcal{D}_b$
- 4: **end for**
- 5: **return** $\hat{f}(x) = \frac{1}{B} \sum_b \hat{f}_b(x)$ (o voto mayoritario)

Validación OOB: cada muestra es OOB para $\approx 37\%$ de los modelos; se puede calcular un error de validación sin usar un conjunto separado.




Figura 6: Esquema de Bagging: B modelos entrenados en paralelo sobre muestras bootstrap.

6. Ensamblados II: Random Forest e Interpretación

6.1. Random Forest

Random Forest

Bagging aplicado a árboles de decisión con una fuente adicional de aleatoriedad: en cada split solo se evalúan m features seleccionados al azar (típicamente $m = \sqrt{p}$ para clasificación, $m = p/3$ para regresión).

Efecto: reduce la correlación entre los árboles $\Rightarrow$ mayor reducción de varianza del ensemble.




Figura 7: El error estabiliza después de cierto número de árboles (retornos decrecientes).

6.2. Dependencia Parcial (PDP)

La **función de dependencia parcial** mide el efecto marginal promedio del feature x_s sobre la predicción, promediando sobre todos los demás features:

$$\hat{f}_s(x_s) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x_s, \mathbf{x}_{-s}^{(i)})$$

6.3. Individual Conditional Expectation (ICE)

Similar al PDP pero se grafica una curva por muestra (sin promediar). La media de todas las curvas ICE coincide con el PDP.




Figura 8: Las curvas ICE revelan heterogeneidad en el efecto del feature.

7. Ensamblados III: Boosting y Gradient Boosting

7.1. Filosofía del Boosting

Boosting

Construir un modelo fuerte a partir de **learners débiles** entrenados *secuencialmente*: cada modelo nuevo se concentra en los errores cometidos por el ensamble anterior.




Figura 9: Esquema de Boosting: cada learner débil aprende de los errores del anterior.

7.2. AdaBoost

AdaBoost (clasificación binaria)

- 1: Inicializar pesos: $w_i = 1/n, \forall i$
- 2: **for** $m = 1$ to M **do**
- 3: Entrenar clasificador h_m con pesos $\{w_i\}$
- 4: Calcular error ponderado: $\varepsilon_m = \sum_{h_m(x_i) \neq y_i} w_i$
- 5: Calcular peso del modelo: $\alpha_m = \frac{1}{2} \ln \frac{1 - \varepsilon_m}{\varepsilon_m}$
- 6: Actualizar pesos:

$$w_i \leftarrow w_i \cdot \exp(-\alpha_m y_i h_m(x_i))$$
- 7: Renormalizar: $w_i \leftarrow w_i / \sum_j w_j$
- 8: **end for**
- 9: **return** $H(x) = \text{sign}(\sum_m \alpha_m h_m(x))$

Intuición: si $\varepsilon_m < 0,5$ entonces $\alpha_m > 0$; muestras mal clasificadas reciben mayor peso en la siguiente iteración.

7.3. Gradient Boosting

7.3.1. Algoritmo General

Gradient Boosting (Friedman, 1999)

- 1: Inicializar: $F_0(x) = \arg \min_c \sum_i L(y_i, c)$
- 2: **for** $m = 1$ to M **do**
- 3: Calcular pseudo-residuos (gradiente negativo):

$$r_{im} = - \left. \frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right|_{F=F_{m-1}}$$
- 4: Entrenar árbol de regresión h_m sobre $\{(x_i, r_{im})\}$
- 5: Determinar paso óptimo: $\gamma_m = \arg \min_{\gamma} \sum_i L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i))$
- 6: Actualizar: $F_m(x) = F_{m-1}(x) + \eta \gamma_m h_m(x)$
- 7: **end for**
- 8: **return** $F_M(x)$

donde $\eta \in (0, 1]$ es la **tasa de aprendizaje** (shrinkage).

7.3.2. Conexión con Descenso de Gradiente

El gradient boosting es equivalente al *descenso de gradiente en el espacio funcional*: cada árbol aproxima el gradiente negativo de la pérdida respecto de la predicción actual.

Función de pérdida $L(y, F)$	Pseudo-residuo r
$\frac{1}{2}(y - F)^2$ (regresión)	$y - F$
$\log(1 + e^{-2yF})$ (clasificación)	$\frac{2y}{1 + e^{2yF}}$
$ y - F $ (MAE)	$\text{sign}(y - F)$

7.3.3. Parámetros Clave

Parámetro	Efecto	Rango típico
M (n_estimators)	Número de árboles	100–3000
η (learning_rate)	Tamaño del paso; menor = más robusto	0.01–0.3
max_depth	Complejidad de cada árbol	3–8
subsample	Fracción de filas por árbol	0.5–1.0
colsample_bytree	Fracción de columnas por árbol	0.5–1.0

Trade-off: η pequeño requiere M grande; combinados producen mayor regularización implícita y mejor generalización, a costa de tiempo de entrenamiento.

7.4. XGBoost: Objetivo Regularizado

XGBoost extiende gradient boosting con una función objetivo regularizada explícita:

$$\mathcal{L} = \underbrace{\sum_{i=1}^n L(y_i, \hat{y}_i)}_{\text{pérdida}} + \underbrace{\sum_{k=1}^K \Omega(f_k)}_{\text{regularización}}$$

donde:

$$\Omega(f_k) = \gamma T_k + \frac{\lambda}{2} \sum_{j=1}^{T_k} w_j^2$$

T_k = número de hojas, w_j = valor en la hoja j , γ y λ son hiperparámetros de regularización.

7.4.1. Expansión de Taylor de Segundo Orden

Para optimizar eficientemente el objetivo:

$$\mathcal{L}^{(m)} \approx \sum_i \left[g_i f_m(x_i) + \frac{1}{2} h_i f_m(x_i)^2 \right] + \Omega(f_m)$$

donde $g_i = \partial_{\hat{y}} L(y_i, \hat{y})$ y $h_i = \partial_{\hat{y}}^2 L(y_i, \hat{y})$.

El valor óptimo en cada hoja j es:

$$w_j^* = - \frac{\sum_{i \in j} g_i}{\sum_{i \in j} h_i + \lambda}$$

7.5. LightGBM y CatBoost

	XGBoost	LightGBM	CatBoost
Crecimiento árbol	Por nivel	Por hoja	Simétrico
Velocidad	Moderada	Alta	Alta
Memoria	Moderada	Baja	Moderada
Features categóricas	Requiere encoding	Nativo	Nativo
Regularización	Explícita	Implícita + explícita	Implícita




Figura 10: XGBoost expande el árbol nivel por nivel; LightGBM expande la hoja con mayor reducción de pérdida (más eficiente pero potencialmente más overfit).

8. Reducción de la Dimensionalidad

8.1. Motivación: La Maldición de la Dimensionalidad

En espacios de alta dimensión el volumen crece exponencialmente: los puntos se vuelven *equidistantes* y los algoritmos basados en distancia (kNN, SVM radial, etc.) pierden efectividad. Además, visualizar y comprender datos con miles de features es prácticamente imposible.

8.2. Análisis de Componentes Principales (PCA)

8.2.1. Objetivo

Encontrar una proyección lineal $\mathbf{z} = \mathbf{W}^\top \mathbf{x}$ ($\mathbf{W} \in \mathbb{R}^{p \times k}$, $k < p$) que maximice la varianza retenida, con columnas de $\mathbf{W}$ ortonormales.

8.2.2. Herramientas Estadísticas Previas

Varianza de la variable j :

$$\sigma_j^2 = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \mu_j)^2$$

Covarianza entre variables j y k :

$$\sigma_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \mu_j)(x_{ik} - \mu_k)$$

Matriz de covarianza :

$$\mathbf{M}_x = \frac{1}{n-1} \mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p} \quad (\mathbf{X} \text{ centrada})$$

$\mathbf{M}_x$ es simétrica semi-definida positiva; su diagonal contiene las varianzas y sus fuera de la diagonal las covarianzas.

8.2.3. Diagonalización y Autovectores

La descomposición espectral de $\mathbf{M}_x$:

$$\mathbf{M}_x = \mathbf{P}\mathbf{D}\mathbf{P}^\top$$

donde $\mathbf{P}$ es ortogonal (autovectores en columnas) y $\mathbf{D} = \text{diag}(\lambda_1, \dots, \lambda_p)$ con $\lambda_1 \geq \dots \geq \lambda_p \geq 0$.

Interpretación geométrica

- Cada autovector $\mathbf{v}_j$ es una **dirección** en el espacio de features.
- El autovalor λ_j es la **varianza** explicada en esa dirección.
- La primera CP ($\mathbf{v}_1$) apunta hacia la dirección de máxima varianza; la segunda es perpendicular a la primera y tiene la segunda mayor varianza; etc.




Figura 11: Las componentes principales son los ejes de la elipse de la nube de puntos. PC1 apunta a la dirección de mayor dispersión.

8.2.4. Algoritmo PCA

PCA Paso a Paso

- 1: Estandarizar cada feature: $x_{ij} \leftarrow (x_{ij} - \mu_j)/\sigma_j$
- 2: Calcular $\mathbf{M}_x = \frac{1}{n-1} \mathbf{X}^\top \mathbf{X}$
- 3: Descomponer: $\mathbf{M}_x \mathbf{v}_j = \lambda_j \mathbf{v}_j$
- 4: Ordenar autovectores por autovalor descendente
- 5: Seleccionar los primeros k autovectores: $\mathbf{P}_k \in \mathbb{R}^{p \times k}$
- 6: Proyectar datos: $\mathbf{Z} = \mathbf{X} \mathbf{P}_k \in \mathbb{R}^{n \times k}$

8.2.5. Varianza Explicada

$$\text{Varianza explicada por CP}_j = \frac{\lambda_j}{\sum_{l=1}^p \lambda_l}$$

$$\text{Varianza acumulada por primeras } k \text{ CPs} = \frac{\sum_{j=1}^k \lambda_j}{\sum_{l=1}^p \lambda_l}$$





Figura 12: Scree plot: se elige k donde la curva acumulada supera el umbral deseado (usualmente 85–95 %).

8.3. Métodos No Lineales de Reducción de Dimensionalidad

PCA asume relaciones **lineales**; cuando los datos yacen en una variedad no lineal, se necesitan métodos más flexibles.



8.3.1. t-SNE

- Convierte distancias euclídeas en probabilidades de similitud (distribución Gaussiana en alta dimensión, t-Student en baja).
- Minimiza la divergencia KL entre distribuciones de alta y baja dimensión.
- Preserva la estructura local (vecinos cercanos); puede distorsionar la global.
- **No** es apto para proyectar nuevas muestras; sólo para visualización exploratoria.

8.3.2. UMAP

- Basado en teoría de topología algebraica (variedades Riemannianas).
- Preserva estructura local **y** global mejor que t-SNE.
- Mucho más rápido que t-SNE; puede proyectar nuevas muestras.
- Útil tanto para visualización como preprocesamiento para ML.

	PCA	t-SNE	UMAP	PaCMAP
Relaciones	Lineal	No lineal	No lineal	No lineal
Estructura local	Media	Alta	Alta	Alta
Estructura global	Alta	Baja	Media	Media-Alta
Velocidad	Muy rápida	Lenta	Rápida	Rápida
Proyecta nuevas muestras	Sí	No	Sí	No
Interpretabilidad	Alta	Baja	Baja	Baja

9. Aprendizaje No Supervisado: Clustering

Clustering

Dado un conjunto de muestras *sin etiquetas*, encontrar grupos (*clusters*) tales que muestras dentro del mismo grupo sean similares entre sí y diferentes de muestras de otros grupos.

La reducción de dimensionalidad es frecuentemente un paso previo al clustering: se proyecta a 2D/3D con PCA/UMAP y se visualizan agrupamientos emergentes.

10. Resumen Comparativo de Modelos

Modelo	Sesgo	Varianza	Interpretable	No lineal
Regresión Lineal/Logística	Alto	Bajo	Muy alta	No
Árbol de decisión (profundo)	Bajo	Alto	Media	Sí
Árbol de decisión (podado)	Medio	Medio	Alta	Sí
Bagging / RF	Bajo	Bajo	Baja	Sí
Gradient Boosting	Muy bajo	Bajo	Baja	Sí

10.1. Bias-Variance Trade-off

$$\mathbb{E}[(y - \hat{f}(x))^2] = \underbrace{\left(\mathbb{E}[\hat{f}(x)] - f(x)\right)^2}_{\text{Sesgo}^2} + \underbrace{\mathbb{E}\left[\left(\hat{f}(x) - \mathbb{E}[\hat{f}(x)]\right)^2\right]}_{\text{Varianza}} + \underbrace{\sigma_\varepsilon^2}_{\text{Ruido irreducible}}$$




Figura 13: El error total tiene un mínimo en la complejidad óptima del modelo.

10.2. Cuándo Usar Cada Modelo

Modelo	Cuándo usarlo
Reg. Lineal / Logística	Cuando se requiere interpretabilidad, las relaciones son lineales o los datos son escasos.
Árbol de decisión	Para exploración rápida, cuando la interpretabilidad es crítica, o como base para ensambles.
Random Forest	Buen punto de partida robusto; menos sensible a hiperparámetros que GB.
Gradient Boosting	Cuando la performance predictiva es prioritaria; tabulares estructurados.
PCA	Preprocesamiento, visualización, eliminar correlaciones, ruido.
UMAP / t-SNE	Visualización exploratoria de datos de alta dimensión.

A. Formulario Rápido

Regresión Lineal

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Ridge

$$\min_{\mathbf{w}} J(\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2$$

Logistic

$$\hat{p} = \sigma(\beta^\top \mathbf{x}) = \frac{1}{1 + e^{-\beta^\top \mathbf{x}}}$$

Gini

$$\text{Gini}_m = 1 - \sum_k p_{mk}^2$$

Lasso

$$\min_{\mathbf{w}} J(\mathbf{w}) + \lambda \|\mathbf{w}\|_1$$

Entropía

$$H_m = - \sum_k p_{mk} \log_2 p_{mk}$$

AdaBoost peso modelo

$$\alpha_m = \frac{1}{2} \ln \frac{1 - \varepsilon_m}{\varepsilon_m}$$

Gradient Boosting

$$r_{im} = -\frac{\partial L(y_i, F_{m-1}(x_i))}{\partial F_{m-1}(x_i)}$$

PCA proyección

$$\mathbf{Z} = \mathbf{X} \mathbf{P}_k$$

Varianza PCA

$$\text{VE}_j = \frac{\lambda_j}{\sum_l \lambda_l}$$

Bias-Variance

$$\mathbb{E}[(y - \hat{f})^2] = \text{Sesgo}^2 + \text{Var} + \sigma^2$$

OOB estimate

Cada muestra es OOB para $\approx e^{-1} \approx 36,8\%$ de árboles.