

Guía Práctica N° 1

Introducción y Camino de Machine Learning

Introducción

1. Defina brevemente qué se entiende por Inteligencia Artificial y explique en qué consiste la prueba clásica propuesta por Alan Turing. ¿A qué se denomina problema de alineación de valores en el marco del modelo del agente racional?
2. A lo largo de la historia se han propuesto diversas definiciones para el Aprendizaje Automático. Contraste la definición clásica de 1959 orientada a la programación explícita con la definición más matemática de 1997. Especifique qué representan la experiencia E , la tarea T y la medida de rendimiento P en algún problema concreto.
3. Los problemas que podemos resolver con modelos de datos se pueden categorizar en Descriptivos, Predictivos y Prescriptivos. Explique qué pregunta fundamental intenta responder cada uno de estos enfoques y clasifique el problema de predicción de abandono de clientes dentro de esta jerarquía.
4. El Machine Learning suele dividirse en tres grandes ramas: Aprendizaje Supervisado, Aprendizaje No Supervisado y Aprendizaje por Refuerzo. Defina cada una de ellas destacando la principal diferencia en cuanto a la presencia o ausencia de etiquetas objetivo en los datos de entrenamiento.
5. Dentro del Aprendizaje Supervisado, ¿cuál es la diferencia conceptual fundamental entre un problema de Regresión y un problema de Clasificación en términos del tipo de salida que arroja la función matemática buscada?

Preprocesamiento de Datos

6. Un dataset de registros médicos presenta un 15 % de valores nulos en la columna "Presión Arterial". Un analista propone eliminar todas las filas que contengan datos faltantes, mientras que otro propone realizar una imputación simple utilizando la media de la columna.
 - a) ¿Cuáles son las ventajas y desventajas de ambos enfoques?
 - b) ¿Qué sesgo peligroso podría introducir en este caso una imputación por la media o mediana?
7. Considere un dataset con dos variables predictoras numéricas: *Edad* (medida en años) y *Sueldo Anual* (medido en pesos).
 - a) Si se utiliza un modelo de Machine Learning que realiza operaciones basadas en el valor absoluto de los features o medidas de distancia, ¿qué problema surgirá si el modelo entrena con los datos originales sin escalar?
 - b) Explique brevemente la diferencia conceptual entre aplicar un *Min-Max Scaling* y un *Standard Scaling*.
8. Para predecir el precio de un automóvil, se cuenta con una variable categórica *Color* con los valores: Rojo, Verde y Azul. Un integrante del equipo decide transformar esta variable utilizando *Label Encoding*, asignando Rojo=0, Verde=1, Azul=2.



- a) Dado que muchos modelos de Machine Learning no pueden manejar variables categóricas directamente, ¿por qué esta estrategia de codificación particular podría ser perjudicial para un modelo lineal?
 - b) Explique cómo la técnica de *One Hot Encoding* resuelve este problema.
9. Durante la etapa de *Feature Selection*, el objetivo es descartar columnas que proveen poca información predictiva.
- a) Compare conceptualmente la aproximación de los *Filter Methods* (por ejemplo, descartar columnas por baja varianza) con la de los *Wrapper Methods* (por ejemplo, *Forward Selection*).
 - b) ¿Qué desventaja computacional grave presenta el método de *Best Subset Selection* frente a las otras alternativas?
10. En un problema de clasificación para la detección de enfermedades raras, las clases se encuentran altamente desbalanceadas. Si entrenamos un clasificador estándar, es probable que asuma que todos los pacientes pertenecen a la clase mayoritaria (sanos). Mencione y explique brevemente en qué consisten las estrategias de preprocesamiento de filas de *oversampling* y *undersampling* para mitigar este efecto.
11. Un equipo de Data Science se encuentra trabajando en un problema de regresión. Como primer paso del código, escalan todo el dataset completo utilizando un **StandardScaler**. Luego, dividen los datos aleatoriamente reservando un 80 % para el conjunto de *Train* y un 20 % para el conjunto de *Test*, y finalmente proceden a entrenar el modelo.
- a) ¿Qué error conceptual fundamental cometió el equipo al armar este pipeline de datos?
 - b) Defina brevemente el concepto de *Data Leakage* e indique cuál sería la secuencia correcta de pasos para evitarlo en este caso.

Model Selection

12. Explique los conceptos de *Overfitting* y *Underfitting* en el contexto del entrenamiento de un modelo de Machine Learning. ¿Cómo se observan típicamente estos fenómenos al analizar las curvas de error de entrenamiento (*Training Error*) frente al error de generalización (*Test Error*) a medida que aumenta la complejidad del modelo?
13. Al entrenar un modelo de forma robusta, el conjunto de datos suele dividirse en *Training Set*, *Validation Set* y *Test Set*. Defina el propósito fundamental de cada uno de estos conjuntos y explique por qué resulta riesgoso o insuficiente utilizar únicamente un *Simple Holdout Set* (es decir, solo partición de Train y Test).
14. Describa el funcionamiento de la técnica *K-fold Cross-Validation*. ¿Qué ventajas presenta esta estrategia frente a una simple partición de *Validation Holdout Set* en términos de la utilización de los datos disponibles y la reducción del azar en la partición?
15. La técnica *Leave-one-out Cross-Validation* (LOOCV) es un caso extremo de validación cruzada. Mencione su principal ventaja en cuanto al uso de las muestras y su mayor desventaja práctica, la cual suele limitar su uso en problemas con datasets modernos o de gran volumen.
16. En ciertas situaciones, las particiones aleatorias estándar pueden introducir *Data Leakage* o alterar la naturaleza del problema. Indique en qué escenarios sería estrictamente necesario recurrir a estrategias específicas como *Stratified K-fold*, *Time Series Split* o *Leave One Group Out*.



Métricas

17. **Precision** se define como:

$$\text{Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$$

Recall se define como:

$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

Se tiene un problema de clasificación binaria en donde se debe diferenciar a pacientes con grandes chances de desarrollar una enfermedad y pacientes que tienen nula o muy bajas chances de padecer el problema. Si lo que más interesa es que no *se pase* ningún paciente con mala predisposición, ¿qué métrica será más útil y cómo se debe definir las clases negativa y positiva?. Con esas definiciones, ¿qué significa una precision alta o baja? ¿qué significa un recall alto o bajo?

18. En problemas de clasificación binaria, se evalúa el rendimiento de un modelo utilizando una matriz de confusión, de la cual se derivan varias métricas. Para una clase designada como *positiva* se define:

- Verdaderos Positivos (TP): Casos positivos correctamente identificados.
- Falsos Positivos (FP): Casos negativos incorrectamente identificados como positivos.
- Verdaderos Negativos (TN): Casos negativos correctamente identificados.
- Falsos Negativos (FN): Casos positivos incorrectamente identificados como negativos.

A partir de estos, se definen las siguientes métricas:

- Precision:

$$\text{Precision} = \frac{TP}{TP + FP}$$

- Recall:

$$\text{Recall} = \frac{TP}{TP + FN}$$

- Tasa de Verdaderos Positivos:

$$\text{TPR} = \frac{TP}{TP + FN}$$

- Tasa de Falsos Positivos:

$$\text{FPR} = \frac{FP}{FP + TN}$$

Con estas métricas, la curva ROC grafica en el Y la métrica TPR y en el eje x la métrica FPR. Por otro lado, la curva precision-recall grafica la métrica precision en el eje Y y la métrica recall en el eje X.

Es conocido que en un problema muy desbalanceado en donde se tienen muy pocos representantes de la clase positiva la curva precision-recall suele ser más útil que la curva ROC, dado que es muy simple para los modelos obtener una buena curva ROC sin tener un gran rendimiento sobre la clase positiva. ¿Por qué pasa esto? Explique brevemente por qué en el caso planteado una curva puede resultar más útil que la otra.



19. Considere las siguientes dos métricas de evaluación para problemas de regresión:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$RMSLE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(y_i + 1) - \log(\hat{y}_i + 1))^2}$$

¿Qué está priorizando cada métrica? De un ejemplo de uso concreto en donde en un conjunto de muestras algunas sean más priorizadas que otras según cuál de las dos métricas se utiliza.

20. El Mean Absolute Error (MAE) se define como:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

El Mean Absolute Percentage Error (MAPE) se define como:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100$$

¿Qué está priorizando cada métrica? ¿En qué contextos elegiría una por sobre la otra?

21. La métrica **Accuracy** (Exactitud) se define como la proporción de predicciones correctas sobre el total de casos:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

El **F1-Score** se define como la media armónica entre Precision y Recall:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall} + \epsilon}$$

Considere un dataset muy desbalanceado para detección de fraude bancario, compuesto por 99.000 transacciones legítimas (clase negativa) y 1.000 transacciones fraudulentas (clase positiva).

- a) Si un modelo ingenuo (*dummy model*) predice que **todas** las transacciones son legítimas, ¿cuál será su Accuracy? Calcule también la Precision y el Recall para la clase positiva.
 - b) A la luz del resultado anterior, explique por qué el Accuracy puede ser una métrica engañosa.
 - c) ¿Por qué el F1-Score utiliza la media armónica en lugar de una simple media aritmética ($\frac{\text{Precision} + \text{Recall}}{2}$)? Dé un ejemplo numérico extremo donde la media aritmética daría una falsa sensación de buen rendimiento.
22. Cuando se pasa de problemas de clasificación binaria a problemas *multiclase*, se necesita adaptar nuestras métricas. Dos enfoques muy comunes para extender Precision, Recall y F1-Score son el *Micro-averaging* y el *Macro-averaging*.



- *Macro-averaging*: Calcula la métrica (por ejemplo, Precision) de forma independiente para cada clase y luego calcula el promedio no ponderado de todas las clases.
- *Micro-averaging*: Suma los Verdaderos Positivos, Falsos Positivos y Falsos Negativos de todas las clases globalmente, y luego calcula la métrica a partir de esos totales.

Suponga que tiene un problema de clasificación de ropa con tres clases: *Remeras* (80 % del dataset), *Pantalones* (15 % del dataset) y *Camperas* (5 % del dataset).

- a) ¿Qué enfoque (Micro o Macro) prioriza el rendimiento del modelo sobre las clases minoritarias (*Pantalones* y *Camperas*)? Justifique su respuesta.
- b) ¿En qué caso particular el Micro-F1, Micro-Precision, Micro-Recall y el Accuracy global del modelo darán exactamente el mismo valor numérico?