

Guía Práctica N° 2

Modelos Lineales, Árboles de Decisión y Ensamblados

Modelos Lineales

1. En el contexto de una Regresión Lineal para predecir una variable continua, la ecuación subyacente se define como $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$. Identifique conceptualmente qué representa cada uno de los componentes de esta ecuación. Además, mencione cuál es la métrica de evaluación que se busca minimizar por defecto al entrenar este modelo.
2. ¿Se puede utilizar el método de gradiente descendiente para resolver un modelo de Regresión Lineal?
3. A pesar de utilizar una función no lineal (como la sigmoidea) para acotar las salidas probabilísticas entre 0 y 1, a la Regresión Logística se la clasifica dentro de la familia de los modelos lineales. ¿Por qué esto es así?
4. En un problema de clasificación binaria mediante Regresión Logística, existe una barrera que separa el espacio de pertenencia entre ambas clases (*Decision Boundary*). Si para una muestra particular el resultado numérico de la combinación lineal de las *features* da exactamente 0, ¿qué probabilidad se le está asignando a dicha muestra y de qué lado de la frontera de decisión se encuentra?
5. ¿Por qué la métrica de optimización de una Regresión Logística es diferente a la métrica de evaluación?. Al no ser las mismas, ¿Qué quiere decir que ambas métricas sean coherentes al perseguir el mismo objetivo? Muestre mediante un ejemplo numérico concreto cómo se comportan en conjunto estas métricas.
6. Suponga que tiene un problema de clasificación en dos dimensiones (X_1 y X_2) donde la clase positiva se encuentra concentrada en el centro del plano formando un círculo, y la clase negativa forma un anillo alrededor de ella. ¿Puede una Regresión Logística estándar separar estas clases de manera efectiva?. Si la respuesta es afirmativa, ¿cómo?. Si la respuesta es negativa, ¿existe alguna adaptación posible para que sea capaz?

Árboles de Decisión

7. Contraste la forma en que un Modelo Lineal separa el espacio de características en un problema de clasificación frente a cómo lo hace un Árbol de Decisión. ¿Qué característica geométrica distintiva tienen las fronteras generadas por un árbol estándar?
8. Los Árboles de Decisión pueden, mediante adaptaciones simples al algoritmo básico, manejar datasets con datos faltantes o variables categóricas. Mencione cuales serían estas adaptaciones en cada caso.
9. En la visualización gráfica de un Árbol de Decisión entrenado (por ejemplo, utilizando `plot_tree` de Scikit-Learn), cada nodo muestra una métrica de "pureza", habitualmente el índice `gini`. Explique intuitivamente qué significa que el valor de `gini` llegue a 0,0 en una hoja particular del árbol.
10. Desarrolle y justifique un ejemplo numérico concreto en el que se visualice cómo la métrica de misclassification error resulta inadecuada para conseguir un progreso al entrenar el árbol de decisión. ¿Qué pasa con la métrica Gini en ese caso?

11. Aunque los Árboles de Decisión simples son altamente interpretables porque replican la lógica humana de toma de decisiones, presentan problemas importantes de robustez. Describa qué sucede con la estructura topológica de un árbol si se altera o se elimina un pequeño porcentaje de las muestras del dataset de entrenamiento.
12. Considere un modelo de Árbol de Regresión que fue entrenado con una variable predictora X cuyos valores oscilan exclusivamente entre 0 y 50. Si al modelo puesto en producción le llega una nueva observación con un valor de $X = 75$, ¿qué valor tenderá a predecir?
13. Compare la explicabilidad de un modelo de Regresión Logística frente a la de un Árbol de Decisión de poca profundidad. Si tuviera que justificarle a un cliente no técnico exactamente por qué se le denegó un préstamo bancario, ¿cuál de los dos modelos resultaría más transparente y fácil de comunicar?

Ensamblados

14. Para un problema de clasificación binaria tenemos 3 modelos entrenados. Cada uno de estos modelos presenta una accuracy de 0.8. Si armamos un ensamble de Majority Voting a partir de estos 3 modelos, ¿cuál será la accuracy del ensamble resultante?
15. ¿Por qué en modelos basados en árboles como Random Forest usamos la métrica de Rank Correlation para saber cuándo dos columnas son *parecidas* entre sí en vez de utilizar otra métrica como el coeficiente de correlación de Pearson?
16. ¿Cuáles métodos de ensambles son trivialmente paralelizables y cuáles no?
17. ¿Qué métodos de interpretabilidad existen sobre el modelo de Random Forest? ¿Cómo se calcula para este modelo el Feature Importance?
18. ¿Por qué la cantidad de árboles es un parámetro de overfitting en el caso de un modelo de boosting como XGBoost, pero no lo es en un modelo como Random Forest?
19. ¿Por qué existen diferentes implementaciones del modelo de Gradient Boosting (XGBoost, CatBoost, LightGBM, etc)? ¿Qué aporta cada implementación?
20. Actualmente los ensambles son los modelos con mejor desempeño (en general) en problemas de Machine Learning tabular. ¿Podemos utilizarlos en datos no tabulares como imágenes, audio o texto? Si la respuesta es afirmativa, ¿Por qué no se utilizan en la práctica?. Si la respuesta es negativa, ¿Por qué?

Casos integrales

21. Se tiene un dataset tabular que contiene información demográfica y transaccional de los clientes de un servicio de películas y series basado en suscripción. El objetivo es construir un modelo de predicción de churn (abandono) para identificar a los clientes que tienen más probabilidades de cancelar su suscripción. El conjunto de datos presenta valores faltantes, clases desbalanceadas con un mayor número de clientes que no cancelan su suscripción, y una combinación de características numéricas y categóricas. Describa los pasos que haría, considerando estos desafíos específicos, para construir un modelo efectivo de predicción de churn.

Describa toda parte del camino de Machine Learning que considere necesario. Como guía, se pueden utilizar las siguientes preguntas, sin tener que limitarse a ellas:

- ¿Es un problema de regresión o de clasificación? ¿Qué se considera como churn?



- ¿Qué debemos hacer con los features para poder utilizar el modelo elegido? Más allá de lo que debemos hacer, ¿Qué otros preprocesamientos podemos hacer? ¿Qué otros datasets podemos sumar para tener mayor poder predictivo?
- ¿Qué modelos de Machine Learning vamos a utilizar?
- ¿Qué cuestiones se deben tener en consideración para utilizar nuestro desarrollo en un ambiente real?

22. Una fintech emergente llamada CréditoRápido nos contrató para auditar su sistema de scoring crediticio. El objetivo del sistema es decidir automáticamente si se le otorga o no un microcrédito a un usuario basándose en su probabilidad de *default* (impago).

El equipo de Data Science anterior dejó implementada una solución antes de renunciar. Contamos con la siguiente información sobre el desarrollo actual:

Se cuenta con un histórico de 100,000 préstamos otorgados. De estos, solo 3,500 resultaron en impago (default), mientras que el resto fueron pagados a término. Las variables incluyen historial de navegación en la app y modelo del celular.

Debido a la complejidad del problema y la necesidad de mostrar buenos resultados al CEO, el equipo decidió entrenar una Red Neuronal Profunda con 5 capas ocultas utilizando PyTorch. El reporte final del modelo muestra las siguientes métricas en el conjunto de test:

- Accuracy : 96.5
- Loss Function: Binary Cross Entropy

A pesar de la métrica reportada, el CFO no está nada contento. La empresa está perdiendo plata porque se otorgan muchos créditos que no se pagan. Además, el área legal ha recibido denuncias de usuarios rechazados exigiendo saber el motivo exacto del rechazo, y el equipo de tecnología responde que la red neuronal es una caja negra y no permite saber qué variable causó la decisión.

Mencionar y justificar todos los aspectos a mejorar que tiene la solución actual. ¿Cómo se podría mejorar cada uno de estos aspectos? ¿Qué otros aspectos importantes fueron omitidos y sería importante tenerlos en cuenta? ¿Cómo se pueden tener en cuenta?

23. En los últimos años se han popularizado soluciones de machine learning para predecir la necesidad de mantenimiento en diferentes maquinarias. El objetivo de este problema es lograr detectar que una maquinaria particular necesita diversos ajustes antes de que suceda una rotura mayor. Como parte de nuestro trabajo para la planta productora que tenemos a cargo, contamos con diversos datos sobre las máquinas: sensores para detectar vibraciones, sonidos emitidos, energía eléctrica consumida, temperaturas, etc. Adicionalmente contamos con otros datos de fabricación de las máquinas y también contamos con reportes históricos de problemas y diversas roturas. El objetivo es desarrollar un modelo que nos indique cuándo una máquina está necesitando un tratamiento preventivo. Describa todos los pasos que haría para conseguir una solución al problema.

Describa toda parte del camino de Machine Learning que considere necesario. Como guía, se pueden utilizar las siguientes preguntas, sin tener que limitarse a ellas:

- ¿En qué categoría de Machine Learning cae este problema?
- ¿Es un problema de regresión o de clasificación?
- ¿Qué debemos hacer con los features para poder utilizar el modelo elegido? Más allá de lo que debemos hacer, ¿Qué otros preprocesamientos podemos hacer? ¿Qué otros datasets podemos sumar para tener mayor poder predictivo?



- ¿Hay algún problema con el balance de los datos? ¿Es necesario hacer algo al respecto?
- ¿Qué modelos de Machine Learning vamos a utilizar?
- ¿Qué métricas van a resultar de mayor interés en este problema?
- ¿Nos interesa la interpretabilidad o *solamente* queremos predecir?
- ¿Qué cuestiones se deben tener en consideración para utilizar nuestro desarrollo en un ambiente real?