

Guía Práctica N° 3

Aprendizaje No Supervisado

Reducción de la dimensionalidad

1. Explique la diferencia fundamental entre el aprendizaje supervisado y el no supervisado. ¿Por qué la evaluación del éxito en el aprendizaje no supervisado suele ser mucho más subjetiva?
2. En el contexto del Análisis de Componentes Principales (PCA), ¿cuáles son los objetivos principales que se buscan al crear las nuevas componentes?
3. Describa brevemente los pasos numéricos necesarios para aplicar PCA a un dataset original de n filas y m columnas.
4. ¿Por qué es útil diagonalizar la matriz de covarianzas en PCA?
5. Al utilizar PCA como paso previo a un modelo supervisado (como KNN), ¿qué ventajas se pueden obtener respecto a la inferencia? En contrapartida, ¿por qué puede degradarse la métrica al aplicar PCA antes de entrenar un Random Forest?
6. ¿Cuál es la limitación matemática fundamental de PCA al intentar encontrar patrones en los datos? Mencione al menos dos métodos alternativos diseñados para superar esta limitación al capturar estructuras no lineales.
7. ¿Cómo se interpretan las nuevas features conseguidas por PCA? ¿Cómo afectan estas nuevas features a los diferentes métodos de interpretabilidad de modelos conocidos?

Clusterización

8. Defina los dos principios básicos de similitud y disimilitud que cualquier algoritmo de clustering busca cumplir al agrupar muestras de un dataset.
9. El algoritmo de K-Means busca minimizar la variación dentro de un cluster (within-cluster variation). Explique conceptualmente los pasos de este algoritmo iterativo y cómo utiliza los centroides para reasignar las observaciones.
10. K-Means es sensible a los valores iniciales de los centroides. ¿Qué consecuencias prácticas tiene esto sobre los resultados del algoritmo y qué estrategias se pueden utilizar para contrarrestar el problema?
11. Dado que en K-Means la cantidad de clusters (K) es un parámetro de entrada, explique de qué manera el “Método del Codo” ayuda a elegir un valor numérico adecuado cuando no se tiene información del dominio.
12. Describa la principal diferencia metodológica entre los enfoques de partición (como K-Means) y el clustering jerárquico aglomerativo. ¿Qué representa visualmente la altura de las uniones en un dendrograma en este último método?
13. En el clustering jerárquico aglomerativo, medir la distancia entre grupos de puntos requiere definir un Linkage. Explique la diferencia operativa fundamental entre utilizar un Complete Linkage y un Single Linkage.



14. Además de Partitioning y Hierarchical, existen otras familias de algoritmos como los Density-based. Indique brevemente cuál es una de las ventajas principales del algoritmo DBSCAN frente a K-Means en relación con la forma de los clusters geométricos que puede encontrar.