

Guía Práctica N° 5

Procesamiento de Imágenes y Redes Convolucionales

Fundamentos de Redes Convolucionales (CNNs)

1. A diferencia de los modelos clásicos sobre datos tabulares, ¿por qué las redes neuronales densas (*Fully Connected*) presentan limitaciones al procesar imágenes naturales, y cómo el uso de convoluciones ayuda a aprovechar la localización espacial de los píxeles?
2. Explique conceptualmente qué son los parámetros de *Padding* y *Stride* en una capa convolucional. Si tenemos una imagen de entrada de 28×28 , aplicamos un kernel de 3×3 con *Padding* $P = 1$ y un *Stride* $S = 2$, ¿cuál será el tamaño espacial del mapa de características (*feature map*) de salida según la fórmula general $O = \frac{I-K+2P}{S} + 1$?
3. Considere una imagen de entrada de 32×32 píxeles a color. Suponga que deseamos procesar esta imagen inicial para extraer características utilizando dos arquitecturas diferentes. Calcule la cantidad total de parámetros entrenables en los siguientes dos escenarios:
 - Escenario A (MLP): Se vectoriza la imagen (*flatten*) y se procesa mediante una capa densa (*Fully Connected*) de 128 neuronas, seguida de una función de activación ReLU, y finalmente una segunda capa densa de 10 neuronas de salida.
 - Escenario B (CNN): Se procesa la imagen mediante una capa convolucional de 10 filtros de 5×5 sin padding y con stride 1, seguida de una activación ReLU. Luego se aplica una capa de *Max Pooling* espacial de 2×2 y, finalmente, una segunda capa convolucional de 20 filtros de 3×3 sin padding y stride 1.
4. Las capas de *Pooling* (como *Max Pooling*) se combinan frecuentemente en los bloques convolucionales. Explique su propósito al resumir la información reduciendo la dimensionalidad y otorgando robustez ante posibles traslaciones del objeto.

Arquitecturas Famosas y Transfer Learning

5. El modelo AlexNet fue un hito en la visión por computadora. ¿Cuáles fueron los aportes clave que hizo para diferenciarse de soluciones anteriores?
6. El salto hacia arquitecturas muy profundas se vio obstaculizado durante un tiempo debido al problema de la desaparición de los gradientes (*Vanishing Gradients*). Explique cómo la arquitectura ResNet soluciona este inconveniente introduciendo bloques residuales que suman la identidad (*skip connections*) antes de la función de activación.
7. Para problemas prácticos, rara vez se cuenta con millones de imágenes para entrenar desde cero. Describa en qué consiste la técnica de *Transfer Learning* y justifique por qué se puede mantener congelada la estructura convolucional (que extrae características ricas de la imagen) y únicamente reemplazar y entrenar la última capa densa final.

Detección de Objetos y Segmentación (I2I)

8. El problema de Detección de Objetos (*Object Detection*) exige clasificar objetos y además ubicarlos con cajas delimitadoras (*bounding boxes*). Contraste brevemente los enfoques de propuestas de regiones (como R-CNN) con la filosofía de una sola pasada (*You Only Look Once* - YOLO).

9. En la arquitectura de YOLO (v1), se realizan predicciones por cada caja que incluyen coordenadas x, y, alto, ancho y un nivel de confianza (*confidence*). Explique cuál es el output de la red y cuántos valores arroja. Explique en qué consiste el procedimiento de *Non-Max Suppression* utilizado en la salida para descartar aquellas detecciones redundantes.
10. La segmentación semántica es un problema donde la red busca clasificar la imagen píxel a píxel. ¿Por qué se suele utilizar una pérdida basada en el coeficiente Dice ($Dice = \frac{2 \times |X \cap Y|}{|X| + |Y|}$) para lidiar con el área de superposición, en lugar de utilizar una función clásica de entropía cruzada?

Interpretabilidad y Manipulación

11. Para interpretar las decisiones de una red, la técnica Grad-CAM rastrea la información observando cómo fluyen los gradientes en la última capa convolucional. Indique qué mejora aporta esto frente a simplemente aplicar mapas de saliencia (*Saliency Maps*) calculando derivadas píxel a píxel.
12. Analizar la red en función de la derivada respecto a los píxeles es lo que habilita generar ataques adversarios. Describa cómo, modificando mínimamente los píxeles de una foto mediante el cálculo del gradiente, se logra que la red equivoque su predicción por completo (por ejemplo, clasificando una pelota de tenis como un koala).
13. La transferencia de estilo permite recombinar el contenido de una imagen con el estilo artístico de otra. Explique matemáticamente cómo se logra este proceso mediante la optimización iterativa de una imagen intermedia y detalle las diferencias entre la pérdida de contenido (*Content Loss*) y la pérdida de estilo (*Style Loss*, basada en matrices de Gram).