

Guía de Ejercicios 3

Tecnología Digital VI

Juan Ignacio Elosegui

Universidad Torcuato Di Tella
Abril 2026

Reducción de la dimensionalidad

Ejercicio 1

- En supervisado se tiene (X, y) , donde X es el dataset con atributos e y es el valor objetivo. En no supervisado se tiene únicamente (X) , no hay variable objetivo.
- En supervisado se busca aprender una función que cumpla $f(X) \approx y$ para poder hacer predicciones, mientras que en no supervisado se busca aprender estructuras en los datos únicamente mirando X .
- En supervisado se tienen varias métricas a mirar dado que se puede comparar con la variable objetivo. Esto es imposible en no supervisado: no hay “ground truth” para medir el error y las estructuras encontradas pueden ser buenas o malas dependiendo del dominio del problema, por eso se dice que es subjetiva.

Ejercicio 2

PCA tiene dos objetivos:

1. **Maximizar la varianza explicada.** Cada componente principal es la dirección en el espacio de features que maximiza la varianza de los datos proyectados. La primera componente captura la mayor varianza posible, la segunda la mayor varianza restante, y así sucesivamente ...
2. **Ortogonalidad entre sus componentes.** Las componentes principales son ortogonales entre sí, lo que implica que están descorrelacionadas. Esto es importante porque (1) elimina la redundancia entre sus variables originales, (2) cada nueva componente aporta información "nuevarespecto a las anteriores, y (3) permite que diagonalizar la matriz de covarianzas tenga sentido.

Ejercicio 3

Los pasos a seguir son:

1. **Centrar los datos.** Restar a cada variable su media, para que cada una tenga media cero.
2. **Calcular la matriz de covarianzas.** $\Sigma = \frac{1}{n-1} X^T X \in \mathbb{R}^{m \times m}$. En la diagonal están las varianzas de cada variable — fuera de la diagonal, las covarianzas entre pares de variables.

3. **Diagonalizar la descomposición espectral.** $\Sigma = V\Lambda V^T$, donde $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$ contiene los autovalores y las columnas de V son los autovectores.
4. **Ordenar autovalores y autovectores de mayor a menor.** Cada autovector es una componente principal. El autovalor asociado representa la varianza que los datos tienen a lo largo de esa dirección.
5. **Elegir las primeras k componentes.** Se elige $k \leq m$ según algún criterio: porcentaje de varianza acumulada $\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^m \lambda_i}$ (ej. 80 %), método del codo en el scree plot, o k fijo por requerimientos del problema.
6. **Proyectar los datos al nuevo espacio.** $Z = XV_k \in \mathbb{R}^{n \times k}$, donde V_k contiene las primeras k columnas de V .

Ejercicio 4

Las nuevas variables que PCA busca son precisamente aquellas que hacen que la matriz de covarianzas sea diagonal en la nueva base. Diagonalizar no es una técnica que “se usa para” hacer PCA — es hacer PCA.

Ejercicio 5

KNN se basa en calcular distancias entre el punto a predecir y los puntos del training set. Aplicar PCA antes tiene varias ventajas, todas relacionadas con la predicción: (1) velocidad de predicción, (2) mitigación de la “maldición de la dimensionalidad”, (3) reducción de ruido, y (4) menor uso de memoria.

PCA con Random Forest puede empeorar la métrica: (1) Random Forest no sufre la maldición de la dimensionalidad de la misma manera, (2) PCA destruye la alineación con los ejes originales, porque las nuevas variables son combinaciones lineales de las originales; (3) PCA maximiza varianza, no poder de inferencia; y (4) se pierde la interpretabilidad que nos ofrecía Random Forest.

Ejercicio 6

La limitación matemática fundamental de PCA es que es un método lineal: sólo puede encontrar combinaciones lineales de las variables originales. Si la estructura subyacente en los datos es no lineal, PCA no puede capturarla correctamente, ya que proyecta los datos sobre un subespacio lineal.

Dos métodos alternativos diseñados para superar esta limitación son:

1. **Kernel PCA.**
2. **t-SNE / UMAP.**

Ejercicio 7

Cada nueva variable producida por PCA es una combinación lineal de todas las variables originales — no corresponde a ninguna variable original individual sino a una dirección abstracta en el espacio de features. Esto impacta directamente en los métodos de interpretabilidad:

- **Importancia de features (Random Forest, Linear Models).** Pierde su significado original: la importancia de una componente principal no se puede atribuir a ninguna variable concreta, ya que cada componente mezcla a todas.
- **Coeficientes en modelos lineales.** Los coeficientes quedan en el espacio de componentes. Para interpretarlos en el espacio original habría que retrotransformar con V_k , lo que añade una capa de indirección que dificulta la lectura directa.
- **SHAP values.** Se pueden calcular sobre las componentes, pero los valores resultantes explican contribuciones de combinaciones lineales, no de variables reales, perdiendo la interpretabilidad semántica.
- **Árboles de decisión.** Los splits se hacen sobre componentes principales, que son direcciones abstractas en el espacio original. El árbol sigue siendo válido como modelo, pero cada nodo ya no dice “si el ingreso es mayor a X ” sino “si la combinación lineal de todas las variables es mayor a X ”.

En general, PCA cede interpretabilidad a cambio de reducción de dimensionalidad. Es una decisión de diseño: si la interpretabilidad es crítica, conviene evitarlo o aplicarlo sólo como paso intermedio sin exponer las componentes al usuario final.

Clusterización

Ejercicio 8

Se busca que las muestras dentro de un cluster A sean similares entre sí, mientras que las muestras de dos clusters A y B deben ser disímiles.

Ejercicio 9

1. Se eligen K centroides iniciales. La forma más simple es seleccionar K observaciones al azar del dataset como centroides iniciales.
2. Cada observación se asigna al centroide más cercano (distancia euclídea). Así se forman K clusters.
3. Se recalcula el centroide de cada cluster como la media de todas las observaciones asignadas a él. De ahí el nombre “K-Means”.
4. Se repiten los pasos 2 y 3 hasta que las asignaciones no cambien — lo que equivale a que la within-cluster variation ya no mejora.

Ejercicio 10

Si se inicializan mal los centroides iniciales: (1) el algoritmo puede converger a un mínimo local — no global — de la within-cluster variation, o (2) correr el algoritmo varias veces puede dar clusters distintos cada vez, porque no es determinístico.

Para *solventar* estas complicaciones se puede correr el algoritmo varias veces con inicializaciones distintas, y quedarse con el resultado que haya dado la menor within-cluster variation; o bien se puede implementar K-Means++.

Ejercicio 11

Mirando el scree plot, se debe elegir el K en el cual se forme un “codo”. De ahí en más, la suma de los cuadrados intra-cluster (*within-cluster sum of squares* — WSS) decrece cada vez menos.

Ejercicio 12

- K-Means toma como parámetro cuántos *clusters* K se quieren tener. En clustering jerárquico algomerativo esto no es así.
- K-Means agrupa como puede todas las observaciones en esos K *clusters*. En clustering jerárquico aglomerativo cada muestra es su propio *cluster* y, basándose en algún tipo de *linkage*, fusiona los *clusters* (muestras) más similares de manera iterativa hasta formar un único gran *cluster*.

La altura a la que se produce una unión representa la distancia (o disimilitud) entre los dos *clusters* que se fusionan en ese paso, según el criterio de *linkage* elegido. Si la fusión entre dos *clusters* es abajo en el dendrograma, entonces eran muy similares; si la fusión es alta en el dendrograma, eran muy distintos.