

Universidad Torcuato Di Tella

Tecnología Digital VI — Parcial Modelo 2

1er Semestre 2026

Instrucciones: El parcial tiene una duración de **90 minutos**. Está prohibido el uso de computadoras o código. Sí se permite el uso de una hoja de fórmulas. Cada sección indica el puntaje. Puntaje total: **100 puntos**.

Nombre y apellido: _____

Legajo: _____

Sección 1: Verdadero o Falso [24 pts]

Indique **V** (Verdadero) o **F** (Falso) para cada afirmación. Si la afirmación es falsa, **justifique brevemente** por qué (sin justificación no se otorga puntaje en los falsos).

1. ____ En Random Forest, cada árbol se entrena con todas las features disponibles en cada split, lo cual garantiza la diversidad del ensamble.

Justificación (si es F): _____

2. ____ En Gradient Boosting, aumentar el número de árboles (M) puede llevar a overfitting, a diferencia de Random Forest donde agregar más árboles siempre es seguro.

Justificación (si es F): _____

3. ____ Una de las ventajas de la regularización L2 (Ridge) frente a L1 (Lasso) es que en presencia de variables correlacionadas, Ridge distribuye el peso entre ellas en lugar de seleccionar una sola.

Justificación (si es F): _____

4. ____ El *Partial Dependence Plot* (PDP) muestra el efecto marginal de un feature sobre la predicción del modelo, promediado sobre todos los valores de los demás features.

Justificación (si es F): _____

5. ____ El bootstrap consiste en muestrear **sin** reemplazo del dataset original, garantizando que cada muestra aparezca en exactamente un subconjunto de entrenamiento.

Justificación (si es F): _____

6. ____ PCA (Análisis de Componentes Principales) es un método adecuado para capturar estructuras no lineales en los datos, como clústeres en forma de espiral o círculo.

Justificación (si es F): _____

7. ____ En AdaBoost, los clasificadores débiles que tienen un error ponderado mayor reciben un peso α_m más grande en la predicción final del ensemble.

Justificación (si es F): _____

8. ____ El *bias-variance tradeoff* establece que al aumentar la complejidad del modelo, el sesgo tiende a disminuir y la varianza tiende a aumentar, por lo que existe un punto óptimo de complejidad que minimiza el error total.

Justificación (si es F): _____

Sección 2: Múltiple Choice [24 pts]

Marque con un círculo la **única** opción correcta en cada pregunta.


1. ¿Cuál de las siguientes afirmaciones sobre XGBoost, LightGBM y CatBoost es **correcta**?
- a) Los tres algoritmos son idénticos en su estrategia de crecimiento de árboles; solo difieren en el lenguaje de implementación.
 - b) XGBoost crece el árbol nivel por nivel (*level-wise*); LightGBM crece por hoja (*leaf-wise*), siendo más eficiente en memoria; CatBoost maneja variables categóricas de forma nativa sin necesidad de encoding previo.
 - c) LightGBM no puede manejar variables categóricas y siempre requiere One-Hot Encoding.
 - d) CatBoost utiliza expansión de Taylor de segundo orden para optimizar su función objetivo, lo que lo hace más preciso que XGBoost.
2. ¿Qué significa que dos componentes principales obtenidas por PCA sean ortogonales entre sí?
- a) Que explican la misma cantidad de varianza en los datos.

- b) Que la correlación lineal entre ellas es cero; cada componente captura información independiente de las demás.
 - c) Que sus autovalores asociados son iguales.
 - d) Que no pueden ser usadas simultáneamente como predictores en un modelo supervisado.
3. En el contexto del *Bias-Variance Tradeoff*, ¿cuál de los siguientes modelos presenta **más sesgo y menos varianza**?
- a) Un árbol de decisión con `max_depth=20` y sin poda.
 - b) Un Random Forest con 500 árboles.
 - c) Una regresión lineal aplicada a datos con relaciones no lineales complejas.
 - d) Un modelo de Gradient Boosting con tasa de aprendizaje muy baja y muchos árboles.
4. ¿Cuál es la razón principal por la que Bagging reduce la varianza del modelo?
- a) Porque penaliza los coeficientes del modelo con un término de regularización L2.
 - b) Porque entrena los modelos secuencialmente, permitiendo que cada uno corrija los errores del anterior.
 - c) Porque promedia las predicciones de múltiples modelos entrenados sobre distintas muestras bootstrap, reduciendo la variabilidad que tendría cualquier modelo individual.
 - d) Porque utiliza siempre el 100 % de los datos disponibles en cada modelo del ensamble.
5. ¿Qué ocurre con el error OOB (*Out-of-Bag*) de un Random Forest a medida que se agregan más árboles al ensamble?
- a) Aumenta indefinidamente, indicando sobreajuste progresivo.
 - b) Disminuye y se estabiliza, ya que agregar más árboles a partir de cierto punto produce retornos decrecientes.
 - c) Permanece constante independientemente de la cantidad de árboles.
 - d) Primero disminuye y luego aumenta, al igual que la curva de validación en modelos de boosting.
6. ¿Cuál de los siguientes métodos de selección de features es un método **Embedded**?
- a) Correlación de Pearson entre cada feature y la variable objetivo.
 - b) Forward Selection con validación cruzada.
 - c) La importancia de features calculada por un árbol de decisión o Random Forest durante el entrenamiento.
 - d) Eliminar columnas con varianza menor a un umbral definido.

Sección 3: Interpretación de Gráficos [20 pts]

Ejercicio A: Scree Plot de PCA [10 pts]


El siguiente gráfico muestra el *scree plot* de un PCA aplicado a un dataset con 8 features originales. Las barras representan la varianza explicada por cada componente principal (individual) y la línea roja la varianza acumulada.



- a) Si se quisiera retener al menos el **85 %** de la varianza original, ¿cuántas componentes principales se deberían seleccionar? Justifique leyendo el gráfico.
- b) ¿Cuánto de la varianza original se **pierde** al reducir el dataset a 2 componentes principales? ¿Qué implica esta pérdida en términos prácticos?
- c) El dataset original tiene 8 features y se quiere usar PCA antes de aplicar un **Random Forest**. Un compañero sugiere que esto siempre mejora el modelo. ¿Está de acuerdo? Justifique.

Ejercicio B: Partial Dependence Plot [10 pts]

El siguiente gráfico muestra el PDP (*Partial Dependence Plot*) del feature “Edad del cliente” sobre la predicción de un modelo de churn (probabilidad de abandono).



- a) Describa en palabras qué muestra este gráfico. ¿Cómo varía la probabilidad de churn en función de la edad?
- b) ¿El PDP permite concluir que la edad **causa** el churn? ¿Por qué?
- c) Si en lugar del PDP se mostrara un **ICE plot** (*Individual Conditional Expectation*), ¿qué información adicional aportaría que el PDP no muestra?

Sección 4: Desarrollo [32 pts]

1. [10 pts] Ensamblados y Diversidad

- a) Explique por qué la diversidad entre los modelos base es fundamental para que un ensamble mejore el rendimiento respecto a un modelo individual. ¿Qué sucedería si todos los modelos del ensamble cometieran exactamente los mismos errores?

- b) Random Forest introduce dos fuentes de aleatoriedad para lograr diversidad. Identifíquelas y explique cómo cada una contribuye a reducir la correlación entre árboles.

- c) ¿Por qué Bagging es trivialmente paralelizable pero Boosting no lo es? Explique la diferencia estructural entre ambos métodos que determina esto.

2. [10 pts] Reducción de la Dimensionalidad

- a) Explique el concepto de “maldición de la dimensionalidad”. ¿Por qué los algoritmos basados en distancias (como KNN) se ven especialmente perjudicados en espacios de alta dimensión?

- b) Compare PCA con t-SNE y UMAP en términos de: (i) tipo de relaciones que capturan (lineales vs. no lineales), (ii) capacidad de proyectar nuevas muestras, y (iii) utilidad para preprocesamiento vs. solo visualización.

- c) ¿Por qué es obligatorio estandarizar los features **antes** de aplicar PCA? ¿Qué problema ocurriría si no se hace?

3. [12 pts] Caso integral: Detección de piezas defectuosas

Una fábrica de electrónicos quiere predecir qué piezas del proceso de manufactura saldrán defectuosas antes de que lleguen al control de calidad. Cuentan con:

- Datos de sensores durante la fabricación: temperatura, presión, vibración (200 sensores en total).
 - Registros históricos de 500.000 piezas, de las cuales 4.500 resultaron defectuosas.
 - Algunos sensores tienen datos correlacionados entre sí.
- a) ¿Qué desafíos presenta este dataset y cómo los abordaría? Considere el desbalance de clases, la alta dimensión y la correlación entre sensores.
- b) ¿Qué modelo(s) elegiría para este problema y por qué? Compare al menos dos opciones considerando: rendimiento predictivo, interpretabilidad y complejidad de ajuste.
- c) En una fábrica, los errores Falso Negativo (no detectar una pieza defectuosa) y Falso Positivo (descartar una pieza buena) tienen costos muy distintos. ¿Cómo tendría esto en cuenta al elegir el umbral de decisión y la métrica de evaluación?

— *Fin del Parcial Modelo 2* —