

Universidad Torcuato Di Tella**Tecnología Digital VI — Parcial Modelo 3**

1er Semestre 2026

Instrucciones: El parcial tiene una duración de **90 minutos**. Está prohibido el uso de computadoras o código. Sí se permite el uso de una hoja de fórmulas. Cada sección indica el puntaje. Puntaje total: **100 puntos**.

Nombre y apellido: _____

Legajo: _____

Sección 1: Verdadero o Falso [24 pts]

Indique **V** (Verdadero) o **F** (Falso) para cada afirmación. Si la afirmación es falsa, **justifique brevemente** por qué (sin justificación no se otorga puntaje en los falsos).

1. _____ SMOTE (*Synthetic Minority Over-sampling Technique*) genera nuevas muestras de la clase minoritaria copiando exactamente observaciones existentes.

Justificación (si es F): _____

2. _____ En K-Means, la elección aleatoria de los centroides iniciales puede llevar a diferentes resultados en distintas ejecuciones del algoritmo con los mismos datos.

Justificación (si es F): _____

3. _____ La importancia de features basada en impureza en árboles tiende a sobreestimar la importancia de variables con muchas categorías o alta cardinalidad, por lo que una alternativa más confiable es la importancia por permutación.

Justificación (si es F): _____

4. _____ t-SNE preserva tanto la estructura local (vecinos cercanos) como la global (distancias entre grupos lejanos) de los datos, lo que lo hace ideal para visualización e inferencia general.

Justificación (si es F): _____

5. ____ El RMSE (Root Mean Squared Error) penaliza más los errores grandes que el MAE (Mean Absolute Error), ya que eleva al cuadrado las diferencias antes de promediarlas.

Justificación (si es F): _____

6. ____ Un modelo de Regresión Logística con combinación lineal $\beta^\top x = 0$ asigna una probabilidad de 0.5 a la muestra, colocándola exactamente sobre el *decision boundary*.

Justificación (si es F): _____

7. ____ En clustering jerárquico aglomerativo con *Single Linkage*, la distancia entre dos grupos se define como la distancia **máxima** entre cualquier par de puntos pertenecientes a grupos distintos.

Justificación (si es F): _____

8. ____ Gradient Boosting puede interpretarse como un descenso de gradiente en el espacio funcional, donde cada árbol nuevo aproxima el gradiente negativo de la función de pérdida respecto a la predicción actual.

Justificación (si es F): _____

Sección 2: Múltiple Choice [24 pts]

Marque con un círculo la **única** opción correcta en cada pregunta.


1. ¿Cuál de las siguientes afirmaciones sobre el algoritmo K-Means es **incorrecta**?
- a) K-Means requiere que el número de clusters K sea especificado de antemano.
 - b) K-Means puede encontrar clusters de forma arbitraria (círculos, espirales) porque no asume ninguna forma geométrica particular.
 - c) K-Means es sensible a los valores atípicos (*outliers*) ya que los centroides son promedios.
 - d) En cada iteración, K-Means reasigna cada punto al centroide más cercano y luego recalcula los centroides.
2. ¿En qué situación la métrica RMSLE es más apropiada que el RMSE?
- a) Cuando la variable objetivo es binaria (0 o 1).

- b) Cuando la variable objetivo abarca varios órdenes de magnitud y los errores relativos importan más que los absolutos (por ejemplo, predecir ventas de productos muy baratos y muy caros en el mismo modelo).
 - c) Cuando el dataset tiene clases muy desbalanceadas.
 - d) Cuando se quiere penalizar más los errores grandes que los pequeños.
3. Un cliente de un banco fue rechazado para un crédito. Cuando pide explicación, el banco responde “el modelo lo rechazó”. ¿Qué principio de ML aplicado fue ignorado en este sistema?
- a) El principio de regularización, ya que el modelo debería haber sido penalizado con Lasso.
 - b) El principio de interpretabilidad y explicabilidad, fundamental en contextos de impacto en personas donde se debe poder justificar las decisiones automáticas.
 - c) El principio de validación cruzada, ya que un simple holdout no es suficiente.
 - d) El principio de escalado, ya que los datos deberían haberse normalizado antes del entrenamiento.
4. ¿Cuál es la principal ventaja de DBSCAN frente a K-Means?
- a) DBSCAN es siempre más rápido que K-Means en datasets grandes.
 - b) DBSCAN puede encontrar clusters de forma arbitraria (no esférica) y detectar automáticamente puntos de ruido, sin necesidad de especificar el número de clusters de antemano.
 - c) DBSCAN requiere que se especifique el número de clusters K como parámetro de entrada.
 - d) DBSCAN siempre produce mejores resultados que K-Means en problemas con clases balanceadas.
5. ¿Qué representa la **altura de las uniones** en un dendrograma de clustering jerárquico aglomerativo?
- a) El número de muestras contenidas en cada cluster al momento de la unión.
 - b) La distancia (o disimilitud) entre los dos grupos que se fusionan en ese paso; cuanto más alta la unión, más diferentes eran los grupos al unirse.
 - c) El valor del índice de Gini del nodo padre al momento de la fusión.
 - d) El número de iteraciones que le tomó al algoritmo converger hasta ese punto.
6. En el contexto de Gradient Boosting, ¿qué representa un valor de *learning rate* (η) muy pequeño (por ejemplo, $\eta = 0,01$)?
- a) Que el modelo converge rápidamente con pocos árboles, sin riesgo de overfitting.
 - b) Que cada árbol nuevo contribuye muy poco a la predicción final, requiriendo más árboles para converger, pero generando mayor regularización implícita y mejor generalización.
 - c) Que el modelo usa solo el 1 % de las muestras en cada iteración.
 - d) Que la tasa de aprendizaje y el número de árboles son independientes entre sí.

Sección 3: Interpretación de Gráficos [20 pts]

Ejercicio A: Curva ROC [10 pts]


Se entrenaron tres modelos para un problema de clasificación binaria (detección de enfermedad). El siguiente gráfico muestra sus curvas ROC.



- a) ¿Cuál de los tres modelos elegiría y por qué? ¿Qué indica el AUC en términos prácticos?
- b) El Modelo C tiene $AUC = 0.52$. ¿Qué nos dice esto sobre su rendimiento? ¿Podría ser útil de alguna forma o es siempre descartable?
- c) En el contexto de detección de enfermedades, si se quiere **maximizar la sensibilidad** (no dejar pasar casos positivos), ¿qué zona de la curva ROC del Modelo A sería de mayor interés y qué consecuencia tiene esto sobre los falsos positivos?

Ejercicio B: Bias-Variance Trade-off [10 pts]

El siguiente gráfico muestra las curvas de sesgo², varianza y error total en función de la complejidad del modelo.



- a) ¿En qué zona del gráfico (baja, óptima o alta complejidad) se encuentran los fenómenos de *underfitting* y *overfitting* respectivamente? Descríbalos.
- b) ¿Por qué el error total tiene un mínimo en la complejidad óptima? ¿Qué sucede con el sesgo y la varianza en ese punto?
- c) Un equipo decide siempre usar el modelo más complejo disponible, argumentando que “más parámetros siempre dan mejores resultados”. ¿Cómo refutaría este argumento usando el gráfico?

Sección 4: Desarrollo [32 pts]

1. [10 pts] Clustering y Aprendizaje No Supervisado

- a) Explique la diferencia fundamental entre el aprendizaje supervisado y el no supervisado. ¿Por qué es más difícil evaluar el éxito de un método no supervisado?

- b) Describa el algoritmo K-Means paso a paso. ¿Cuál es su criterio de convergencia? ¿Cómo afecta la elección de los centroides iniciales al resultado final y qué estrategia existe para mitigarlo?

- c) ¿Cómo ayuda el “Método del Codo” a elegir el valor de K en K-Means? ¿Cuál es la limitación de este método en la práctica?

2. [10 pts] Comparación de Métricas y Selección de Modelos

- a) Se tiene un problema de predicción de precios de propiedades (regresión). El equipo debate entre usar RMSE y MAE. Explique las diferencias entre ambas métricas y en qué situaciones preferiría una sobre la otra.

- b) Un modelo de detección de tumores malignos tiene $\text{Precision} = 0.95$ y $\text{Recall} = 0.40$. ¿Qué le preocuparía de este resultado? ¿Qué ajuste haría al modelo y cómo afectaría el tradeoff entre Precision y Recall?

- c) Explique la diferencia entre los métodos de selección de features **Filter**, **Wrapper** y **Embedded**, dando un ejemplo de cada uno. ¿Cuál es computacionalmente más costoso y por qué?

3. [12 pts] Caso integral: Segmentación de clientes

Una empresa de e-commerce quiere segmentar a sus clientes para diseñar campañas de marketing personalizadas. Tiene un dataset con:

- 200.000 clientes con las siguientes variables: monto total comprado (últimos 12 meses), frecuencia de compra mensual, categorías de productos preferidas (10 categorías, variable categórica), edad, y 50 features adicionales derivadas del comportamiento en la app.
 - No existe una variable objetivo (etiqueta) que diga a qué segmento pertenece cada cliente.
- a) ¿En qué rama del Machine Learning cae este problema? ¿Es un problema de regresión o clasificación? Justifique.
- b) El dataset tiene 60 features en total. Antes de aplicar un algoritmo de clustering, ¿qué pasos de preprocesamiento realizaría y por qué? Mencione al menos **tres** pasos concretos y justifique cada uno.
- c) ¿Qué algoritmo(s) de clustering utilizaría? Compare al menos dos opciones considerando las características del dataset. ¿Cómo validaría que los clusters encontrados son **útiles** para el negocio, dado que no hay etiquetas verdaderas?

— *Fin del Parcial Modelo 3* —