

Tecnología Digital VI — Segundo Parcial

Modelo de Examen 2

Universidad Torcuato Di Tella

Duración: 2 horas

Nombre: _____

Parte 1: Verdadero o Falso (2 pts c/u)

Justifique brevemente las respuestas falsas.

- a) El Perceptrón simple puede aprender la función XOR porque tiene un peso por cada entrada más el bias.
 - b) La función Softmax garantiza que las salidas sumen 1 y sean no negativas, lo que permite interpretarlas como probabilidades.
 - c) En una CNN, la operación de convolución es no lineal, por lo que no es necesario agregar una función de activación después.
 - d) El algoritmo ADAM combina las ideas de Momentum y Learning Rate adaptativo por parámetro.
 - e) En Transfer Learning, se suelen congelar las primeras capas convolucionales porque capturan features genéricas (bordes, texturas) útiles para cualquier tarea visual.
 - f) Una BiLSTM procesa la secuencia en ambas direcciones, por lo que tiene el doble de hidden states que una LSTM unidireccional.
-

Parte 2: Multiple Choice (3 pts c/u)

Marque la opción correcta. Solo una es válida.

- 1) ¿Cuál es el propósito principal de **Batch Normalization**?
 - A) Reemplazar las funciones de activación en cada capa.
 - B) Normalizar las salidas de cada capa para combatir el Internal Covariate Shift y acelerar la convergencia.
 - C) Reducir la cantidad de parámetros de la red.
 - D) Eliminar la necesidad de usar un optimizador como ADAM.
- 2) En Style Transfer, la **Style Loss** se calcula usando:

- A) La diferencia pixel a pixel entre la imagen generada y la imagen de estilo.
 - B) La diferencia entre las matrices de Gram de los feature maps de la imagen generada y la imagen de estilo.
 - C) El error cuadrático entre los logits de la última capa FC.
 - D) La divergencia KL entre las distribuciones de los feature maps.
- 3) ¿Por qué se divide por $\sqrt{d_k}$ en el **Scaled Dot-Product Attention**?
- A) Para que las queries y keys tengan norma unitaria.
 - B) Para reducir la cantidad de parámetros del modelo.
 - C) Para evitar que el producto punto crezca demasiado con la dimensión, estabilizando la softmax.
 - D) Para convertir los scores en probabilidades.
- 4) ¿Qué técnica usa **InstructGPT** para alinear las respuestas del LLM con la intención del usuario?
- A) Data Augmentation sobre el corpus de pre-entrenamiento.
 - B) Reinforcement Learning from Human Feedback (RLHF).
 - C) Agregar más capas de Transformer al modelo base.
 - D) Fine-tuning supervisado sin ningún componente adicional.
- 5) En una celda LSTM, la **Forget Gate** se encarga de:
- A) Decidir qué información nueva se escribe en el cell state.
 - B) Decidir cuánto del cell state actual se expone como salida h_t .
 - C) Decidir qué información del cell state anterior se descarta (multiplicando por un valor entre 0 y 1).
 - D) Calcular el gradiente para el backpropagation through time.

Parte 3: Desarrollo (10 pts c/u)

1) Forward Pass manual.

Considere una red con 2 entradas (x_1, x_2) , una capa oculta de 2 neuronas con activación ReLU, y una neurona de salida con activación Sigmoide. Los pesos y biases son:

	Neurona oculta 1	Neurona oculta 2
w_{x_1}	0.5	-1,0
w_{x_2}	1.0	0.5
b	-0,5	0.0

Neurona de salida: $w_1 = 1,0$, $w_2 = -0,5$, $b = 0,2$.

Para la entrada $x_1 = 1$, $x_2 = 0$:

- a) Calcule z y a para cada neurona de la capa oculta.
- b) Calcule z y a para la neurona de salida.
- c) Si el label verdadero es $y = 1$, ¿la red predice correctamente (umbral 0.5)?

2) Segmentación semántica y Dice Loss.

- a) ¿Por qué en segmentación semántica se prefiere Dice Loss sobre Cross-Entropy clásica?
- b) Dada una predicción y un ground truth para una imagen de 4×4 píxeles (clase “objeto” = 1, “fondo” = 0):
 Predicción: $[[1, 1, 0, 0], [1, 1, 0, 0], [0, 0, 0, 0], [0, 0, 0, 0]]$
 Ground Truth: $[[1, 1, 1, 0], [1, 1, 0, 0], [1, 0, 0, 0], [0, 0, 0, 0]]$
 Calcule el coeficiente Dice: $\text{Dice} = \frac{2|X \cap Y|}{|X| + |Y|}$.

3) Transformers: Self-Attention.

Considere la oración: “El banco está cerca del río”.

- a) Explique intuitivamente qué representan las matrices Query, Key y Value en el mecanismo de Self-Attention.
- b) ¿Cómo resuelve Self-Attention la ambigüedad de la palabra “banco” (¿institución financiera o ribera?) en esta oración?
- c) ¿Para qué sirve Multi-Head Attention? Dé un ejemplo de dos “relaciones” distintas que podrían aprender dos heads diferentes.

Parte 4: Interpretación de Código (15 pts)

Analice el siguiente código de PyTorch y responda las preguntas.

```

1  import torch
2  import torch.nn as nn
3
4  class CNN(nn.Module):
5      def __init__(self):
6          super().__init__()
7          self.conv1 = nn.Conv2d(1, 32, kernel_size=9, padding=4)
8          self.conv2 = nn.Conv2d(32, 64, kernel_size=3, padding=1)
9          self.pool = nn.MaxPool2d(2, 2)
10         self.relu = nn.ReLU()
11         self.fc1 = nn.Linear(64 * 7 * 7, 128)
12         self.fc2 = nn.Linear(128, 10)
13
14     def forward(self, x):
15         x = self.pool(self.relu(self.conv1(x)))
16         x = self.pool(self.relu(self.conv2(x)))
17         x = x.view(-1, 64 * 7 * 7)
18         x = self.relu(self.fc1(x))
19         x = self.fc2(x)
20         return x

```

- a) ¿Cuál es el tamaño esperado de la imagen de entrada? Justifique rastreando las dimensiones capa por capa hasta llegar a $64 \times 7 \times 7$ antes del flatten. (Use la fórmula $O = \frac{I-K+2P}{S} + 1$.)
- b) ¿Por qué el `padding=4` en la primera convolución y `padding=1` en la segunda? ¿Qué relación tiene con el tamaño del kernel?
- c) ¿Cuántos parámetros entrenables tiene la capa `conv1`? Muestre el cálculo.
- d) ¿Por qué la capa `fc1` tiene como entrada $64 \times 7 \times 7 = 3136$ neuronas?
- e) ¿Qué problema está resolviendo esta red? ¿Para qué dataset fue diseñada?
- f) Si quisiera adaptar esta red para clasificar imágenes a color de 32×32 en 100 clases (ej. CIFAR-100), ¿qué cambios mínimos haría en la arquitectura?