

Universidad Torcuato Di Tella

Tecnología Digital VI — Parcial Modelo 1

1er Semestre 2026

Instrucciones: El parcial tiene una duración de **90 minutos**. Está prohibido el uso de computadoras o código. Sí se permite el uso de una hoja de fórmulas. Cada sección indica el puntaje. Puntaje total: **100 puntos**.

Nombre y apellido: _____

Legajo: _____

Sección 1: Verdadero o Falso [24 pts]

Indique **V** (Verdadero) o **F** (Falso) para cada afirmación. Si la afirmación es falsa, **justifique brevemente** por qué (sin justificación no se otorga puntaje en los falsos).

1. ____ En un mecanismo MCAR (*Missing Completely at Random*), la ausencia de un valor depende del valor faltante en sí mismo, lo que lo hace el tipo de dato faltante más problemático.

Justificación (si es F): _____

2. ____ Aplicar un *StandardScaler* ajustado sobre el conjunto de *test* antes de dividir los datos en train/test constituye un caso de *data leakage*.

Justificación (si es F): _____

3. ____ En K-Fold Cross-Validation con $k = 5$, cada muestra del dataset es usada exactamente una vez como muestra de validación a lo largo de las 5 iteraciones.

Justificación (si es F): _____

4. ____ La Regresión Logística es un modelo no lineal porque utiliza la función sigmoide para transformar su salida.

Justificación (si es F): _____

5. ____ La regularización L1 (Lasso) tiende a producir coeficientes exactamente iguales a cero, lo que la convierte en un método implícito de selección de variables.

Justificación (si es F): _____

6. _____ Un árbol de decisión muy profundo (sin regularización) suele tener bajo sesgo y baja varianza, lo que lo convierte en un modelo ideal sin necesidad de ajuste.

Justificación (si es F): _____

7. _____ Un AUC-ROC de 0.5 indica que el modelo tiene un rendimiento equivalente al de clasificar al azar.

Justificación (si es F): _____

8. _____ El índice Gini y la Entropía, como funciones de impureza en árboles de decisión, alcanzan su valor máximo cuando todas las muestras de un nodo pertenecen a la misma clase.

Justificación (si es F): _____

Sección 2: Múltiple Choice [24 pts]

Marque con un círculo la **única** opción correcta en cada pregunta.


1. Un dataset de detección de fraude tiene 98 % de transacciones legales y 2 % de transacciones fraudulentas. Un modelo que siempre predice “legal” obtiene un *Accuracy* del 98 %. ¿Cuál de las siguientes afirmaciones describe mejor la situación?
 - a) El modelo es excelente; un 98 % de accuracy es muy alto para cualquier problema.
 - b) El accuracy es engañoso en este caso; métricas como F1-Score o Precision-Recall son más adecuadas para evaluar el rendimiento real.
 - c) El problema se resolvería aumentando el umbral de decisión del modelo a 0.99.
 - d) La solución correcta es aplicar un StandardScaler antes de entrenar.
2. ¿Cuál es el efecto principal de aumentar el parámetro `max_depth` en un árbol de decisión?
 - a) Reduce el tiempo de entrenamiento y aumenta el sesgo del modelo.
 - b) Aumenta la complejidad del modelo, reduciendo el sesgo pero potencialmente aumentando la varianza (overfitting).
 - c) Reduce tanto el sesgo como la varianza, mejorando siempre el desempeño.

- d) No tiene efecto sobre el overfitting; solo afecta la velocidad de predicción.
3. Un equipo aplica *Label Encoding* a la variable “País” con valores {Argentina=0, Brasil=1, Chile=2} y luego entrena una regresión logística. ¿Cuál es el problema principal de este enfoque?
- a) El modelo no puede manejar más de dos categorías en una variable.
 - b) El encoding impone un orden numérico artificial (Argentina < Brasil < Chile) que el modelo interpretará como una relación ordinal inexistente.
 - c) El Label Encoding solo funciona con árboles de decisión, no con modelos lineales.
 - d) No hay ningún problema; Label Encoding es siempre equivalente a One-Hot Encoding.
4. La curva Precision-Recall es preferida sobre la curva ROC cuando:
- a) El dataset está perfectamente balanceado entre clases.
 - b) Se trabaja con un problema de regresión, no de clasificación.
 - c) Las clases están muy desbalanceadas y la clase positiva es la de interés, ya que la curva ROC puede resultar optimista al verse influida por la gran cantidad de verdaderos negativos.
 - d) El modelo utilizado es un árbol de decisión en lugar de una regresión logística.
5. ¿Qué representa el error *Out-of-Bag* (OOB) en Random Forest?
- a) El error cometido sobre el conjunto de test reservado al final del proceso.
 - b) Una estimación del error de generalización calculada usando, para cada muestra, solo los árboles que **no** la incluyeron en su muestra de bootstrap.
 - c) El error promedio de entrenamiento de todos los árboles individuales.
 - d) El error producido por usar demasiados árboles, causando overfitting en el ensamble.
6. ¿Cuál de las siguientes opciones describe correctamente la diferencia entre *Bagging* y *Boosting*?
- a) Bagging entrena modelos secuencialmente ponderando los errores; Boosting los entrena en paralelo sobre distintas muestras bootstrap.
 - b) Bagging entrena modelos en paralelo sobre muestras bootstrap independientes para reducir la varianza; Boosting entrena modelos secuencialmente, donde cada modelo se focaliza en los errores del anterior, reduciendo el sesgo.
 - c) Bagging y Boosting son técnicamente idénticos, solo difieren en el lenguaje de programación utilizado.
 - d) Bagging solo funciona con modelos lineales; Boosting solo funciona con árboles.

Sección 3: Interpretación de Gráficos [20 pts]

Ejercicio A: Curvas de aprendizaje [10 pts]

El siguiente gráfico muestra las curvas de error de entrenamiento y validación de un modelo en función de la profundidad máxima del árbol (`max_depth`).



- a) ¿En qué valor de `max_depth` el modelo comienza a presentar *overfitting*? Justifique observando el comportamiento de ambas curvas.
- b) ¿Qué ocurre con el modelo cuando `max_depth` = 1 o 2? ¿Cómo se llama este fenómeno?
- c) Si debería elegir un valor de `max_depth` para producir el mejor modelo, ¿cuál elegiría y por qué?

Ejercicio B: Matriz de confusión [10 pts]

Un modelo de clasificación binaria para detectar correos spam (positivo = spam) produjo la siguiente matriz de confusión sobre el conjunto de test:

		Predicción	
		Spam	No Spam
Real	Spam	80	20
	No Spam	30	870

- a) Calcule el **Recall** (sensibilidad) para la clase Spam y explique con palabras qué nos indica este valor en el contexto del problema.
- b) Calcule la **Precision** para la clase Spam e interprete el resultado.
- c) En este contexto (filtro de spam), ¿es más grave tener un Recall bajo o una Precision baja? Justifique considerando las consecuencias prácticas de cada tipo de error.

Sección 4: Desarrollo [32 pts]

1. [10 pts] Preprocesamiento y Data Leakage

Un equipo de Data Science tiene un pipeline para predecir el precio de propiedades. El pipeline que implementaron es el siguiente:

- I. Cargar el dataset completo (10.000 propiedades).
- II. Imputar valores faltantes con la *media* de cada columna, calculada sobre todo el dataset.
- III. Escalar todas las variables numéricas con MinMaxScaler ajustado sobre todo el dataset.
- IV. Dividir en 80 % train y 20 % test aleatoriamente.
- V. Entrenar un modelo de Regresión Lineal sobre el conjunto de train.
- VI. Evaluar con RMSE sobre el conjunto de test.

- a) Identifique **todos** los errores conceptuales presentes en el pipeline. Explique por qué cada uno es un problema.

- b) Describa el pipeline corregido, paso a paso, que elimina los errores identificados.

2. [10 pts] Árboles de Decisión y Regularización

- a) Explique intuitivamente por qué los árboles de decisión son modelos con **alta varianza**. ¿Qué propiedad del algoritmo de construcción los hace tan sensibles a cambios pequeños en los datos?
- b) Mencione **tres** hiperparámetros que se pueden ajustar para regularizar un árbol de decisión (reducir overfitting) y explique brevemente el efecto de cada uno.
- c) Un árbol de regresión fue entrenado con valores de temperatura entre 10°C y 40°C. Hoy en producción recibe una observación con temperatura = 55°C. ¿Qué valor predecirá el modelo? ¿Es esto un problema? ¿Por qué?

3. [12 pts] Caso integral: Sistema de recomendación de créditos

Un banco quiere construir un sistema para predecir si un cliente pagará o no un crédito (variable objetivo: `default` = 1 si no paga, 0 si paga). El dataset tiene:

- 500.000 clientes históricos, de los cuales solo 12.000 no pagaron.
- Variables numéricas: ingreso mensual, edad, monto del crédito, historial de pagos.
- Variables categóricas: tipo de empleo, zona geográfica, nivel de educación.
- Un 8 % de valores nulos en “ingreso mensual” y un 3 % en “historial de pagos”.

El equipo propone entrenar directamente un árbol de decisión con parámetros por defecto y reportar el Accuracy al directorio.

- a) ¿Qué problemas tiene el dataset que deben resolverse antes de entrenar? Mencione al menos **tres** y proponga una estrategia para cada uno.

- b) ¿Por qué reportar el Accuracy al directorio es engañoso en este caso? ¿Qué métrica(s) recomendaría y por qué?
- c) El equipo propone un árbol de decisión. ¿Qué argumentos daría para considerar también un **Random Forest** o **Gradient Boosting**? ¿Existe alguna razón para mantener el árbol simple?

— *Fin del Parcial Modelo 1* —