

Universidad Torcuato Di Tella

Tecnología Digital VI

Banco de Preguntas Teóricas para el Parcial

1er Semestre 2026

Cómo usar este documento: Este banco cubre todos los temas teóricos evaluables en el parcial. Las preguntas marcadas con **[CLÁSICA]** son las que se repiten históricamente. Las respuestas se encuentran en el documento *preguntas_teoricas.pdf*.

Índice

1. Preprocesamiento y Validación	2
1.1. Valores Faltantes	2
1.2. Data Leakage	2
1.3. Escalado de Features	2
1.4. Desbalance de Clases	2
1.5. Validación Cruzada	2
2. Métricas de Evaluación	2
2.1. Regresión	2
2.2. Clasificación	3
3. Modelos Lineales	3
3.1. Regresión Lineal y Logística	3
3.2. Regularización	3
4. Árboles de Decisión	3
5. Ensamblados I: Bagging y Random Forest	3
6. Ensamblados II: Boosting	4
7. Reducción de la Dimensionalidad	4
8. Overfitting, Underfitting y Trade-offs	4
9. Selección de Features	5
10. Resumen: Comparación de Modelos	5
11. Preguntas de Integración	5

Preprocesamiento y Validación

Valores Faltantes

- P1. Explique los tres mecanismos de datos faltantes (MCAR, MAR, MNAR) y dé un ejemplo de cada uno.
- P2. ¿Qué estrategias existen para imputar valores faltantes? ¿Cuándo usar cada una?

Data Leakage

P3.

[CLÁSICA] ¿Qué es el *data leakage*? Dé un ejemplo concreto y explique cómo prevenirlo.

- P4. Un equipo aplica un MinMaxScaler ajustado sobre todo el dataset y luego divide en train/test. ¿Hay data leakage? Justifique.

Escalado de Features

- P5. ¿Cuándo es obligatorio escalar features y cuándo no importa? Dé ejemplos de modelos en cada categoría.
- P6. Compare StandardScaler, MinMaxScaler y RobustScaler. ¿Cuándo preferiría cada uno?

Desbalance de Clases

P7.

[CLÁSICA] Un dataset de detección de fraude tiene 98 % de transacciones normales y 2 % fraudulentas. Un modelo que predice siempre “normal” obtiene 98 % de accuracy. ¿Qué problema hay y qué haría?

- P8. ¿Qué es SMOTE y cómo genera muestras sintéticas?

Validación Cruzada

P9.

[CLÁSICA] Explique K-Fold Cross-Validation. ¿Por qué es preferible al simple holdout?

- P10. ¿Qué es Leave-One-Out CV (LOOCV)? ¿Cuál es su ventaja y su desventaja principal?

Métricas de Evaluación

Regresión

- P11. Compare MSE, RMSE y MAE. ¿Cuándo elegiría cada uno?
- P12. ¿Puede el R^2 ser negativo? Explique qué significaría eso.
- P13. ¿Cuándo usar RMSLE en lugar de RMSE?

Clasificación

P14.

[CLÁSICA] Defina Precision y Recall. ¿Cuándo es más grave tener Recall bajo? ¿Cuándo es más grave tener Precision baja?

P15. ¿Qué es el F1-Score y cuándo es más útil que el Accuracy?

P16. Explique la curva ROC y el AUC-ROC. ¿Qué significa un AUC de 0.5?

P17. ¿Cuándo preferiría la curva Precision-Recall sobre la curva ROC?

Modelos Lineales

Regresión Lineal y Logística

P18. ¿Por qué la Regresión Logística es un modelo lineal si usa la función sigmoide?

P19. ¿Por qué la Regresión Lineal tiene solución cerrada pero la Logística no?

Regularización

P20.

[CLÁSICA] Compare L1 (Lasso) y L2 (Ridge). ¿En qué se diferencian y cuándo usar cada una?

P21. ¿Qué efecto tiene aumentar λ en la regularización? ¿Y disminuirlo?

Árboles de Decisión

P22. Explique intuitivamente por qué los árboles de decisión son modelos de **alta varianza**.

P23. Defina Gini y Entropía. ¿Qué valor toman cuando el nodo es puro? ¿Y cuando es máximamente impuro?

P24.

[CLÁSICA] Mencione **tres** hiperparámetros que regularizan un árbol de decisión (reducen overfitting) y explique el efecto de cada uno.

P25. Un árbol fue entrenado con temperaturas entre 10°C y 40°C. En producción recibe una observación de 55°C. ¿Qué predice? ¿Es un problema?

P26. ¿Qué es la importancia de features en un árbol? ¿Cuál es su sesgo principal?

Ensamblados I: Bagging y Random Forest

P27. Explique el concepto de **Bootstrap**. ¿Qué porcentaje de muestras queda fuera (OOB) en promedio?

P28. ¿Cómo se usa el error OOB en Random Forest? ¿Qué ventaja tiene frente a la validación cruzada?

P29.

[CLÁSICA] ¿Cuál es la diferencia fundamental entre Bagging y Random Forest?

P30. ¿Agregar más árboles a un Random Forest puede causar overfitting? ¿Y en Gradient Boosting?

P31. ¿Por qué la diversidad (decorrelación) entre modelos es importante en un ensamble?

Ensamblados II: Boosting

P32.

[CLÁSICA] Explique la diferencia conceptual entre Bagging y Boosting en cuanto a cómo reducen el error.

P33. Explique el algoritmo de AdaBoost. ¿Cómo se actualizan los pesos?

P34. ¿Qué son los pseudo-residuos en Gradient Boosting? ¿Por qué se usan?

P35. ¿Qué rol cumplen el *learning rate* (η) y el número de árboles (M) en Gradient Boosting? ¿Cómo interactúan?

P36. Compare XGBoost, LightGBM y CatBoost en al menos dos dimensiones.

Reducción de la Dimensionalidad

P37. ¿Qué es la maldición de la dimensionalidad y por qué afecta a los modelos basados en distancias?

P38. Explique PCA paso a paso. ¿Qué maximiza y cómo se obtienen las componentes?

P39. ¿Qué significa la varianza explicada en PCA? ¿Cómo se elige k ?

P40.

[CLÁSICA] Compare PCA, t-SNE y UMAP en cuanto a: linealidad, velocidad, y si pueden proyectar nuevas muestras.

Overfitting, Underfitting y Trade-offs

P41.

[CLÁSICA — SE TOMA SIEMPRE] ¿Qué hiperparámetros pueden causar **overfitting**? Liste al menos cinco (de distintos modelos) y explique por qué.

P42. Explique el Bias-Variance Trade-off con la fórmula y un ejemplo.

P43. ¿Cómo detectar si un modelo tiene overfitting o underfitting a partir de las curvas de aprendizaje?

Selección de Features

P44. Compare los tres tipos de selección de features: Filter, Wrapper y Embedded.

P45. ¿Por qué Label Encoding puede ser problemático para modelos lineales?

Resumen: Comparación de Modelos

P46.

[CLÁSICA] ¿Cuándo elegiría un árbol simple sobre Random Forest o Gradient Boosting?

P47. Complete la siguiente tabla comparativa de modelos:

Modelo	Sesgo	Varianza	Interpretable	No lineal
Reg. Lineal/Logística				
Árbol (profundo)				
Árbol (podado)				
Bagging / RF				
Gradient Boosting				

Preguntas de Integración

P48. Un equipo implementa el siguiente pipeline: (I) cargar dataset; (II) imputar con la media de todo el dataset; (III) escalar con MinMaxScaler sobre todo el dataset; (IV) dividir en train/test; (V) entrenar; (VI) evaluar. Identifique todos los errores.

P49. Un modelo de detección de enfermedades tiene Recall = 0.99 pero Precision = 0.10. ¿Cómo lo interpretaría? ¿Es buen modelo?

P50. Un banco quiere predecir impago de créditos. El dataset tiene 500k clientes, solo 12k no pagaron. ¿Qué problemas anticiparía y cómo los abordaría?

Banco de preguntas completo — TD VI 1S-2026

Para las respuestas, consulte el documento *preguntas_teoricas.pdf*.