

Objetivo

El objetivo de este Trabajo Práctico es introducir los fundamentos de la Visión Computacional mediante el uso de Redes Neuronales Convolucionales (CNNs). A diferencia del uso de modelos tabulares, aquí deberán lidiar con la dimensionalidad espacial de las imágenes, entendiendo cómo las redes extraen características, cómo interpretar sus decisiones y qué ventajas ofrece el uso de arquitecturas preentrenadas.

El Dataset: EuroSAT

Trabajarán con el dataset **EuroSAT**, un conjunto de datos basado en imágenes satelitales de los satélites Sentinel-2. El objetivo es clasificar el uso del suelo de distintos recortes topográficos.

- Deberán utilizar la **versión RGB** del dataset.
- El dataset consta de 10 clases balanceadas (por ejemplo: *Forest*, *Highway*, *River*, *Pasture*, *AnnualCrop*, entre otras).
- Pueden descargar el dataset desde
<https://www.kaggle.com/datasets/apollo2506/eurosat-dataset>.

Enunciado

El trabajo práctico debe resolverse utilizando el framework **PyTorch**. Se espera que cumplan, como mínimo, con los siguientes requerimientos:

1. Arquitectura Custom y Entrenamiento desde Cero

- Diseñar e implementar una Red Neuronal Convolucional (CNN) propia desde cero para el problema de clasificación de las imágenes.
- Configurar el pipeline de datos utilizando **DataLoader** y aplicando técnicas de *Data Augmentation* pertinentes para imágenes satelitales (considerar invarianzas geométricas).
- Realizar el loop de entrenamiento evidenciando el monitoreo de métricas. Se debe graficar la evolución de la *Loss Function* y del *Accuracy* tanto en el conjunto de entrenamiento como en el de validación.
- Implementar un monitoreo básico del flujo de gradientes durante las primeras épocas para asegurar que la red no sufra de desvanecimiento o explosión de gradientes (*Vanishing/Exploding Gradients*).

2. Análisis de Errores y Espacio Latente

- Evaluar el modelo final sobre el conjunto de test, reportando las métricas de clasificación y generando la Matriz de Confusión. Analizar y justificar las confusiones más frecuentes entre clases particulares.
- Extraer los *features* de las imágenes justo antes de la capa de clasificación final y utilizar técnicas de reducción de dimensionalidad (como t-SNE, UMAP o PCA) para proyectar y visualizar este espacio latente en 2 o 3 dimensiones. Analizar si las clases forman clusters distinguibles antes de la decisión final de la red.

3. Transfer Learning

- Seleccionar una arquitectura convolucional clásica preentrenada en ImageNet (por ejemplo: ResNet18 o VGG16).
 - Adaptar la red para clasificar las 10 clases de EuroSAT y entrenarla mediante *Fine-Tuning* o descongelando solo las últimas capas.
 - Comparar este enfoque contra su red custom en términos de: velocidad de convergencia, rendimiento final en métricas y tiempo de cómputo por época.
-

Modalidad de Entrega

- El trabajo se debe realizar en grupos de 3 personas. Únicamente **1 integrante** del grupo debe subir el trabajo a la carpeta correspondiente en el Campus Virtual.
- Se debe entregar el código generado junto a un pequeño informe explicativo.
- El trabajo se debe entregar hasta las **23:59hs del domingo 7 de junio**.