



TDVI: Inteligencia Artificial


Introducción a redes neuronales

Licenciatura en Tecnología Digital












Agenda

1. ¿Qué es una red?
2. ¿Por qué neuronales?
3. Perceptrón
4. Perceptrón multicapa
5. Tensores






¿Qué es una red?




¿Qué es una red?


- Grafos con nodos y ejes




Grafo de redes neuronales




Grafo de redes neuronales




Grafo de redes neuronales




Procesamiento de información




¿Ciclos?



¿Ciclos?



Grafos acíclicos dirigidos → Feedforward neural network



**Grafos acíclicos dirigidos
= Feedforward Neural Network**

Agenda


1. ¿Qué es una red?
2. ¿**Por qué neuronales?**
3. Perceptrón
4. Perceptrón multicapa
5. Tensores



brain



neural network




neuron



nucleus



axon




myelin sheath




axon terminal
fibre

dendrites







Redes neuronales

- Primer paper de influencia 1943 escrito por psiquiatras [[McCulloch43](#)].
 - Abstracción matemática de las funciones básicas de una neurona
 - Describe cómo estos modelos se conectan
- En 1958 se presentó el **perceptrón** como un modelo simplificado de una neurona [[Rosenblatt58](#)].






FIG. 1. Organization of a perceptron.



Beginnings

Thresholded
Logic Unit

1943

Perceptron

1957

Adaline

1960

1940

1950

1960





S. McCulloch - W. Pitts



R. Rosenblatt



B. Widrow -
M. Hoff




1st Neural Winter

XOR
Problem

1969



M. Minsky - S. Papert



1970

Multilayer
Backprop

1982

CNNs

1986

LSTMs


1989

1997



P. Werbos
D. Rumelhart -
G. Hinton -
R. Williams

Y. Lecun
J. Schmidhuber




2nd Neural Winter

SVMs

1995



C. Cortes -
V. Vapnik



2000

GPU Era

Deep
Nets


2006

Alex
Net

2012





R. Salakhutdinov - J. Hinton -
A. Krizhevsky - I. Sutskever



Agenda

1. ¿Qué es una red?
2. ¿Por qué neuronales?
3. **Perceptrón**
4. Perceptrón multicapa
5. Tensores



Redes neuronales artificiales

- Cada **input** es un número (escalar)

input 1 →


input 2 →

input 3 →

input 4 →


Redes neuronales artificiales

- Cada **input** es un número (escalar)
- Los inputs los multiplicamos por números reales o pesos (**weight**).




Redes neuronales artificiales

- Cada **input** es un número (escalar)
- Los inputs los multiplicamos por números reales o pesos (**weight**).
- **Sumamos** los resultados




Redes neuronales artificiales

- Cada **input** es un número (escalar)
- Los inputs los multiplicamos por números reales o pesos (**weight**).
- **Sumamos** los resultados
- Función de umbral/threshold (**activación**)




Redes neuronales artificiales

- Cada **input** es un número (escalar)
- Los inputs los multiplicamos por números reales o pesos (**weight**).
- **Sumamos** los resultados
- Función de umbral/threshold (**activación**)
- Opcional: término de **bias** antes del mapeo no-lineal




Nodos computacionales

- Generalmente se dibuja sin los pesos ni bias




Nodos computacionales

- Generalmente se dibuja sin los pesos ni bias
- Formalmente por una unidad k :
 - Inputs: x_j
 - Weights: w_{kj}
 - Bias: w_{k0} ($m+1$ inputs, $x_0 = 1$)
 - Funcion de activacion: φ
 - Output: y_k



Nodos computacionales

- Generalmente se dibuja sin los pesos ni bias
- Formalmente por una unidad k :
 - Inputs: x_j
 - Weights: w_{kj}
 - Bias: w_{k0} ($m+1$ inputs, $x_0 = 1$)
 - Funcion de activacion: φ
 - Output: y_k




$$y_k = \varphi \left(\sum_{j=0}^m w_{kj} x_j \right)$$

Modelado de regresión!

- ¿Que función debería ser φ para que la red implemente una regresión logística?

$$y_k = \varphi \left(\sum_{j=0}^m w_{kj} x_j \right)$$




Modelado de regresión!

- ¿Que función debería ser φ para que la red implemente una regresión logística?

$$\sigma(t) = \frac{e^t}{e^t + 1} = \frac{1}{1 + e^{-t}}$$


$$y = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)}}$$

$$y_k = \varphi \left(\sum_{j=0}^m w_{kj} x_j \right)$$



El verdadero poder de las RN

- Combinar capas con funciones no lineales!
- Composición de funciones: $f(g(h(a \otimes b)))$




Neurona

- **Neurona Artificial**
 - Es explícito y descriptivo
 - Enfatiza que fue inspirado en neuronas biológicas
 - La analogía con las neuronas reales es un poco engañosa...
- El término “unidad” o “nodo” son más apropiados
 - Generalmente utilizada en literatura avanzada y por aquellos ya familiarizados con deep learning.




Agenda

1. ¿Qué es una red?
2. ¿Por qué neuronales?
3. Perceptrón
4. **Perceptrón multicapa**
5. Tensores




Perceptrón Multicapa (MLP)

- En el contexto de deep learning, las unidades se organizan en capas.




Perceptrón Multicapa (MLP)

- En el contexto de deep learning, las unidades se organizan en capas.




Perceptrón Multicapa (MLP)

- En el contexto de deep learning, las unidades se organizan en capas.
- Fully-connected (FC) layers.




Perceptrón Multicapa (MLP)

- En el contexto de deep learning, las unidades se organizan en capas.
- Fully-connected (FC) layers.
- Output layer / capa de salida




Perceptrón Multicapa (MLP)

- In the context of Deep Learning, units are arranged in layers.
- Fully-connected (FC) layers.
- Output layer / capa de salida



Perceptrón Multicapa (MLP)

- In the context of Deep Learning, units are arranged in layers.
- Fully-connected (FC) layers.
- Output layer, input layer, and hidden layers.




Conceptos básicos

Capacidad de una red: definida por el número de nodos y capas.


Shallow networks: anchas

Deep networks: profundas



Agenda

1. ¿Qué es una red?
2. ¿Por qué neuronales?
3. Perceptrón
4. Perceptrón multicapa
5. **Tensores**




Tensores

- En las redes neuronales los datos se organizan en tensores


Tensors

- En las redes neuronales los datos se organizan en tensores
- Escalares (0D tensors)
- Vectores (1D tensors)
- Matrices (2D tensors)



Tensors

- En las redes neuronales los datos se organizan en tensores
- Escalares (0D tensors)
- Vectores (1D tensors)
- Matrices (2D tensors)
- Un tensor es un array multi-dimensional de números escalares.



¿Por qué tensores?

- Provee una manera **consistente** de representar datos en cualquier dimensión.
- Se usa para representar los términos de inputs, outputs, weights y bias.
- Sirve para datos de alta-dimensionalidad:
 - sonido, imágenes, videos, modelos 3D, etc
- Es una estructura optimizada para procesamiento en paralelo con GPUs

Bibliografía

Deep Learning, Ian Goodfellow and Yoshua Bengio and Aaron Courville - Capítulo 6.1

Neural Networks and Deep Learning. Charu C. Aggarwal 1.1 y 1.2

Introduction to Statistical Learning. Capítulo 10.1 y 10.2

