

TD VI: Inteligencia Artificial

Guía de ejercicios 1

Ejercicio 1. Indique o verdadero o falso y justifique.


- A. Al hacer uso de la técnica de *leave-one-out cross-validation* (LOOCV) para seleccionar modelos se tiene que, incluso para un mismo modelo (determinístico), los resultados obtenidos varían cada vez que se hace uso de dicha técnica.
- B. Trabajar con matrices ralas/esparsas siempre es buena idea, pues permite ahorrar memoria RAM.
- C. Para un clasificador dado (e.g., un árbol de decisión), aumentar el *threshold* (umbral de decisión / probabilidad de corte) suele estar asociado a aumentos de la métrica *recall*.
- D. Suponga que usted entrena un clasificador que tiene como *performance* un valor de F_1 cercano a 0,3. Esto implica que tanto *recall* como *precision* tienen valores cercanos a 0,3.
- E. *True positive rate* (TPR) es lo mismo que *precision*.

Ejercicio 2. Responda/Resuelva los siguientes ítems referidos a selección de modelos.

- A. Explique brevemente cuál es el **objetivo** de utilizar algún esquema de validación de modelos del tipo *holdout set*, LOOCV, o *k-fold cross-validation*.
- B. Ordene los esquemas *holdout set*, LOOCV, y *k-fold cross-validation* (con $k = 3$) de más a menos demandante en términos de cómputo (i.e., cuántos cálculos requieren hacer). Puede asumir que el *dataset* está compuesto por un par de miles de observaciones. Justifique su respuesta.
- C. Dé un ejemplo de una situación en donde usted usaría *k-fold cross-validation* por sobre *holdout set* y dé otro ejemplo de una situación donde haría lo contrario. Justifique su respuesta.
- D. Indique por qué, además del conjunto de validación, se suele usar también un tercer conjunto llamado de *testeo*.
- E. Suponga que usted se enfrenta a un problema de predicción de un evento futuro con datos con estructura temporal (por ejemplo, predecir el precio que tendrá el Bitcoin de aquí a un mes); en dicho caso, armar un conjunto de validación eligiendo registros de los datos de entrenamiento al azar es una buena idea.

Ejercicio 3

- A. Explique en términos coloquiales y concisos qué miden los valores de TPR y FPR asociados a los ejes de la curva ROC.
- B. Indique de manera concisa por qué, dado un modelo entrenado, suele existir una relación directa entre TPR y FPR (es decir, por qué la curva ROC tiene pendiente positiva).
- C. Grafique una curva ROC que se corresponda a un área bajo la curva igual a 1.
- D. Grafique una curva ROC que se corresponda a un área bajo la curva igual a 0.
- E. Grafique una curva ROC que se corresponda a un área bajo la curva igual a 0,5.
- F. Grafique una curva ROC que se corresponda a un área bajo la curva entre 0,5 y 1.
- G. Suponga que usted se enfrenta a un problema en donde clasificar mal una observación que efectivamente es positiva sale relativamente caro, mientras que clasificar mal una observación que efectivamente es negativa sale relativamente barato. Suponga, además, que es un problema con clases balanceadas (proporción similar de casos positivos y negativos). Dada una curva ROC como la que se presenta abajo, ¿es de esperar que sea preferible elegir un punto de corte como el asociado al punto A o como el asociado al punto B? Justifique su respuesta de manera concisa.



Ejercicio 4. Suponga que se encuentra frente a un problema de clasificación binaria.

- Suponga que se encuentra trabajando con variables categóricas **no ordinales**. Además de aplicar *one-hot encoding*, ¿qué otras estrategias se mencionaron en clase para incorporar información de estas variables en modelos de aprendizaje automático que no manejan directamente variables categóricas?
- Suponga que se encuentra trabajando con variables categóricas **ordinales**. Además de aplicar *one-hot encoding*, ¿qué otra estrategia se mencionó en clase para incorporar información de estas variables en modelos de aprendizaje automático que no manejan directamente variables categóricas?
- Suponga que se adopta la siguiente estrategia al trabajar con variables categóricas: si una observación tiene valores faltantes (NA en R) en una variable categórica, al realizar *one-hot encoding* de dicha variable, la fila correspondiente a esta observación tendrá NA en todas las nuevas columnas generadas. ¿Qué problema práctico puede surgir al seguir esta estrategia trabajando con grandes volúmenes de datos? ¿Qué otra estrategia podría seguirse para evitar dicho problema y contemplar los NA?
- Si realiza *one-hot encoding* antes de separar un conjunto de validación, puede incurrir en *data leakage*, ya que es posible que un valor de la variable únicamente se encuentre en el conjunto de validación. Esto resultaría en la creación de una nueva columna basada en información que no debería considerarse disponible durante el entrenamiento del modelo. Un colega le dice que esto no representa ningún inconveniente. ¿Está en lo cierto su colega? ¿Por qué?

Ejercicio 5

El F_1 -Score es un caso particular de la métrica F_β . La misma está diseñada para ponderar entre precisión y recall. Muestre a qué es igual F_β cuando β es igual a 0 y cuando β tiende a infinito.

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}$$

Ejercicio 6

Un banco comercial planea llevar adelante una campaña para reducir el *churn* de clientes (i.e., retener clientes que se darán de baja). Para ello, entrena un modelo predictivo el cual predice para cada cliente actual la probabilidad de que el mismo se dé de baja el siguiente mes ($y = 1$, se dará de baja; $y = 0$, no se dará de baja). En base a dichas predicciones, el banco decidirá si enviará a cada cliente una oferta especial (la cual asumimos que, una vez enviada, retiene con seguridad al cliente).

Enviar la oferta a un cliente tiene un costo monetario, de modo que no es factible ofrecerla a todos los clientes. Se sabe que el banco valora más ser selectivo y enviar la oferta a pocos clientes que estima se darán de baja, antes que enviarla de manera excesivamente generalizada. También se sabe que se consideraría un fracaso enviar la oferta a un número irrisoriamente pequeño de clientes (por ejemplo, 5 o 6).

El equipo de *analytics* del banco propone evaluar la performance del sistema de predicción utilizando la siguiente métrica (la cual depende de un valor $\beta \geq 0$ que debe fijarse de antemano):

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}$$

Responda y justifique las siguientes dos preguntas:

- Para un problema como el planteado, ¿usted recomendaría un valor de β igual, mayor o menor a 1? Justifique de manera concisa su respuesta; si lo considera necesario, puede utilizar ejemplos numéricos o gráficos para justificar su respuesta.
- Suponga ahora que dispone de la siguiente matriz de costos. Los valores de la misma dependen tanto de lo que eventualmente haga el cliente (darse o no de baja) y de si se le envía o no una oferta. Tome los valores de esta matriz como dados y asuma que ha entrenado un clasificador con “alta capacidad predictiva” (i.e., las probabilidades predichas son cercanas/idénticas a las verdaderas). ¿Qué valor del umbral de decisión (threshold) debería utilizar a los fines de minimizar el costo esperado de la campaña? Justifique de manera concisa su respuesta.

¿El cliente se da de baja?		¿Se envía la oferta?	
		Sí	No
	Sí	800	5.000
	No	800	10

Ejercicio 7

Suponga que usted se enfrenta a un problema de clasificación fuertemente desbalanceado y que el conjunto de datos contiene únicamente un gran número de variables predictoras continuas positivas. Teniendo esto en cuenta, usted entrena un modelo siguiendo los siguientes pasos (en el orden que se indican).

- Se cargan los datos disponibles para entrenar el modelo.
- Para toda variable predictora X_j se genera una serie de nuevas variables predictoras iguales a X_j elevada al cuadrado, al cubo, a la cuarta y a la quinta (i.e., $X_j^2, X_j^3, X_j^4, X_j^5$). Nótese que de este modo ahora se tendrán $5 * J$ variables predictoras (siendo J igual al número total de variables predictoras que contiene el conjunto de datos original).
- Se hace *oversampling* de la clase minoritaria.
- Se separa un conjunto de validación elegido al azar (digamos el 20% de los datos).
- Utilizando el 80% de los datos de entrenamiento, se entrenan distintos modelos con distintas combinaciones de hiperparámetros (seleccionados sobre la base de una estrategia exhaustiva de *grid search*) y se elige aquella combinación que tiene mejor performance en el 20% de los datos de validación.
- Se entrena el mejor modelo identificado en el paso E con todos los datos disponibles (el 80% de entrenamiento + el 20% de validación).
- Se lleva el modelo a producción (i.e., se hace que prediga sobre datos nuevos).

Responda:

- ¿Qué error grave tiene el *pipeline* de trabajo planteado? Justifique de manera concisa su respuesta indicando qué da lugar a dicho error.
- ¿Qué efectos no deseables esperaría obtener si siguiera este pipeline de trabajo tal cual se lo propone? Justifique de manera concisa su respuesta.
- ¿Cómo corregiría el pipeline de trabajo para evitar cometer el error que usted detectó? Justifique de manera concisa su respuesta. IMPORTANTE: en un examen, se tomaría como incorrecto proponer correcciones sobre pasos que no generan problemas.

Ejercicio 8

En el capítulo 2 de ISLP, se indica que la esperanza del error al cuadrado entre valor a predecir y la predicción es igual a la siguiente expresión (2.3 en el libro):

$$\begin{aligned}
 E(Y - \hat{Y})^2 &= E[f(X) + \epsilon - \hat{f}(X)]^2 \\
 &= \underbrace{[f(X) - \hat{f}(X)]^2}_{\text{Reducible}} + \underbrace{\text{Var}(\epsilon)}_{\text{Irreducible}}
 \end{aligned}$$

La expresión anterior asume que $Y = f(X) + \epsilon$, que $\hat{Y} = \hat{f}(X)$, $E(\epsilon) = 0$ y que tanto $\hat{f}$ como X se encuentran fijas. Derive usted la expresión mencionada en el libro. Relacione dicha expresión con la *notebook* `underfitting_and_overfitting.ipynb` vista en la tercera clase teórica.

Ejercicio 9

- Demuestre que tanto en *ridge regression* como en *lasso regression* cuando λ (i.e., el parámetro que controla la cantidad de regularización) tiende a infinito, las predicciones del modelo tienden a la media de la variable a predecir en el conjunto de entrenamiento.
- Demuestre que si se penaliza también por el valor de B_0 , las predicciones del modelo serán igual a 0.
- Demuestre que la suma de los errores al cuadrado de entrenamiento en caso de penalizar la constante son mayores o iguales a los obtenidos en caso de no penalizarla.

Ejercicio 10

Suponga que trabaja en el contexto de un modelo lineal ($y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_p X_{ip} + \varepsilon_i$) y que minimiza la siguiente función de costo a los fines de estimar los valores de los coeficientes:

$$C(\beta_0, \beta_1, \dots, \beta_p; X_{tr}, y_{tr}) = \frac{1}{n} \sum_{i=1}^n [\ln(y_i) - \ln(\hat{\beta}_0 + \sum_{j=1}^p \beta_j \cdot x_{i,j})]^2 + \lambda \sum_{j=1}^p \beta_j^2$$

Demuestre que cuando λ tiende a infinito, las predicciones del modelo tienden a la media geométrica de la variable a predecir en el conjunto de entrenamiento. Puede asumir que tanto los valores de y como de sus predicciones son siempre mayores a 0.

Ejercicio 11

Suponga que se encuentra trabajando en el contexto de un problema de clasificación binaria como el que tratamos en clases, al presentar la matriz de costos para medir performance de clasificadores (en donde un cliente podía darse de baja o no el siguiente mes y en donde uno podía o no enviarle una oferta). Suponga que tiene la siguiente matriz de costos.

	oferta	no oferta
baja	C(b,o)	C(b,no)
no baja	C(nb,o)	C(nb,no)

Suponga que dispone de un clasificador que, para una i cualquiera con atributos x_i , predice con exactitud $P(y=baja|x_i)$. Asumiendo las siguientes restricciones:

- $C(nb,o) > C(nb,no)$: el costo de enviar la oferta es mayor si el cliente no se iba a dar de baja.
 - $C(b,no) > C(b,o)$: el costo de no enviar la oferta es mayor si el cliente iba a darse de baja.
 - La matriz no tiene valores negativos.
- A. Derive la expresión general del threshold a partir del cual conviene enviar la oferta que debería elegir a los fines de minimizar el costo esperado de la campaña.
- B. Demuestre que a medida que $c(b,no)$ aumenta (i.e., a medida que más caro se vuelve perder un cliente) el threshold disminuye.

Ejercicio 12

En la sección “6.1.2 Stepwise Selection” de ISLP, se indica que tanto en *backward* como en *forward selection* se entrenan $1 + p(p+1)/2$ modelos, siendo p la cantidad de predictores. Es decir, la complejidad asintótica en términos de p igual a $O(p^2)$.

Ahora, consideremos el siguiente enfoque híbrido. Se seguirán agregando variables de manera similar a como se hace *forward selection* (tal como se describe en el libro). Sin embargo, a partir de la segunda iteración (para $k \geq 1$), llevamos a cabo un proceso adicional. Para cada una de las variables que fueron previamente incorporadas al modelo (y que aún están siendo consideradas), evaluamos si su eliminación mejora el rendimiento en validación. Si observamos una mejora al eliminar una variable, procedemos a eliminarla permanentemente del modelo y nunca la volvemos a contemplar como variable predictora. Por otro lado, si no notamos ninguna mejora al eliminar una variable, la conservamos en el modelo (pudiendo ser eliminada en iteraciones futuras).

Es importante destacar que en cada iteración k , es posible que eliminemos todas las variables que fueron agregadas en las $k-1$ iteraciones anteriores. Asimismo, existe la posibilidad de que el algoritmo finalice sin haber eliminado ninguna variable en absoluto.

Noten que el peor de los casos, en términos de cómputo, es aquel en donde nunca se observa una mejora en validación al eliminar una variable. En dicho caso, ¿cuántos modelos se entrenan al ejecutar este método híbrido de punta a punta? ¿La complejidad asintótica deja de ser $O(p^2)$?