

## TD VI: Inteligencia Artificial

### Guía de ejercicios 2

**Ejercicio 1.** Indique o verdadero o falso y justifique.

- Si un modelo XGBoost está sobreajustando los datos de entrenamiento, es mala idea aumentar el valor de `min_child_weight`.
- Si un modelo SVM está haciendo underfitting, es buena idea subir el valor de `C` (del “budget” - tal como lo presenta ISLP).
- En word2vec, a medida que se aumenta el tamaño de la ventana, menos demora el algoritmo en entrenar.
- La tarea de generar una representación densa para obtener embeddings de palabras puede ser abordada como un problema de self-supervised learning.
- Es de esperar que los clusters obtenidos por el algoritmo de *k*-medias varíen según si las variables están escaladas o no, pero que esto no ocurra en los algoritmos de clustering jerárquico.
- El algoritmo de Bayes ingenuo está pensado para predecir una clase sobre la base de variables categóricas, y no existe estrategia para utilizarlo si alguna variable predictora del conjunto de datos de entrenamiento es continua.
- Saber el número de componentes a considerar en un análisis de componentes principales es simple, lo único que hay que hacer es ver si al agregar un componente adicional se observa una reducción en el error medido en el conjunto de validación.

**Ejercicio 2.** Resuelva el ejercicio 4 de la sección 4.8 del libro ISLP.

**Ejercicio 3.** Resuelva los ejercicios 1 y 2 de la sección 9.7 del libro ISLP.

**Ejercicio 4.** Suponga que usted tiene un conjunto de datos con 5 observaciones (A, B, C, D, E) y la siguiente matriz de distancias entre dichas observaciones:


|   | A    | B    | C    | D    | E    |
|---|------|------|------|------|------|
| A | 0.00 | 0.30 | 0.20 | 0.10 | 0.05 |
| B | 0.30 | 0.00 | 0.15 | 0.30 | 0.20 |
| C | 0.20 | 0.15 | 0.00 | 0.80 | 0.20 |
| D | 0.10 | 0.30 | 0.80 | 0.00 | 0.20 |
| E | 0.05 | 0.20 | 0.20 | 0.20 | 0.00 |

- Grafique el dendrograma que se obtendría luego de correr sobre esta matriz de distancias un algoritmo de clustering jerárquico utilizando **single linkage**. Para obtener este gráfico deberá ir calculando matrices de distancias intermedias (en donde figuren las distancias de los clusters que se van creando a medida que avanza el algoritmo). Se pide que también presente en su resolución estas matrices intermedias.
- Ahora haga lo mismo, pero utilizando **complete linkage**.

**Ejercicio 5.** Suponga que para un determinado conjunto de datos se lleva adelante un análisis de clustering jerárquico. Primero calcula la matriz de distancias (en la cual **no se observan valores duplicados excepto por los 0 de la diagonal principal**). Después, por un lado se obtiene un dendrograma utilizando **average linkage** y por el otro se obtiene otro dendrograma utilizando **single linkage**. Responda las siguientes dos preguntas:

- a) Suponga que en cierto paso en el dendrograma que utiliza average linkage, un cluster formado únicamente por las observaciones  $\{A, B\}$  y un cluster formado únicamente por las observaciones  $\{C, D, E\}$  se fusionan. A su vez, en el dendrograma que utiliza single linkage, también ocurre que en cierto paso un cluster formado únicamente por las mismas observaciones  $\{A, B\}$  y otro formado únicamente por las mismas observaciones  $\{C, D, E\}$  se fusionan. ¿Cuál de las dos fusiones ocurrirá más arriba en el dendrograma? ¿O ocurrirán a la misma altura? ¿O no se dispone de información suficiente para responder? Justifique su respuesta.
- b) Suponga que en cierto punto en el dendrograma que utiliza average linkage, un cluster formado únicamente por la observación  $\{L\}$  y un cluster formado únicamente por la observación  $\{M\}$  se fusionan a una altura  $X$ . Suponga también que en el dendrograma que utiliza single linkage ocurre que en cierto punto un cluster formado únicamente por la observación  $\{R\}$  y un cluster formado por las observaciones  $\{S, T\}$  se fusionan a una altura  $Y$ . A su vez, asuma que  $X$  es menor a  $Y$  ( $X < Y$ ). Si llamamos  $d(i, j)$  a la distancia entre la observación  $i$  y la observación  $j$ , ¿es cierto o falso que  $d(R, S) < d(L, M)$ ? Justifique su respuesta. Si considera que no se dispone de la información suficiente para responder esta pregunta indique qué información adicional se requiere para responderla.

**Ejercicio 6.** La figura que se muestra abajo contiene 6 dendrogramas, de los cuales se sabe lo siguiente:



- Tres de los seis fueron obtenidos a partir de una matriz de distancias dada a la que llamamos "L", mientras que los restantes tres fueron obtenidos a partir de la matriz de distancias  $2 * L$  (o sea cada elemento de  $L$  multiplicado por 2).
- Dos de los seis fueron obtenidos utilizando complete linkage como método de aglomeración, dos de los seis fueron obtenidos utilizando single linkage como método de aglomeración y los restantes dos utilizando average linkage como método de aglomeración.

Teniendo esto en cuenta, responda los siguientes puntos:

- a) Indique cuáles de los dendrogramas fueron creados tomando como input la matriz de distancias  $L$  y cuáles fueron creados tomando como input la matriz de distancias  $2 * L$ . Justifique brevemente su respuesta.
- b) Sabiendo que  $L$  es la matriz que se muestra debajo y que los dendrogramas obtenidos son los que se mostraron previamente, indique qué método de aglomeración (single, complete o average) se utilizó en cada uno de los seis dendrogramas. Justifique brevemente su respuesta.

|   | a     | b     | c     | d     | e     | f     |
|---|-------|-------|-------|-------|-------|-------|
| a | 0.000 | 0.255 | 0.030 | 0.120 | 0.190 | 0.170 |
| b | 0.255 | 0.000 | 0.205 | 0.185 | 0.195 | 0.175 |
| c | 0.030 | 0.205 | 0.000 | 0.200 | 0.115 | 0.070 |
| d | 0.120 | 0.185 | 0.200 | 0.000 | 0.250 | 0.100 |
| e | 0.190 | 0.195 | 0.115 | 0.250 | 0.000 | 0.110 |
| f | 0.170 | 0.175 | 0.070 | 0.100 | 0.110 | 0.000 |

**Ejercicio 7.** Resuelva los siguiente puntos referidos al algoritmo de Bayes ingenuo:

- a) En clases derivamos:

$$P(C_k|x_i) \propto \prod_{j=1}^p P(v_j = x_{ij}|C_k) \cdot P(C_k)$$

Es decir, que la probabilidad condicional es proporcional al likelihood por el prior. Ahora demuestre que se puede calcular la probabilidad exacta mediante la siguiente expresión:

$$P(C_k|x_i) = \frac{\prod_{j=1}^p P(v_j = x_{ij}|C_k) \cdot P(C_k)}{\sum_{l=1}^K \prod_{j=1}^p P(v_j = x_{ij}|C_l) \cdot P(C_l)}$$

- b) Si en Bayes ingenuo, al usar suavizado aditivo, se aumenta el valor de  $\alpha$  haciendo que tienda a infinito, ¿a qué valor tienden las probabilidades predichas? Justifique su respuesta. Asuma que todas las variables predictoras son categóricas.

**Ejercicio 8.** Suponga que se enfrenta a un problema de clasificación, que cuenta con 1200 observaciones de entrenamiento; en donde 2/3 de las observaciones son de la clase “0” y 1/3 de las observaciones son de la clase “1”.

Usted decide entrenar un modelo de regresión logística con penalización cuadrática de los coeficientes. De modo que:

- El modelo vendrá dado por:

$$P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{im}) = \frac{1}{1 + e^{-(\beta_0 + \sum_{j=1}^m \beta_j x_{ij})}}$$

- La función de costo a optimizar vendrá dada por:

$$-\frac{1}{n} \sum_{i=1}^n [y_i \ln(P(y_i = 1/\beta_0, \beta_1, \dots, \beta_m; x_i)) + (1 - y_i) \ln(1 - P(y_i = 1/\beta_0, \beta_1, \dots, \beta_m; x_i))] + \frac{1}{2} \lambda \sum_{j=1}^m \beta_j^2$$

Responda y justifique su respuesta:

- 1) ¿A qué valor tiende  $\beta_0$  a medida que  $\lambda$  tiende a infinito?
- 2) Relacione su respuesta con la obtenida en el ejercicio 7.

**Ejercicio 9.** Al momento de predecir la probabilidad de que una observación pertenezca a una clase dada, el algoritmo de vecinos más cercanos pondera por igual a cada observación de la vecindad identificada. Esto puede dar lugar a “empates” (sobre todo cuando  $k$  es par).

Se pide que proponga una alternativa en donde la probabilidad condicional se estime teniendo en cuenta algún tipo de ponderación que tenga en cuenta la distancia de la observación a predecir a cada uno de los vecinos encontrados.

**Ejercicio 10.** Demuestre que, para una observación de entrenamiento  $i$  cualquiera, las derivadas primera ( $g_i$ ) y segunda ( $h_i$ ) de cross-entropy respecto al valor predicho ( $\hat{y}_i$ ) vienen dadas por:

$$g_i = -\frac{y_i}{\hat{y}_i} + \frac{(1-y_i)}{(1-\hat{y}_i)} \quad h_i = \frac{y_i}{\hat{y}_i^2} + \frac{(1-y_i)}{(1-\hat{y}_i)^2}$$

**Ejercicio 11.** Demuestre la expresión 2.7 del libro ISLP. Es decir, demuestre que:

$$E \left( y_0 - \hat{f}(x_0) \right)^2 = \text{Var}(\hat{f}(x_0)) + [\text{Bias}(\hat{f}(x_0))]^2 + \text{Var}(\epsilon)$$

**Ejercicio 12.** Resuelva el ejercicio 1 de la sección 12.6 del libro ISLP.