



Guia 6: Optimizadores e Hiperparámetros

1. Q&A

- ¿Por qué escalar los valores de entrada es importante?
- ¿Por qué inicializar todos los gradientes en cero es problemático?
- Al utilizar dropout se produce un efecto en el impacto cuantitativo de los pesos en la predicción. ¿Cómo puede afectar esto a la predicción final de nuevos datos? ¿Cómo lo podríamos solucionar?
- En Mini Batch, ¿qué pasa cuando el tamaño del batch es 1?, y ¿qué pasa cuando el tamaño del batch es N? Siendo N la cantidad de datos de entrenamiento.
- Explique la diferencia entre dying neuron y vanishing/exploding gradient. ¿Cómo afecta cada uno a la red?

2. ¿Cuáles de los siguientes mecanismos sirven para atacar el problema del vanishing gradient?

- Batch Normalization ☐
- Eliminar el momentum ☐
- Estrategias de inicialización de pesos ☐
- Aumentar las capas de la red neuronal ☐
- Utilizar LogSoftmax en vez de Softmax ☐

3. Aumentación de datos

Nombre 4 formas de aumentación de datos para los siguientes formatos:

1. Imágenes
2. Sonido
3. Video
4. Texto

4. Optimizadores

- a. ¿Cómo se actualizan los pesos con el método del momentum? ¿Para qué sirve?
- b. ¿Qué desventaja tiene el momentum frente a ADAGrad?
- c. ¿Por qué en ADAGrad la variable que utilizamos para ponderar la actualización del gradiente, tiene el cómputo del gradiente al cuadrado?
- d. ¿Qué introduce ADAM y que ventajas trae?

5. Optimizadores: Verdadero o Falso

- La función de pérdida asociada a todo perceptrón multicapa es siempre convexa. ☐
- Con una cantidad suficiente de iteraciones, el algoritmo de descenso por gradiente garantiza encontrar el mínimo global en funciones no-convexas. ☐
- Con una cantidad suficiente de iteraciones y un tamaño del paso adecuado, el algoritmo de descenso por gradiente garantiza encontrar el mínimo global en funciones convexas. ☐
- Si se cuenta con una gran cantidad de datos de entrenamiento, mediante el método del gradiente descendente, es posible encontrar el mínimo global de la función de pérdida asociado a todo perceptrón multicapa. ☐

6. Regularización Weight Decay: Verdadero o Falso

- Weight decay ayuda a disminuir el sobreajuste a los datos de entrenamiento. ☐
- Weight decay es un mecanismo pensado para mejorar el rendimiento de una red neuronal no en datos de prueba (validación, evaluación, producción) sino en datos de entrenamiento. ☐
- Weight decay aumenta la cantidad de parámetros de una red neuronal. ☐
- Weight decay aumenta la cantidad de hiperparámetros de una red neuronal. ☐

7. Regularización Dropout: Verdadero o Falso

- Dropout es un mecanismo pensado para mejorar el rendimiento de una red neuronal no en datos de entrenamiento sino en datos de prueba (validación, evaluación, producción). ☐
- Dropout aumenta la cantidad de parámetros de una red neuronal. ☐
- Dropout aumenta la cantidad de hiperparámetros de una red neuronal. ☐
- Dropout puede ser utilizado en capas convolucionales. ☐
- Weight decay y dropout pueden ser utilizados en combinación. ☐