

¿Puede haber ciclos en una red neuronal?

¿Puede haber ciclos en una red neuronal?

No.

Explicar la estructura del perceptrón

Explicar la estructura del perceptrón

Se cuenta con los inputs (escalares), un peso de ese input y un bias (opcionalmente).

Se hace la suma de los inputs multiplicados por sus respectivos pesos. Finalmente, se aplica una función de activación.

¿Qué es un MLP? ¿Cómo se organiza?

¿Qué es un MLP? ¿Cómo se organiza?

Un MLP es un perceptrón multicapa.

Un MLP cuenta con todas capas fully connected (FC). Tiene una input layer, hidden layer(s) y una output layer.

Definir shallow y deep network

Definir shallow y deep network

Una shallow network tiene más neuronas de input. Las hace más anchas viéndolas de manera horizontal.

Una deep network tiene más hidden layers. La hace más profunda.

¿Qué es un tensor? ¿Qué ventajas tiene?

¿Qué es un tensor? ¿Qué ventajas tiene?

Un tensor es un arreglo multidimensional de escalares.

Sirve para datos de alta dimensionalidad (como imágenes o audios), es eficiente para GPU, y es una representación fácil de inputs, outputs, weights y biases.

Definir forward propagation y sus pasos a seguir.

Definir forward propagation y sus pasos a seguir.

Forward propagation computa el output para un input. Se hacen los cálculos a través de cada capa en el sentido de IL/HL/OL para conseguir una predicción $\hat{y}$. A medida que se avanza, se guardan los parámetros para usar en backward propagation.

Definir backward propagation y su proceso. ¿Qué ventaja y desventaja tiene?

Definir backward propagation y su proceso. ¿Qué ventaja y desventaja tiene?

Es el proceso de actualizar los pesos y biases usando el gradiente de la función loss. Se busca minimizar la función loss en el training set. Va en sentido contrario a forward propagation.

Primero, se calcula la función loss definida por $\hat{y} - y$ a grandes rasgos. Luego, se calculan los gradientes usando la regla de la cadena. Luego, se aplica el learning rate LR al gradiente. Finalmente, se actualizan los pesos y biases yendo en sentido contrario: OL/HL/IL.

Ventaja: es eficiente, ya que una observación del dataset requiere una pasada forward y una pasada backward.

Desventaja: es sensible a la arquitectura de la red, porque afecta su estabilidad.

Nombrar los dos tipos de capas.

Nombrar los dos tipos de capas.

Capas entrenables: sus pesos y biases se modifican en backpropagation.

Capas no entrenables: sus pesos y biases quedan fijos en training para mantener las features aprendidas previamente.

¿Qué es la vectorización y para qué sirve?

¿Qué es la vectorización y para qué sirve? ¿Cuáles son sus ventajas? ¿Cómo queda el cálculo de una neurona en una hidden layer?

Es una práctica común para almacenar pesos, inputs y biases en vectores. Sirve para simplificar las operaciones y acelerar los tiempos.

Las ventajas que trae son la escalabilidad, la claridad, la capacidad de procesamiento en batch, performance y paralelismo.

$$\phi(\mathbf{W}^T \mathbf{x} + \mathbf{b})$$

Donde ϕ es la función de activación, $\mathbf{W}$ el vector de pesos, $\mathbf{x}$ el vector de inputs y $\mathbf{b}$ el vector de biases.

¿Qué es y para qué sirve la función loss?

¿Qué es y para qué sirve la función loss?

Es una función que compara la predicción predicha con la etiqueta real en el proceso de training: $\hat{y} - y$.

Sirve para guiar el entrenamiento de la red.

¿Para qué sirven los grafos computacionales?

¿Para qué sirven los grafos computacionales?

Para reutilizar cálculos y ayudar con la eficiencia del backpropagation. Las librerías lo usan mucho.

¿Para qué sirven y por qué son importantes las funciones de activación?

¿Para qué sirven y por qué son importantes las funciones de activación?

Sirven para aprender mapeos no lineales y para capturar estructuras complejas de los datos.

Porque, de no tenerlas, la red se colapsaría a una única capa con la combinación lineal.

Nombrar y describir las funciones de activación lineales.
¿Qué ventajas y qué desventajas tiene?

Nombrar y describir la función de activación lineal. ¿Qué ventajas y qué desventajas tiene?

Función de identidad: el output es el mismo que el input. $f(x) = x$.

Ventajas: simples y eficientes, son fáciles de interpretar.

Desventajas: limitadas con datos con patrones complejos, colapsa la red. Generalmente se usa en la capa de output.

Nombrar y describir las funciones escalonadas. ¿Qué ventajas y qué desventajas tienen?

Nombrar y describir las funciones escalonadas. ¿Qué ventajas y qué desventajas tienen?

Heaviside step: cuando el valor está del lado izquierdo a un umbral tiene un valor. Cuando está del lado derecho tiene otro.

Función de signo: es una función heaviside step pero con -1 para valores negativos y 1 para valores positivos.

Ventajas: son simples y fáciles de implementar y las salidas binarias convienen para problemas de clasificación.

Desventajas: no es diferenciable en el threshold, es sensible a pequeños cambios en el input y no posee información de gradiente para aprender.

Nombrar y describir las funciones lineales por partes.
¿Qué ventajas y qué desventajas tienen?

Nombrar y describir las funciones lineales por partes. ¿Qué ventajas y qué desventajas tienen?

ReLU: si el input es negativo, el output es cero. Si el input es positivo, es la función identidad. $f(x) = \max(0, x)$

Leaky ReLU: el resultado para los valores negativos cambia. Es igual a ReLU solo que la parte negativa está inclinada.

Shifted ReLU: es ReLU pero con otro threshold.

Ventajas (ReLU): simple y eficiente, introduce no linealidad en la red, ayuda con el problema de vanishing gradient.

Desventajas (ReLU): las neuronas con el input negativo pueden desactivarse.

Ventajas (var. ReLU): threshold variable, la neurona no puede morir, mismos beneficios que ReLU.

Desventajas (var. ReLU): más hiperparámetros.

Nombrar y describir las funciones suaves. ¿Qué ventajas y qué desventajas tienen?

Nombrar y describir las funciones suaves. ¿Qué ventajas y qué desventajas tienen?

Softplus: es la versión suave de la ReLU. $f(x) = \ln(1 + e^x)$.

ELU: es la versión suave de la Shifted ReLU.

Sigmoide: es una curva con forma de S, con su output acotado entre 0 y 1.

Tanh: es igual que la sigmoide, con su output acotado entre -1 y 1.

Swish: es una combinación entre ReLU y Sigmoide.

Ventajas: son suaves y diferenciables. La sigmoide sirve para clasificación, tanh para convergencia, swish usa self-gating y ELU evita que la neurona muera.

Desventajas: son costosas y sufren del vanishing gradient.

Describir el problema de Vanishing Gradient y Dying Neuron.

Describir el problema de Vanishing Gradient y Dying Neuron.

Vanishing Gradient: cuando los gradientes se hacen muy pequeños durante back-propagation a través de las capas.

Dying Neuron: cuando las neuronas siempre están inactivas y sus pesos no se actualizan dado que su gradiente es cero.

Explicar la función Softmax y Log-Softmax.

Explicar la función Softmax y Log-Softmax.

Softmax: es una operación que se aplica únicamente y en simultáneo a todas las neuronas en la capa de output. Sirve para normalizar las salidas a una distribución de probabilidad.

Log-Softmax: es hacer el logaritmo de la función SoftMax. Sirve para aportar estabilidad a los números.