

TDVI: Inteligencia Artificial

Recurrent Neural Nets (RNN) y Long short-term memory networks (LSTMs)

Licenciatura en Tecnología Digital




Agenda

1. **Feed Forward**
2. Recurrent Neural Networks
3. LSTMs: Long short-term memory networks
4. LSTM vs. RNN
5. BiLSTM
6. Aplicaciones
7. Bibliografía

Feed Forward Neural Net


- Flujo de información es unidireccional
 - para adelante en el sentido desde el input hacia el output
- No tiene ciclos



Flujo de información

Feed Forward Neural Net - Cons

- No manejas datos secuenciales
- Operan sobre los datos actuales
- No recuerdan datos previos




Flujo de información

Agenda

1. Feed Forward
2. **Recurrent Neural Networks**
3. LSTMs: Long short-term memory networks
4. LSTM vs. RNN
5. BiLSTM
6. Aplicaciones
7. Bibliografía

Redes Neuronales Recurrentes (RNN)

- Maneja información secuencial
- Considera los datos actuales y también los anteriores
- Recuerda datos anteriores
 - tiene memoria



Aplicaciones de RNN


- Predicción de series de tiempo
 - Predicción de precios en activos
- Procesamiento del lenguaje natural
 - text mining
 - sentiment analysis
- Traducciones
 - El orden y formas cambian por idiomas

Máquinas de estados


- Una red neuronal recurrente es una máquina de estados con redes neuronales que constituyen las funciones f y g :

$$s_t = f(s_{t-1}, x_t)$$

$$y_t = g(s_t)$$




RNN



Aplicamos los mismos pesos a cada output

- Vamos generando nuevos estados $\mathbf{h}$ y estos se utilizan para calcular un nuevo estado y/o salida




Ejemplo: entrenamiento supervisado

$$\hat{\mathbf{y}}_t = \text{softmax}(\mathbf{W}_o \mathbf{h}_t), \mathbf{W}_o \in \mathbb{R}^{|V| \times d}$$


Cross-entropy loss:

$$L(\theta) = -\frac{1}{n} \sum_{t=1}^n \log \hat{\mathbf{y}}_{t-1}(w_t)$$

$$\theta = \{\mathbf{W}, \mathbf{U}, \mathbf{b}, \mathbf{W}_o, \mathbf{E}\}$$



¿Back-propagation ?



Backpropagation through time (BPTT)

$$\mathbf{h}_1 = g(\mathbf{W}\mathbf{h}_0 + \mathbf{U}\mathbf{x}_1 + \mathbf{b})$$

$$\mathbf{h}_2 = g(\mathbf{W}\mathbf{h}_1 + \mathbf{U}\mathbf{x}_2 + \mathbf{b})$$


$$\mathbf{h}_3 = g(\mathbf{W}\mathbf{h}_2 + \mathbf{U}\mathbf{x}_3 + \mathbf{b})$$

$$L_3 = -\log \hat{\mathbf{y}}_3(w_4)$$

$$\frac{\partial L_3}{\partial \mathbf{W}} = \frac{\partial L_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{W}} + \frac{\partial L_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{W}} + \frac{\partial L_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{h}_1} \frac{\partial \mathbf{h}_1}{\partial \mathbf{W}}$$

$$\frac{\partial L}{\partial \mathbf{W}} = -\frac{1}{n} \sum_{t=1}^n \sum_{k=1}^t \frac{\partial L_t}{\partial \mathbf{h}_t} \left(\prod_{j=k+1}^t \frac{\partial \mathbf{h}_j}{\partial \mathbf{h}_{j-1}} \right) \frac{\partial \mathbf{h}_k}{\partial \mathbf{W}}$$

Backpropagation through time (BPTT) Truncado



- A medida que la secuencia es más larga, backpropagation es más costoso
 - Correr forward y backpropagation en ventanas/batches
 - Mantenemos todos los estados forward pero utilizamos solamente de a ventanas para el cálculo en backpropagation

Ventajas de RNN

- Pueden procesar entradas de cualquier longitud
 - el tamaño del modelo no aumenta a medida que crece el tamaño de la entrada.
- La memoria interna es una propiedad inherente que se utiliza para procesar secuencias arbitrarias de entradas
 - a diferencia de las redes neuronales feedforward.
- Diseñado para recordar información a lo largo del tiempo
 - muy útil en predictores de series temporales.
- Los pesos de todas las capas ocultas dependientes entre sí pueden ser compartidos a lo largo del tiempo
 - mayor eficiencia en el modelo.
- RNN + CNN
 - eficaz predicción del vecindario de píxeles.

Desventajas de RNN

- Lenta.
- El entrenamiento puede ser muy difícil
 - En especial secuencias muy largas si se utilizan funciones de activación como ReLU o tanh.
- Propenso a problemas como la explosión y desvanecimiento del gradiente.
- No pueden apilarse en modelos muy profundos.
- No capturan relaciones a largo plazo.

Vanishing gradient

Si los gradientes se vuelven muy pequeños (casi nulos) a lo largo de largas distancias (paso a paso), entonces no podemos determinar si:

- No necesitamos dependencias a largo plazo.
- Tenemos parámetros incorrectos para capturar la verdadera dependencia.

Los perros en el vecindario están ____

Vanishing gradient

Si los gradientes se vuelven muy pequeños (casi nulos) a lo largo de largas distancias (paso a paso), entonces no podemos determinar si:

- No necesitamos dependencias a largo plazo.
- Tenemos parámetros incorrectos para capturar la verdadera dependencia.

Los perros en el vecindario están _____

sigue siendo difícil de predecir "*ladrando*".

Agenda


1. Feed Forward
2. Recurrent Neural Networks
- 3. LSTMs: Long short-term memory networks**
4. LSTM vs. RNN
5. BiLSTM
6. Aplicaciones
7. Bibliografía

Long Short-Term Memory (LSTM)

- Long Short-Term Memory (LSTM) es un tipo de Red Neuronal Recurrente (RNN) diseñado específicamente para manejar **datos secuenciales**, como series temporales, habla y texto.
- Las redes LSTM son **capaces de aprender dependencias a largo plazo** en datos secuenciales, lo que las hace adecuadas para tareas como la traducción de lenguaje, el reconocimiento de voz y la predicción de series temporales.
- En una RNN tradicional, hay un **único estado oculto** que se transmite a lo largo del tiempo, lo que puede dificultar que la red aprenda dependencias a largo plazo.
 - Las LSTMs abordan este problema introduciendo una **celda de memoria**, que es un contenedor que puede retener información durante un período prolongado.


Puertas

- La celda de memoria está controlada por tres puertas:
 - La puerta de **entrada** controla qué información se agrega a la celda de memoria.
 - La puerta de **olvido** controla qué información se elimina de la celda de memoria.
 - La puerta de **salida** controla qué información se produce desde la celda de memoria.
- Esto permite a las redes LSTM retener o descartar selectivamente información a medida que fluye a través de la red y así aprender dependencias a largo plazo.




Memoria

- Actualizamos la memoria utilizando el operador de producto Hadamard (producto punto a punto)
 - Si la puerta de olvido siempre es 1 y la puerta de entrada siempre es 0, el estado interno de la celda de memoria permanecerá constante
 - las puertas dan al modelo la flexibilidad de aprender cuándo mantener este valor inalterado y cuándo perturbarlo en respuesta a las entradas subsiguientes.
- Este diseño alivia el problema del gradiente desvaneciente en la práctica, lo que facilita el entrenamiento de modelos, especialmente con secuencias largas en los conjuntos de datos.




Estado oculto

- Valores de la puerta de salida
 - cercanos a 1 la celda de memoria impacta a las capas subsiguientes sin restricciones.
 - cercanos a 0 evita que la memoria actual afecte a otras capas de la red
- Una celda de memoria puede acumular información a lo largo de muchos pasos sin afectar al resto de la red
- Puede impactar repentinamente a la red en un paso subsiguiente
 - si la puerta de salida cambia de valores cercanos a 0 a valores cercanos a 1.



LSTM



Agenda

1. Feed Forward
2. Recurrent Neural Networks
3. LSTMs: Long short-term memory networks
4. **LSTM vs. RNN**
5. BiLSTM
6. Aplicaciones
7. Bibliografía

LSTM vs. RNN

	RNN	LSTM
Arquitectura	Básica red recursiva	RNN con celdas de memoria
Retención de memoria	Problemática con memoria a largo plazo y vanishing gradient	Maneja memoria a largo plazo y ayuda al problema del vanishing gradient
Estructura de unidad	Estado oculto	Estado oculto y puerta de entrada, de salida y de memoria
Manejo de secuencias	si, limitado a memoria largo plazo	si
Eficiencia de entrenamiento	simple, y más rápido	más complejo, más lento

Agenda

1. Feed Forward
2. Recurrent Neural Networks
3. LSTMs: Long short-term memory networks
4. LSTM vs. RNN
5. **BiLSTM**
6. Aplicaciones
7. Bibliografía

BiLSTM: Bilateral LSTM ¿por qué?

Traducción:

Python is the.....

BiLSTM: Bilateral LSTM ¿por qué?

Traducción:


Python is the.....

Contexto:

Python is the genus of constricting snakes in the Pythonidae family.

Python is the interpreted, object-oriented, high-level programming language with dynamic semantics that is used widely around the world.

BiLSTM



Bi-LSTM

- El LSTM bidireccional (bi-LSTM) permite que una red neuronal tenga información secuencial en ambas direcciones:
 - hacia atrás (futuro al pasado)
 - hacia adelante (pasado al futuro).
 - La entrada fluye en ambas direcciones
 - Preserva información tanto del futuro como del pasado
-
- Genera dos secuencias de representaciones ocultas, una correspondiente al procesamiento ascendente y otra al procesamiento descendente.
 - Estas representaciones se combinan para producir una representación final que refleja el contexto completo de la secuencia en cada punto.

Agenda


1. Feed Forward
2. Recurrent Neural Networks
3. LSTMs: Long short-term memory networks
4. LSTM vs. RNN
5. BiLSTM
- 6. Aplicaciones**
7. Bibliografía

Aplicaciones


- Simulación de Lenguaje:
 - Procesamiento de lenguaje natural, como la traducción automática, el modelado de lenguaje y la resumen de texto.
 - Al comprender las relaciones entre las palabras en una oración, pueden ser entrenadas para construir oraciones significativas y gramaticalmente correctas.
- Reconocimiento de Voz:
 - Transcripción de voz a texto y el reconocimiento de comandos.
 - Pueden ser entrenadas para reconocer patrones en el habla y relacionarlos con el texto apropiado.
- Análisis de Sentimientos
- Predicción de Series Temporales:
 - predecir valores futuros en una serie temporal
- Análisis de Video:
 - Pueden utilizarse para aprender las relaciones entre los fotogramas y las acciones, objetos y escenas asociados.

Aplicaciones


Language modeling



Sequence tagging




Text classification



Ejemplo traducción

{I am a student}_{ENG} → {मैं एक छात्र हूँ}_{HINDI}



Bibliografía

- RNN
 - <https://arxiv.org/pdf/1912.05911.pdf>
- LSTM
 - <https://deeplearning.cs.cmu.edu/F23/document/readings/LSTM.pdf>
- Understanding LSTM:
 - <https://arxiv.org/pdf/1909.09586.pdf>
- BiLSTM:
 - <https://arxiv.org/pdf/1508.01991.pdf>