

TDVI: Inteligencia Artificial

Regresión logística / Support Vector Machines

UTDT - LTD

Estructura de la clase

- Repaso de regresión logística
- Introducción a SVMs

Estructura de la clase


- Repaso de regresión logística
- Introducción a SVMs

Repaso de regresión logística

Recordemos qué mide *cross-entropy* (log-loss):

Para una observación i , toma valores altos si no se predice una alta probabilidad a la clase correcta

Para el caso binario: $CE = -\frac{1}{n} \sum_{i=1}^n (y_i \cdot \ln(\hat{P}(y_i = 1|x_i)) + (1 - y_i) \cdot \ln(1 - \hat{P}(y_i = 1|x_i)))$



Aclaración: minimizar cross-entropy es equivalente a maximizar likelihood como se presenta en ISLP



$$\prod_{i:y_i=1} p(x_i) \prod_{i':y_{i'}=0} (1 - p(x_{i'}))$$

Repaso de regresión logística

En regresión logística (que es un clasificador), asumimos la siguiente **forma funcional**:

$$p(y_i = 1/x_{i1}, x_{i2}, \dots, x_{im}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_m x_{im})}}$$


Es decir, la probabilidad predicha se relaciona con cada predictor mediante la **función sigmoidea**



Repaso de regresión logística

¿Cómo afecta el valor de los coeficientes al comportamiento de la predicción?

Esto es un modelo no lineal



Subir $b_0 \Rightarrow$ correr a la izquierda
Bajar $b_0 \Rightarrow$ correr a la derecha

Para cualquier valor de x_i

Cross entropy bajo, aplica mejor el modelo

Pensemos en el caso de un único predictor

$$p(y_i = 1/x_{1i}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_i)}}$$

Repaso de regresión logística

¿Es regresión logística un clasificador lineal?

¿Cómo hacer para que logre captar no linealidades?

Pensemos en el caso de dos predictores:

$$\hat{P}(y_i = 1/x_{i1}, x_{i2}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2})}}$$

Los puntos donde z (el exponente de e) da cero es la frontera

La regresión logística separa el espacio de atributos con una línea

Repaso de regresión logística

Tomaremos como los coeficientes estimados a aquellos que **minimizan cross-entropy** medido en **el training set**

$$CE = -\frac{1}{n} \sum_{i=1}^n (y_i \cdot \ln(\hat{P}(y_i = 1|x_i)) + (1 - y_i) \cdot \ln(1 - \hat{P}(y_i = 1|x_i)))$$

$$\hat{P}(y_i = 1/x_{i1}, x_{i2}, \dots, x_{im}) = \frac{1}{1 + e^{-(\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_m x_{im})}}$$

Es decir:

$$\min_{\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_m; X, y} = CE(\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_m; X, y)$$



Los valores que minimizan esta expresión **no pueden encontrarse mediante una fórmula cerrada**

¿Cómo podremos encontrarlos?

Repaso de regresión logística

Lo haremos a través de algún método numérico de optimización. Por ejemplo, descenso gradiente

$$\theta_{i+1} = \theta_i - \gamma * \nabla (\theta_i)$$



Repaso de regresión logística

Para entrenar un modelo de regresión logística con descenso gradiente necesitamos las **derivadas parciales de CE respecto a cada coeficiente**

Son tediosas de derivar ([link](#)), pero la expresión final que se obtiene es sorprendentemente simple

Si el costo viene dado por: $J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^i \log(h_{\theta}(x^i)) + (1 - y^i) \log(1 - h_{\theta}(x^i))$

La probabilidad predicha por: $h_{\theta}(x) = g(\theta^T x)$ $g(z) = \frac{1}{1 + e^{-z}}$

La derivada parcial de CE respecto a cada parámetro es igual a:

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x^i$$

Antes de ejecutar el algoritmo **es buena práctica escalar las variables** ([link](#))

Repaso de regresión logística

Cross-entropy puede modificarse de la siguiente manera:

Cross entropy + Ridge

$$CE_{reg} = CE(\Theta; X, y) + \frac{1}{2} \lambda \sum_{j=1}^p \theta_j^2$$

Para evitar overfitting, modificás el lambda

Ahora **se penaliza la complejidad del modelo**. Importante: el coeficiente asociado a la constante (o bias), no se penaliza.

La derivada parcial de la función de costo respecto a cada coeficiente penalizado vendrá dada por:

$$\frac{\partial}{\partial \theta_j} CE_{reg} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x^i + \lambda \theta_j$$

¿Qué efecto tiene aumentar λ ?

¿A qué tenderá la predicción cuando λ tiende a infinito?

Repaso de regresión logística

En este diagrama se resume todo lo visto:




Figure 11: Conceptual overview of logistic regression.

Fuente: <https://arxiv.org/pdf/1811.12808.pdf>

Estructura de la clase

- Repaso de regresión logística
- Introducción a SVMs

Introducción a SVMs

Versión (base)

Supongamos que trabajamos con p atributos (un espacio de atributos de dimensión p), ¿qué es un hiperplano en dicho espacio?

El plano de atributos

Dados unos valores de β , serán todos los valores de x que cumplen con la condición:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p = 0$$

Si por el contrario, se tiene que:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p > 0$$

Decimos que una observación se encuentra de un lado del hiperplano. Si fuera menor a 0, decimos que se encuentra del otro

Introducción a SVMs

Veamos un ejemplo con $p = 2$




FIGURE 9.1. The hyperplane $1 + 2X_1 + 3X_2 = 0$ is shown. The blue region is the set of points for which $1 + 2X_1 + 3X_2 > 0$, and the purple region is the set of points for which $1 + 2X_1 + 3X_2 < 0$.

Introducción a SVMs

Supongamos que tenemos valores de X como siempre, pero ahora y puede valor -1 ó 1 (estamos en un problema de clasificación binaria)

Objetivo: queremos encontrar un hiperplano que separe el espacio de atributos de manera que de un lado del mismo queden las observaciones con $y = 1$ y del otro queden las observaciones con $y = -1$

Sin perder generalidad vamos a querer lo siguiente:

$$\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} > 0 \text{ if } y_i = 1,$$

$$\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} < 0 \text{ if } y_i = -1$$

O lo que es lo mismo:



$$y_i(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}) > 0$$

Introducción a SVMs

Si los datos **son linealmente separables**, seguramente existan **infinitos hiperplanos** que cumplan con:

$$y_i(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}) > 0$$

Un hiperplano es un conjunto de parámetros B. Todos separan "bien" los datos porque se cumple que los azules queden de un lado, y los violetas del otro.



Margen = distancia al punto más cercano a la frontera
Queremos que sea lo más grande posible para las dos opciones de predecir.


Vamos a decir que el mejor de ellos será el que tenga **el mayor margen**

No todas las observaciones influyen en la posición del hiperplano

Introducción a SVMs

Maximal Margin Classifier

El hiperplano de mayor margen será aquel que, clasificando bien las observaciones, tenga **mayor distancia mínima** con las mismas




Si $\beta_0, \beta_1, \dots, \beta_p$ son los coeficientes del maximal margin classifier, una observación **será predicha por el signo de**:

$$f(x^*) = \beta_0 + \beta_1 x_1^* + \beta_2 x_2^* + \dots + \beta_p x_p^*$$

Introducción a SVMs

En la figura, son 3 las observaciones que definen la posición del hiperplano separador. Las otras podrían no estar y se obtendría **el mismo hiperplano!**

A las observaciones sobre el margen se las conoce como los **vectores de soporte** (*support vectors*)



El vector sería el punto...

Introducción a SVMs

¿Cómo se encuentra el hiperplano con mayor margen?

Es el que surge del siguiente problema de optimización

$$\underset{\beta_0, \beta_1, \dots, \beta_p, M}{\text{maximize}} \quad M \quad \text{M = margen. Sin restricciones se iría a infinito.} \quad (9.9)$$

$$\text{subject to} \quad \sum_{j=1}^p \beta_j^2 = 1, \quad \text{La suma de todos los beta da como resultado 1} \quad (9.10)$$

$$y_i(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}) \geq M \quad \forall i = 1, \dots, n. \quad (9.11)$$

La distancia de cada punto al hiperplano $\geq$ margen

Si no es linealmente separable el dataset, 9.10 y 9.11 no tienen solución. Linealmente separable es poder separar los datos en dos regiones por un hiperplano


La restricción 9.10 es importante. Si se cumple, entonces la distancia de cada observación i al hiperplano vendrá dada por:

$$y_i(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip})$$

Las observaciones para las que 9.11 es igualdad son los vectores de soporte

Introducción a SVMs

¿Qué sucede en casos no linealmente separables?



<-- No linealmente separable

FIGURE 9.4. *There are two classes of observations, shown in blue and in purple. In this case, the two classes are not separable by a hyperplane, and so the maximal margin classifier cannot be used.*

Introducción a SVMs

Support vector classifier (soft margin classifier)

No sirve hacer una función partida. Solamente una única función lineal.




FIGURE 9.5. Left: Two classes of observations are shown in blue and in purple, along with the maximal margin hyperplane. Right: An additional blue observation has been added, leading to a dramatic shift in the maximal margin hyperplane shown as a solid line. The dashed line indicates the maximal margin hyperplane that was obtained in the absence of this additional point.

Incluso siendo un problema linealmente separable, podríamos preferir que se "equivoque" en algunas observaciones de entrenamiento

Dejar de lado la menor cantidad de observaciones equivocadas?

Introducción a SVMs

Ahora permitiremos que algunas observaciones estén del **lado incorrecto del margen o incluso del lado incorrecto del hiperplano**




FIGURE 9.6. Left: A support vector classifier was fit to a small data set. The hyperplane is shown as a solid line and the margins are shown as dashed lines. Purple observations: Observations 3, 4, 5, and 6 are on the correct side of the margin, observation 2 is on the margin, and observation 1 is on the wrong side of the margin. Blue observations: Observations 7 and 10 are on the correct side of the margin, observation 9 is on the margin, and observation 8 is on the wrong side of the margin. No observations are on the wrong side of the hyperplane. Right: Same as left panel with two additional points, 11 and 12. These two observations are on the wrong side of the hyperplane and the wrong side of the margin.

Introducción a SVMs

Este comportamiento se obtiene al intentar a optimizar el siguiente problema de optimización:

$$\underset{\beta_0, \beta_1, \dots, \beta_p, \epsilon_1, \dots, \epsilon_n, M}{\text{maximize}} \quad M \quad (9.12)$$

$$\text{subject to} \quad \sum_{j=1}^p \beta_j^2 = 1, \quad (9.13)$$

$$y_i(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}) \geq M(1 - \epsilon_i), \quad (9.14)$$

$$\epsilon_i \geq 0, \quad \sum_{i=1}^n \epsilon_i \leq C, \quad (9.15)$$


A las ϵ se las conoce como *slack variables*

- $\epsilon_i = 0 \rightarrow$ la observación i está del **lado correcto del margen**
 - $\epsilon_i > 0 \rightarrow$ la observación i está del **lado incorrecto del margen**
 - $\epsilon_i > 1 \rightarrow$ la observación i está del **lado incorrecto del hiperplano**
- } Vectores de soporte + las $\epsilon_i = 0$ en el margen

Más pequeño sea C (el "*budget*") $\rightarrow$ menos permitiremos que haya observaciones del lado incorrecto del margen

Introducción a SVMs

A menor valor de C , **menos se toleran errores** en entrenamiento



Introducción a SVMs

¿Qué sucede con los problemas que requieren fronteras no lineales?




FIGURE 9.8. Left: The observations fall into two classes, with a non-linear boundary between them. Right: The support vector classifier seeks a linear boundary, and consequently performs very poorly.

Se podrían hacer expansiones polinómicas y se podría utilizar SVC (como venimos haciendo en regression logística)

Introducción a SVMs

La solución de 9.12 a 9.15, únicamente considera el **producto interno de todos los pares de observaciones** (el producto interno captura similitud)

$$\langle x_i, x_{i'} \rangle = \sum_{j=1}^p x_{ij} x_{i'j}$$

A su vez, el clasificador (la función utilizada para clasificar) puede expresarse como se muestra abajo (siendo S los vectores de soporte):

$$f(x) = \beta_0 + \sum_{i \in S} \alpha_i \langle x, x_i \rangle$$


Kernel trick: si reemplazamos los productos internos tradicionales por generalizaciones del producto interno (K), se tiene que: 1) la solución de 9.12 a 9.15 sólo dependerá de $K(x_i, x_j)$ y 2) el clasificador vendrá dado por:

$$f(x) = \beta_0 + \sum_{i \in S} \alpha_i K(x, x_i)$$

Introducción a SVMs

¿Qué es un kernel?

Una función que, dadas dos observaciones (en el espacio de atributos original), devuelve el valor del **producto interno de dichas observaciones en un espacio expandido**



Recuerden:

- La solución (en el espacio expandido) sólo depende de los productos internos en dicho espacio (lo que devuelve el kernel)
- Para clasificar cada observación, alcanza con saber el valor del producto interno de dicha observación con cada vector de soporte (en el espacio expandido, lo que devuelve el kernel)

Introducción a SVMs

Polynomial kernel

$$K(x_i, x_{i'}) = \left(1 + \sum_{j=1}^p x_{ij} x_{i'j}\right)^d$$

Si en toda expresión de SVC se reemplazan los productos internos por esta expression, se obtienen fronteras no lineales

Si se trabaja con p atributos originales y un grado d , es como si se hubiera estado trabajando con un espacio expandido de dimensión $\binom{p+d}{d}$

Introducción a SVMs

Radial kernel

$$K(x_i, x_{i'}) = \exp\left(-\gamma \sum_{j=1}^p (x_{ij} - x_{i'j})^2\right)$$

Si las observaciones son lejanas (en términos de distancia euclídea) → el valor del kernel será bajo

El espacio implícito de este kernel tiene dimensión infinita

Interesante: existen kernels que miden similitud de objetos muy variados (e.g., grafos, texto, imágenes, etc.), de este modo, eligiendo el kernel apropiado, se puede usar SVMs tomando como input estos tipo de datos

Introducción a SVMs




FIGURE 9.9. Left: An SVM with a polynomial kernel of degree 3 is applied to the non-linear data from Figure 9.8, resulting in a far more appropriate decision rule. Right: An SVM with a radial kernel is applied. In this example, either kernel is capable of capturing the decision boundary.

Introducción a SVMs

Probemoslo en Python

Bibliografía

- ISLP, Capítulo 4. Secciones 4.1, 4.2 y 4.3
- ISLP, Capítulo 9
- Avanzada:
Alpaydin, E, “[*Introduction to Machine Learning*](#)”, Capítulo 13